IMCA

Maestría en Modelización Matemática y Computacional

Curso: Optimización

Semana 1: Introducción y Fundamentos de Optimización Continua

1. Formulación General del Problema

En esta primera semana establecemos el marco matemático formal para la optimización continua abstracta, tomando como base las formulaciones de Nocedal & Wright [NW] y Bertsekas [B].

Un problema de optimización continua no restringido se formula matemáticamente como:

$$\min_{x \in \mathbb{R}^n} f(x) \tag{1}$$

donde $f : \mathbb{R}^n \to \mathbb{R}$ es una función objetivo continuamente diferenciable ($f \in \mathcal{C}^1$ o $f \in \mathcal{C}^2$).

De manera más general, un problema con restricciones se escribe como:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeto a} \quad & c_i(x) = 0, \quad i \in \mathcal{E}, \\ & c_i(x) \geq 0, \quad i \in \mathcal{I}, \end{aligned} \tag{2}$$

donde $\mathcal{E}$ e $\mathcal{I}$ son los conjuntos finitos de índices para las restricciones de igualdad y desigualdad, respectivamente.

Definición 1.1: Mínimos Locales y Globales

Consideremos la función $f : \mathbb{R}^n \to \mathbb{R}$ y un conjunto factible $\Omega \subseteq \mathbb{R}^n$.

i) Un punto $x^* \in \Omega$ es un **mínimo local** de f sobre Ω si existe una vecindad $\mathcal{B}(x^*, \epsilon) = \{x \in \mathbb{R}^n : \|x - x^*\| < \epsilon\}$ con $\epsilon > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in \mathcal{B}(x^*, \epsilon) \cap \Omega$.

ii) Un punto $x^* \in \Omega$ es un **mínimo local estricto** si $f(x^*) < f(x)$ para todo $x \in (\mathcal{B}(x^*, \epsilon) \cap \Omega) \setminus \{x^*\}$.

iii) Un punto $x^* \in \Omega$ es un **mínimo global** si $f(x^*) \leq f(x)$ para todo $x \in \Omega$.

2. Fundamentos de Convexidad

La convexidad juega un rol central en optimización computacional debido a que elimina la brecha entre mínimos locales y mínimos globales.

Definición 2.1: Conjuntos y Funciones Convexas

I) Un conjunto $\mathcal{C} \subseteq \mathbb{R}^n$ es **convexo** si para todo $x, y \in \mathcal{C}$ y todo $\alpha \in [0,1]$, se cumple que $\alpha x + (1-\alpha)y \in \mathcal{C}$.

II) Una función $f : \mathcal{C} \to \mathbb{R}$ definida sobre un conjunto convexo $\mathcal{C}$ es **convexa** si para todo $x, y \in \mathcal{C}$ y todo $\alpha \in [0,1]$:

$$f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha) f(y)$$

Teorema 2.1: Óptimo Local es Óptimo Global

Sea $f : \mathcal{C} \to \mathbb{R}$ una función convexa definida sobre el conjunto convexo no vacío $\mathcal{C} \subseteq \mathbb{R}^n$. Si $x^* \in \mathcal{C}$ es un mínimo local de f sobre $\mathcal{C}$, entonces x^* es un mínimo global de f sobre $\mathcal{C}$.

Esbozo de Demostración. Razonemos por contradicción. Supongamos que x^* es un mínimo local pero no global. Entonces existe un punto $y \in \mathcal{C}$ tal que $f(y) < f(x^*)$.

Por la convexidad del conjunto $\mathcal{C}$, el segmento $x(\alpha) = (1-\alpha)x^* + \alpha y$ pertenece a $\mathcal{C}$ para todo $\alpha \in (0,1]$. Por la convexidad de la función f:

$$f(x(\alpha)) \leq (1-\alpha) f(x^*) + \alpha f(y) < (1-\alpha) f(x^*) + \alpha f(x^*) = f(x^*)$$

Tomando $\alpha > 0$ suficientemente pequeño tal que $x(\alpha) \in \mathcal{B}(x^*, \epsilon)$, obtenemos que $f(x(\alpha)) < f(x^*)$, lo cual contradice la hipótesis de que x^* es un mínimo local. □

Ejemplo de Aplicación: Garantía de Solución Global en Regresión Lasso (Data Science)

En el entrenamiento de modelos de Machine Learning con regularización L_1 (Lasso):

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1, \quad \lambda > 0$$

Tanto la norma residual $\|Ax - b\|_2^2$ como el penalizador $\|x\|_1$ son funciones convexas sobre el dominio convexo $\mathbb{R}^n$. Por el Teorema 2.1, cualquier algoritmo de optimización que converja a un mínimo local habrá encontrado garantizadamente la solución global del modelo.

Observación Crítica y Contraejemplo: Necesidad de Convexidad Conjunta (Dominio y Función)

Si el dominio $\mathcal{C}$ no es convexo o si la función f no es convexa, la propiedad de que todo mínimo local es global falla:

a) **Función no convexa en dominio convexo:** Para $f(x) = x^3 - 3x$ definida sobre el convexo $\mathbb{R}$, $x^* = 1$ es un mínimo local ($f(1) = -2$), pero no es global.

b) **Función convexa sobre dominio no convexo:** Minimizar la función convexa $f(x_1, x_2) = x_1$ sobre el conjunto acotado pero no convexo:

$$\Omega = \{(x_1, x_2) \in \mathbb{R}^2 : 1 \leq x_1^2 + x_2^2 \leq 4\}$$

El punto $x^* = (-2, 0)$ es el **mínimo global** ($f(-2, 0) = -2$). Sin embargo, si consideramos el punto $\tilde{x} = (1, 0)$ y una vecindad restringida a la frontera izquierda del disco interior, o si consideramos el problema con la restricción no convexa de igualdad $x_1^2 + x_2^2 = 1$, el punto $(-1, 0)$ actuaría como mínimo local dentro de esa componente mientras que en la frontera exterior $x^* = (-2, 0)$ alcanzamos un valor menor.

Proposición 2.1: Caracterización Diferenciable de Funciones Convexas

Sea $f : \mathcal{C} \subseteq \mathbb{R}^n \to \mathbb{R}$ continuamente diferenciable sobre un conjunto abierto y convexo $\mathcal{C}$.

I) f es convexa en $\mathcal{C}$ si y solo si para todo $x, y \in \mathcal{C}$:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) \tag{3}$$

II) Si f es dos veces continuamente diferenciable ($\mathcal{C}^2$), f es convexa en $\mathcal{C}$ si y solo si su matriz Hessiana $\nabla^2 f(x)$ es semidefinida positiva ($\nabla^2 f(x) \succeq 0$) para todo $x \in \mathcal{C}$.

Demostración. Demostramos ambas caracterizaciones utilizando la reducción del problema multidimensional al caso unidimensional sobre segmentos de recta.

Demostración de i) Caracterización de primer orden:

($\Rightarrow$) **Necesidad:** Supongamos que f es convexa en $\mathcal{C}$. Por definición, para todo $x, y \in \mathcal{C}$ y todo $t \in (0, 1]$ se cumple:

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y)$$

Reorganizando los términos:

$$f(x + t(y - x)) \leq f(x) + t(f(y) - f(x))$$

Restando $f(x)$ a ambos lados y dividiendo entre $t > 0$:

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x)$$

Tomando el límite cuando $t \to 0^+$, el término de la izquierda representa la derivada direccional de f en la dirección $(y - x)$:

$$\nabla f(x)^T (y - x) \leq f(y) - f(x) \implies f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

($\Leftarrow$) **Suficiencia:** Asumamos que (3) se cumple para todo par de puntos en $\mathcal{C}$. Sean $x, y \in \mathcal{C}$ y $t \in [0,1]$. Definimos $z = (1-t)x + ty$, el cual pertenece a $\mathcal{C}$ por ser un conjunto convexo. Evaluando la desigualdad (3) usando a z como punto de apoyo:

$$f(x) \geq f(z) + \nabla f(z)^T (x - z)$$
$$f(y) \geq f(z) + \nabla f(z)^T (y - z)$$

Multiplicando la primera por $(1-t) \geq 0$, la segunda por $t \geq 0$ y sumando ambas desigualdades:

$$(1-t)f(x) + tf(y) \geq f(z) + \nabla f(z)^T \Big((1-t)(x-z) + t(y-z) \Big)$$

Sustituyendo $(1-t)(x-z) + t(y-z) = (1-t)x + ty - z = z - z = 0$, obtenemos:

$$(1-t)f(x) + tf(y) \geq f(z) = f((1-t)x + ty)$$

Por lo tanto, f es convexa en $\mathcal{C}$.

Demostración de ii) Caracterización de segundo orden: Dados $x, y \in \mathcal{C}$, definimos la función escalar auxiliar de una variable $g : [0,1] \to \mathbb{R}$ como $g(t) = f(x + t(y-x))$. Por la regla de la cadena:

$$g'(t) = \nabla f(x + t(y-x))^T (y - x)$$
$$g''(t) = (y-x)^T \nabla^2 f(x + t(y-x))(y-x)$$

($\Rightarrow$) **Necesidad:** Si f es convexa en $\mathcal{C}$, entonces $g(t)$ es convexa en $[0,1]$. Para una función unidimensional C^2 convexa, la segunda derivada es no negativa en todo el dominio:

$$g''(t) \geq 0 \quad \forall t \in [0,1]$$

Evaluando en $t = 0$:

$$g''(0) = (y-x)^T \nabla^2 f(x)(y-x) \geq 0$$

Como $x \in \mathcal{C}$ es arbitrario y $y - x$ puede tomar la dirección de cualquier vector $v \in \mathbb{R}^n$, se concluye que $v^T \nabla^2 f(x) v \geq 0$ para todo $v \in \mathbb{R}^n$, es decir, $\nabla^2 f(x) \succeq 0$.

($\Leftarrow$) **Suficiencia:** Supongamos que $\nabla^2 f(z) \succeq 0$ para todo $z \in \mathcal{C}$. Esto implica que $g''(t) \geq 0$ para todo $t \in [0,1]$. Aplicando el Teorema de Taylor con resto en forma de Lagrange a $g(t)$ alrededor de $t = 0$:

$$g(1) = g(0) + g'(0)(1-0) + \frac{1}{2} g''(\xi) \quad \text{para algún } \xi \in (0,1)$$

Sustituyendo los valores de g, g' y g'':

$$f(y) = f(x) + \nabla f(x)^T (y-x) + \frac{1}{2} (y-x)^T \nabla^2 f(x + \xi(y-x))(y-x)$$

Dado que $\nabla^2 f(x + \xi(y-x)) \succeq 0$, el término cuadrático es no negativo:

$$\frac{1}{2} (y-x)^T \nabla^2 f(x + \xi(y-x))(y-x) \geq 0$$

Por lo tanto, $f(y) \geq f(x) + \nabla f(x)^T (y-x)$. Por el apartado i), f es convexa en $\mathcal{C}$.

□

Ejemplo de Aplicación: Aproximación Plano Tangente en Control Predictivo

La propiedad de subestimación lineal de la desigualdad (3) se utiliza en optimización de procesos industriales para construir aproximaciones internas de funciones de costo convexas mediante hiperplanos de corte (*cutting planes*), acelerando la convergencia en sistemas de control en tiempo real.

Observación Crítica y Contraejemplo: Dominio no Abierto y Dominios Desconectados

La hipótesis de que $\mathcal{C}$ es abierto y convexo es fundamental para que la derivada direccional esté bien definida en todas las direcciones hacia el interior de $\mathcal{C}$. Si evaluamos $f(x) = x^3$ en $\mathbb{R}$, tenemos $\nabla^2 f(x) = 6x$. La matriz Hessiana no es semidefinida positiva para $x < 0$, lo que confirma formalmente que la función no es convexa globalmente.

3. Condiciones de Optimidad No Restringidas

Consideremos el problema de minimización sin restricciones (1) con $f \in \mathcal{C}^2$.

Teorema 3.1: Condición Necesaria de Primer Orden (FONC)

Si $x^* \in \mathbb{R}^n$ es un mínimo local de $f : \mathbb{R}^n \to \mathbb{R}$ y f es continuamente diferenciable en un entorno abierto de x^*, entonces:

$$\nabla f(x^*) = 0$$

Un punto x^* que satisface $\nabla f(x^*) = 0$ se denomina **punto estacionario** o crítico.

Esbozo de Demostración. Sea $d \in \mathbb{R}^n$ una dirección fija cualquiera. Por la expansión de Taylor de primer orden alrededor de x^*:

$$f(x^* + \alpha d) = f(x^*) + \alpha \nabla f(x^*)^T d + o(\alpha)$$

Como x^* es mínimo local, para todo $\alpha > 0$ suficientemente pequeño se cumple $f(x^* + \alpha d) - f(x^*) \geq 0$. Dividiendo por α y tomando $\alpha \to 0^+$:

$$\nabla f(x^*)^T d \geq 0$$

Dado que la dirección d es arbitraria, reemplazando d por $-d$ se obtiene $\nabla f(x^*)^T(-d) \geq 0 \implies \nabla f(x^*)^T d \leq 0$. Por lo tanto, $\nabla f(x^*)^T d = 0$ para todo d, lo que implica $\nabla f(x^*) = 0$. □

Ejemplo de Aplicación: Criterio de Parada en Algoritmos de Optimización

En la implementación computacional de métodos numéricos como el Gradiente Descendente o Newton para minimizar el error de ajuste en modelos industriales, el Teorema 3.1 provee la condición práctica de parada: la ejecución se detiene cuando la norma del gradiente es menor a una tolerancia prefijada, $\|\nabla f(x_k)\| < \epsilon$.

Observación Crítica y Contraejemplo: FONC no es una Condición Suficiente

La condición $\nabla f(x^*) = 0$ es solo *necesaria*, no suficiente. Un punto estacionario puede corresponder a un máximo local o a un punto silla.

- **Función $f(x) = x^3$ en $\mathbb{R}$:** Se cumple $\nabla f(0) = 3(0)^2 = 0$. Sin embargo, $x^* = 0$ es un punto de inflexión (no es ni mínimo ni máximo local).
- **Función Silla de Monstruo en $\mathbb{R}^2$:** Para $f(x_1, x_2) = x_1^2 - x_2^2$, el gradiente es $\nabla f(0,0) = (0,0)^T$. Sin embargo, movernos en la dirección del eje x_1 aumenta la función, mientras que movernos en el eje x_2 la disminuye. Por ende, $(0,0)$ es un punto silla.

Teorema 3.2: Condiciones Necesarias y Suficientes de Segundo Orden

Sea $f : \mathbb{R}^n \to \mathbb{R}$ dos veces continuamente diferenciable sobre un entorno de x^*.

I) **Condición Necesaria de Segundo Orden (SONC):** Si x^* es un mínimo local de f, entonces $\nabla f(x^*) = 0$ y la matriz Hessiana es semidefinida positiva ($\nabla^2 f(x^*) \succeq 0$).

II) **Condición Suficiente de Segundo Orden (SOSC):** Si $\nabla f(x^*) = 0$ y la matriz Hessiana es definida positiva:

$$\nabla^2 f(x^*) \succ 0$$

entonces x^* es un mínimo local estricto de f.

Demostración. Dado que $f \in \mathcal{C}^2$, para cualquier vector de dirección $d \in \mathbb{R}^n$ y un escalar $t > 0$ lo suficientemente pequeño tal que $x^* + td$ pertenezca al entorno de x^*, la expansión de Taylor en forma de Lagrange establece:

$$f(x^* + td) = f(x^*) + t\nabla f(x^*)^T d + \frac{t^2}{2} d^T \nabla^2 f(x^* + \theta td) d$$

para algún $\theta \in (0, 1)$.

Demostración de i) SONC:

Supongamos que x^* es un mínimo local de f. Por la Condición Necesaria de Primer Orden (FONC), sabemos que $\nabla f(x^*) = 0$. Sustituyendo esto en la expansión de Taylor:

$$f(x^* + td) - f(x^*) = \frac{t^2}{2} d^T \nabla^2 f(x^* + \theta td) d$$

Como x^* es un mínimo local, $f(x^* + td) \geq f(x^*)$ para todo $t > 0$ suficientemente pequeño, lo que implica:

$$\frac{t^2}{2} d^T \nabla^2 f(x^* + \theta td) d \geq 0$$

Dividiendo entre $\frac{t^2}{2} > 0$:

$$d^T \nabla^2 f(x^* + \theta td) d \geq 0$$

Tomando el límite cuando $t \to 0^+$, y por la continuidad de $\nabla^2 f$ (dado que $f \in \mathcal{C}^2$):

$$d^T \nabla^2 f(x^*) d \geq 0$$

Como la dirección $d \in \mathbb{R}^n$ es arbitraria, se deduce que $\nabla^2 f(x^*) \succeq 0$.

Demostración de ii) SOSC:

Supongamos que $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*) \succ 0$.

Al ser $\nabla^2 f(x^*)$ definida positiva, su autovalor mínimo $\lambda_{\text{mín}}$ es estrictamente positivo ($\lambda_{\text{mín}} > 0$). Por el Cociente de Rayleigh-Ritz, para todo $d \neq 0$:

$$d^T \nabla^2 f(x^*) d \geq \lambda_{\text{mín}} \|d\|^2 > 0$$

Por la continuidad de la matriz Hessiana, existe una bola abierta $B(x^*, r)$ con $r > 0$ tal que para todo $z \in B(x^*, r)$ y todo $d \neq 0$:

$$d^T \nabla^2 f(z) d \geq \frac{\lambda_{\text{mín}}}{2} \|d\|^2$$

Sea $x \in B(x^*, r)$ con $x \neq x^*$. Escribimos $h = x - x^* \neq 0$. Aplicando Taylor de segundo orden con $\nabla f(x^*) = 0$:

$$f(x) - f(x^*) = \frac{1}{2} h^T \nabla^2 f(x^* + \theta h) h$$

para algún $\theta \in (0, 1)$. Dado que $x^* + \theta h \in B(x^*, r)$:

$$f(x) - f(x^*) \geq \frac{\lambda_{\text{mín}}}{4} \|h\|^2 > 0$$

Por lo tanto, $f(x) > f(x^*)$ para todo $x \in B(x^*, r) \setminus \{x^*\}$, lo que prueba que x^* es un mínimo local estricto. □

Ejemplo de Aplicación: Verificación de Estabilidad en Estructuras de Ingeniería

En el análisis de estabilidad de estructuras mecánicas, los estados de equilibrio corresponden a puntos donde el gradiente de la energía potencial es nulo ($\nabla f(x^*) = 0$). La condición SOSC ($\nabla^2 f(x^*) \succ 0$) asegura que la estructura se encuentra en un estado de equilibrio estable ante pequeñas perturbaciones externas.

Observación Crítica y Contraejemplo: Hessiana Semidefinida Positiva no es Suficiente para Mínimo Estricto

Es un error común asumir que $\nabla^2 f(x^*) \succeq 0$ implica que x^* es un mínimo local.

a) **Caso $f(x) = x^3$:** Se satisface $\nabla f(0) = 0$ y $\nabla^2 f(0) = 0 \geq 0$ (semidefinida positiva), pero $x^* = 0$ no es mínimo.

b) **Caso $f(x) = -x^4$:** Se satisface $\nabla f(0) = 0$ y $\nabla^2 f(0) = 0 \geq 0$, pero $x^* = 0$ es de hecho un máximo local estricto.

Por ende, la estricta positividad de los autovalores ($\nabla^2 f(x^*) \succ 0$) es la hipótesis irreducible para garantizar la suficiencia local.

4. Ejercicios Propuestos

Ejercicio Propuesto (Verificación de Optimización Cuadrática)

Considere la función $f : \mathbb{R}^2 \to \mathbb{R}$ dada por:

$$f(x_1, x_2) = 2x_1^2 + x_2^2 - 2x_1x_2 + 2x_1 - 4x_2$$

a) Escriba $f(x)$ en la forma cuadrática vectorial $f(x) = \frac{1}{2}x^T Ax + b^T x$.

b) Calcule el gradiente $\nabla f(x)$ y la matriz Hessiana $\nabla^2 f(x)$.

c) Encuentre todos los puntos estacionarios de f y clasifíquelos aplicando las condiciones de segundo orden (SONC/SOSC).

Ejercicio Propuesto (Modelización de Estimación Robusta (Data Science))

En la estimación de parámetros industriales a partir de mediciones con ruido, se busca resolver $\min_{x \in \mathbb{R}^n} f(x)$ utilizando la función de pérdida de Huber $\rho_\delta(t)$, definida por:

$$\rho_\delta(t) = \begin{cases} \frac{1}{2}t^2 & \text{si } |t| \leq \delta \\ \delta|t| - \frac{1}{2}\delta^2 & \text{si } |t| > \delta \end{cases}$$

Demuestre formalmente que la función $\rho_\delta(t)$ es convexa y continuamente diferenciable ($\mathcal{C}^1$) en $\mathbb{R}$, y halle su derivada $\rho'_\delta(t)$.

Ejercicio Propuesto (Función de Rosenbrock y Puntos Silla)

Dada la función no convexa de Rosenbrock $f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$:

a) Demuestre que $x^* = (1, 1)^T$ es el único punto estacionario de f.

b) Verifique que $\nabla^2 f(x^*) \succ 0$ y concluya que x^* es un mínimo global estricto.

c) Muestre que la matriz Hessiana se vuelve indefinida o degenerada en ciertas regiones del plano, dificultando la convergencia de métodos de optimización clásicos.