IMCA

Maestría en Modelización Matemática y Computacional

Curso: Optimización
Profesores: E. Oré & E. Ocaña

Semana 6: Región de Confianza (*Trust Region*)

1. Introducción y Motivación

En la optimización continua sin restricciones

$$\min_{x\in\mathbb{R}^n} f(x),$$

donde $f:\mathbb{R}^n\to\mathbb{R}$ es de clase C^2, los métodos de **Búsqueda Lineal** (*Line Search*) eligen primero una dirección de descenso p_k y luego buscan una longitud de paso adecuada $\alpha_k>0$. Sin embargo, cuando la matriz Hessiana $\nabla^2 f(x_k)$ no es definida positiva o presenta mal condicionamiento, la dirección de Newton pura puede fallar o requerir modificaciones heurísticas artificiales.

La estrategia de **Región de Confianza** (*Trust Region*) invierte este orden conceptual: se fija primero un radio de región de confianza $\Delta_k>0$ (tamaño de paso) dentro del cual se confía en que un modelo cuadrático local $m_k(p)$ aproxima fielmente a $f(x_k+p)$, y luego se resuelve el subproblema acotado:

$$\min_{\|p\|\le\Delta_k} m_k(p).$$

Esta formulación adapta de forma natural la curvatura de la función (incluso con curvaturas negativas) ajustando dinámicamente el radio Δ_k según el acuerdo entre la reducción predicha por el modelo y la reducción real observada en la función objetivo.

2. Modelo Local Cuadrático y el Subproblema de Región de Confianza

Definición 2.1: Modelo Cuadrático Local y Subproblema

Sea $f:\mathbb{R}^n\to\mathbb{R}$ una función C^2. En la iteración x_k, la aproximación cuadrática local asociada m_k está dada por:

$$m_k(p)=f(x_k)+g_k^Tp+\frac{1}{2}p^TB_kp, \tag{1}$$

donde $g_k=\nabla f(x_k)$ y $B_k\in\mathbb{R}^{n\times n}$ es una matriz simétrica (típicamente $B_k=\nabla^2 f(x_k)$ o una aproximación cuasi-Newton).
El **Subproblema de Región de Confianza** consiste en resolver:

$$\min_{p\in\mathbb{R}^n} m_k(p) \quad \text{s.a.} \quad \|p\|\le\Delta_k, \tag{2}$$

donde $\|\cdot\|$ denota la norma euclidiana $\|\cdot\|_2$ y $\Delta_k>0$ es el radio de la región de confianza.

Interpretación Gráfica

Geométricamente, el subproblema de región de confianza restringe la búsqueda del paso $p \in \mathbb{R}^n$ a una bola cerrada $B(0, \Delta_k) = \{p \in \mathbb{R}^n : \|p\| \leq \Delta_k\}$ centrada en el origen del espacio de pasos. Se presentan dos escenarios fundamentales según el comportamiento del modelo cuadrático $m_k(p)$:

a) **Mínimo no restringido interior ($\|p_k^N\| \leq \Delta_k$):** Si la matriz $B_k \succ 0$ es definida positiva y el paso de Newton completo $p_k^N = -B_k^{-1} g_k$ cae estrictamente dentro o sobre la frontera de la bola, p_k^N resuelve globalmente el subproblema y se acepta directamente ($\lambda^* = 0$).

b) **Mínimo no restringido exterior ($\|p_k^N\| > \Delta_k$) o curvatura indefinida ($B_k \not\succ 0$):** Si p_k^N cae fuera de la bola de confianza (como en la Figura 1) o si B_k presenta direcciones de curvatura negativa, la solución óptima p_k^* se ubica **estrictamente sobre la frontera** $\|p\| = \Delta_k$.

Geométricamente, la solución óptima p_k^* (vector azul) es el **punto de tangencia exacta** entre la frontera de la bola de confianza $\|p\| = \Delta_k$ y la curva de nivel más interna alcanzable del modelo cuadrático $m_k(p)$ (elipse roja continua). En dicho punto p_k^*, la superficie del modelo y la frontera circular comparten la misma recta tangente (línea punteada), garantizando la condición KKT de alineación ortogonal de gradientes:

$$\nabla m_k(p_k^*) = -\lambda^* p_k^* \quad (\text{con } \lambda^* > 0).$$

Esta solución óptima p_k^* difiere explícitamente tanto de la dirección no restringida del paso de Newton p_k^N (vector rojo) como de su proyección radial directa sobre la esfera.

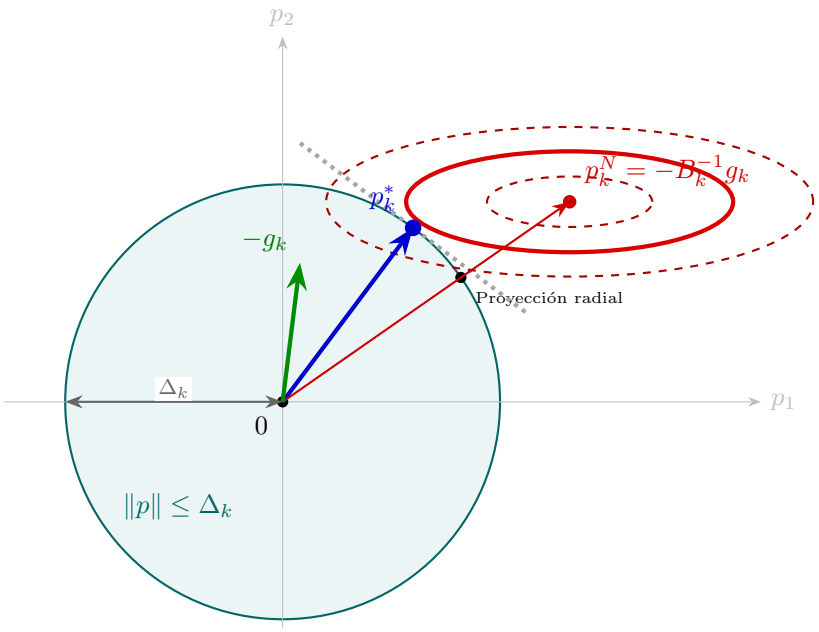


Figura 1: Geometría del subproblema de región de confianza cuando el paso de Newton p_k^N cae fuera de la bola de radio Δ_k. La solución óptima p_k^* (azul) se ubica en el punto de tangencia exacta (recta punteada) entre la bola $\|p\| = \Delta_k$ y la curva de nivel más interna del modelo $m_k(p)$ (elipse roja continua horizontal), diferenciándose explícitamente de la dirección del paso de Newton p_k^N (rojo) y de su proyección radial.

2.1. Evaluación del Paso y Actualización del Radio de Confianza

Para evaluar la calidad del paso candidato p_k, se define la razón entre la reducción real y la reducción predicha.

Definición 2.2: Razón de Reducción y Actualización del Radio

La **razón de reducción** ρ_k mide el grado de acuerdo entre la reducción real de la función objetivo y la reducción predicha por el modelo cuadrático m_k. Se define mediante

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)} = \frac{f(x_k) - f(x_k + p_k)}{-g_k^T p_k - \frac{1}{2} p_k^T B_k p_k}. \tag{3}$$

El numerador

$$f(x_k) - f(x_k + p_k)$$

representa la **reducción real** de la función objetivo, mientras que el denominador

$$m_k(0) - m_k(p_k)$$

representa la **reducción predicha** por el modelo cuadrático.
Por tanto, ρ_k compara lo que realmente ocurrió con lo que el modelo había predicho.

- Si $\rho_k > 1$, la reducción real es mayor que la reducción predicha por el modelo (el paso fue incluso mejor de lo esperado– El modelo subestimó la reducción real–).
- Si $\rho_k \approx 1$, la reducción real es cercana a la reducción predicha por el modelo. En este caso, el modelo proporciona una buena aproximación de f en el paso considerado.
- Si ρ_k es pequeña y positiva, la reducción real es mucho menor que la predicha por el modelo. Esto indica un acuerdo deficiente entre el modelo y la función.
- Si $\rho_k < 0$, la función objetivo aumenta al realizar el paso, aunque el modelo haya predicho una reducción.

Dados los parámetros

$$0 < \eta_1 \leq \eta_2 < 1,$$

el algoritmo utiliza ρ_k para decidir si el paso p_k es aceptado y para determinar cómo debe modificarse el radio Δ_k de la región de confianza.

Definición 2.3: Criterio de Aceptación del Paso

La primera decisión consiste en determinar si el paso p_k debe ser aceptado. Para ello se compara la razón ρ_k con el umbral η_1.

Caso 1: Rechazo del paso: $\rho_k < \eta_1$. Si $\rho_k < \eta_1$, la reducción obtenida en la función es demasiado pequeña en comparación con la reducción predicha por el modelo. Por tanto, el paso se considera poco satisfactorio y se rechaza:

$$x_{k+1} = x_k.$$

En este caso, además, se reduce el radio de la región de confianza. Por ejemplo,

$$\Delta_{k+1} = \frac{1}{2}\Delta_k.$$

Por consiguiente,

$$\boxed{\rho_k < \eta_1 \quad \Longrightarrow \quad x_{k+1} = x_k, \qquad \Delta_{k+1} = \frac{1}{2}\Delta_k.}$$

Caso 2: Aceptación del paso: $\rho_k \geq \eta_1$. Si $\rho_k \geq \eta_1$, la reducción real se considera suficientemente buena en relación con la reducción predicha. Por tanto, el paso se acepta:

$$x_{k+1} = x_k + p_k.$$

Es importante observar que la aceptación del paso no implica necesariamente que el radio deba aumentar. La actualización del radio depende además de la comparación de ρ_k con η_2 y de si el paso se encuentra en la frontera de la región.

Definición 2.4: Actualización del Radio de la Región de Confianza

Una vez determinada la aceptación del paso, se decide si el radio Δ_k debe reducirse, mantenerse o aumentarse.

Caso 1: Contracción: $\rho_k < \eta_1$. El paso es rechazado y el radio se reduce:

$$x_{k+1} = x_k, \qquad \Delta_{k+1} = \frac{1}{2}\Delta_k.$$

Caso 2: Mantenimiento del radio: $\eta_1 \leq \rho_k \leq \eta_2$. El paso es aceptado, $x_{k+1} = x_k + p_k$, pero el radio se mantiene:

$$\Delta_{k+1} = \Delta_k.$$

En este caso, el modelo ha sido suficientemente satisfactorio para aceptar el paso, pero no existe evidencia suficiente para ampliar la región.

Caso 3: Posible ampliación del radio: $\rho_k > \eta_2$. En este caso el paso es aceptado ($x_{k+1} = x_k + p_k$). Si además el paso se encuentra en la frontera de la región de confianza ($\|p_k\| = \Delta_k$), se amplía el radio:

$$\Delta_{k+1} = \text{mín}(2\Delta_k, \Delta_{\text{máx}}).$$

La condición $\|p_k\| = \Delta_k$ es importante: significa que el paso calculado ha utilizado toda la región disponible. Si, además, ρ_k es suficientemente grande, el buen acuerdo entre el modelo y la función sugiere que puede ser conveniente explorar una región más grande.

Por el contrario, si $\rho_k > \eta_2$ y $\|p_k\| < \Delta_k$, el paso se acepta, pero el radio se mantiene ($\Delta_{k+1} = \Delta_k$). Las razones se explican más abajo*.

En consecuencia, las decisiones del algoritmo pueden resumirse como sigue:

Condición	**Decisión sobre p_k**	**Actualización de Δ_k**
$\rho_k < \eta_1$	Rechazar	$\Delta_{k+1} = \frac{1}{2}\Delta_k$
$\eta_1 \leq \rho_k \leq \eta_2$	Aceptar	$\Delta_{k+1} = \Delta_k$
$\rho_k > \eta_2,\ \|p_k\| < \Delta_k$	Aceptar	$\Delta_{k+1} = \Delta_k$
$\rho_k > \eta_2,\ \|p_k\| = \Delta_k$	Aceptar	$\Delta_{k+1} = \text{mín}(2\Delta_k, \Delta_{\text{máx}})$

La idea fundamental es, por tanto:

mal acuerdo entre modelo y función	buen acuerdo y paso en la frontera
$\Downarrow$	$\Downarrow$
reducir la región	ampliar la región

mientras que en los demás casos el radio permanece sin cambios.

*__Referente al caso $\rho_k > \eta_2$ y $\|p_k\| < \Delta_k$,__ se establece que el paso p_k se acepta ($x_{k+1} = x_k + p_k$), pero el radio permanece inalterado ($\Delta_{k+1} = \Delta_k$). Las razones teóricas y geométricas son las siguientes:

1. **La restricción no estuvo activa ($\|p_k\| < \Delta_k$):** El paso calculado p_k se encuentra en el *interior* de la bola de confianza. Esto significa que la frontera $\|p\| = \Delta_k$ no limitó ni restringió la búsqueda del mínimo del modelo local $m_k(p)$. Por lo tanto, el mínimo encontrado coincide con un mínimo no restringido (como el paso de Newton completo p_k^N).

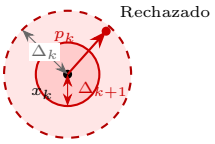
2. **Inutilidad de la ampliación del radio:** Aumentar el radio ($\Delta_{k+1} > \Delta_k$) no tendría un impacto real en la siguiente iteración, dado que el algoritmo ni siquiera utilizó todo el espacio disponible en la iteración actual. El tamaño de la región de confianza no fue un factor limitante.

3. **Criterio doble para la ampliación ($\Delta_{k+1} = \text{mín}(2\Delta_k, \Delta_{\text{máx}})$):** Para justificar la expansión de la región se requieren dos condiciones simultáneas:

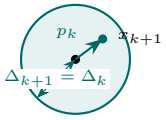
   - **Excelente acuerdo:** $\rho_k > \eta_2$ (el modelo cuadrático predice fielmente a f).
   - **Frontera activa:** $\|p_k\| = \Delta_k$ (el paso se vio forzado a detenerse en el límite del radio actual).

Observación

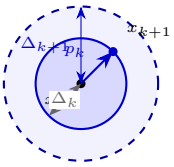
Como lo señala la **Definición 2.4**, "La condición $\|p_k\| = \Delta_k$ es importante: significa que el paso calculado ha utilizado toda la región disponible. Si, además, ρ_k es suficientemente grande, el buen acuerdo entre el modelo y la función sugiere que puede ser conveniente explorar una región más grande. Por el contrario, si $\rho_k > \eta_2$ y $\|p_k\| < \Delta_k$, el paso se acepta, pero el radio se mantiene ($\Delta_{k+1} = \Delta_k$)."



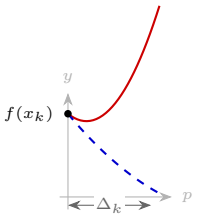
(a) $\rho_k < \eta_1$
Paso rechazado ($x_{k+1} = x_k$), $\Delta_{k+1} = \frac{1}{2}\Delta_k$.



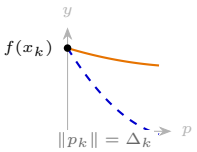
(b) $\eta_1 \leq \rho_k \leq \eta_2$
Paso aceptado ($x_{k+1} = x_k + p_k$), $\Delta_{k+1} = \Delta_k$.



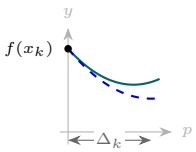
(c) $\rho_k > \eta_2$ y $\|p_k\| = \Delta_k$
Paso aceptado, $\Delta_{k+1} = 2\Delta_k$.



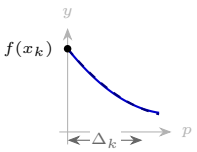
(d) $\rho_k < \eta_1$
Mal acuerdo.
Rechazado, $\Delta_{k+1} = \frac{\Delta_k}{2}$.



(e) $0 < \rho_k < \eta_1$
Reducción insuficiente.
Rechazado, $\Delta_{k+1} = \frac{\Delta_k}{2}$.



(f) $\eta_1 \leq \rho_k \leq \eta_2$
Buen acuerdo.
Aceptado, $\Delta_{k+1} = \Delta_k$.



(g) $\rho_k > \eta_2$ y $\|p_k\| = \Delta_k$
Excelente acuerdo.
Aceptado, $\Delta_{k+1} = 2\Delta_k$.

Figura 2: Resumen visual del comportamiento del algoritmo de Región de Confianza: actualización del radio Δ_k (arriba) y comparación gráfica entre el modelo cuadrático $m_k(p)$ y la función $f(x_k + p)$ (abajo).

Ejemplo de Aplicación: Sector Transporte – Optimización de Rutas Logísticas

En la planificación de flotas de transporte terrestre interprovincial, se busca minimizar el costo operativo total $f(x)$, donde $x \in \mathbb{R}^2$ representa las frecuencias semanales de despacho en dos corredores logísticos principales. El costo incluye gasto de combustible y mantenimiento (con efectos de congestión no lineal)[a].
Supongamos que en la iteración $x_k = (10, 5)^T$, el gradiente de costo es $g_k = (-4, -6)^T$ (\$/despacho) y la matriz de curvatura de costos es $B_k = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$. Fijamos un radio de región de confianza $\Delta_k = 1.0$ (variación máxima permitida de viajes por estabilidad operativa). El subproblema es:

$$\min_{p \in \mathbb{R}^2} m_k(p) = f(x_k) - 4p_1 - 6p_2 + \frac{1}{2}(2p_1^2 + 2p_1p_2 + 4p_2^2) \quad \text{s.a.} \quad p_1^2 + p_2^2 \leq 1.0.$$

El paso de Newton sin restricción resuelve $B_k p^N = -g_k$:

$$\begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} p_1^N \\ p_2^N \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix} \implies p_1^N = \frac{10}{7} \approx 1.43, \quad p_2^N = \frac{8}{7} \approx 1.14.$$

La norma del paso de Newton es $\|p^N\| = \sqrt{(1.43)^2 + (1.14)^2} \approx 1.83 > 1.0 = \Delta_k$. Por lo tanto, el mínimo del subproblema debe estar en la frontera $\|p\| = 1.0$.

[a] Por ejemplo, si la función de costo en una ruta es $C(x_1) = 20x_1 + 1.0x_1^2$, para la frecuencia actual de $x_{1,k} = 10$ despachos, el costo al ajustar en p_1 viajes es $C(10 + p_1) = 300 + 40p_1 + 1.0p_1^2$. La variación $\Delta C(p_1) = 40p_1 + 1.0p_1^2$ muestra un incremento lineal base $(40p_1)$ debido al consumo inmediato de combustible y peajes, y un término cuadrático $(1.0p_1^2)$ producido por la congestión adicional y el desgaste acelerado del motor y llantas.

3. Caracterización Exacta del Subproblema y Solución

El siguiente teorema fundamental establece las condiciones necesarias y suficientes para la solución global del subproblema de región de confianza.

Teorema 3.1: Caracterización Exacta de la Solución del Subproblema

El vector $p^* \in \mathbb{R}^n$ es una solución global del subproblema de región de confianza (2) si y solo si p^* satisface $\|p^*\| \leq \Delta_k$ y existe un escalar $\lambda^* \geq 0$ tal que se cumplen las siguientes condiciones:

$$(B_k + \lambda^* I)p^* = -g_k, \tag{4}$$
$$\lambda^*(\|p^*\| - \Delta_k) = 0, \tag{5}$$
$$(B_k + \lambda^* I) \succeq 0 \quad \text{(semidefinida positiva)}. \tag{6}$$

Demostración. La prueba se divide en dos partes.

⇐: Las condiciones implican optimalidad global. Supongamos que p^* es factible, $\|p^*\| \leq \Delta_k$, y que existe $\lambda^* \geq 0$ que satisface (4)–(6).

Sea p un punto factible arbitrario: $\|p\| \leq \Delta_k$. Por (4),

$$(B_k + \lambda^* I)p^* = -g_k,$$

de modo que $g_k = -(B_k + \lambda^* I)p^*$. Consideremos la diferencia entre los valores de la función cuadrática:

$$m_k(p) - m_k(p^*) = g_k^T(p - p^*) + \frac{1}{2}p^T B_k p - \frac{1}{2}(p^*)^T B_k p^*.$$

Sustituyendo la expresión de g_k:

$$m_k(p) - m_k(p^*) = -(p^*)^T(B_k + \lambda^* I)(p - p^*) + \frac{1}{2}p^T B_k p - \frac{1}{2}(p^*)^T B_k p^*.$$

Como B_k es simétrica, podemos reorganizar los términos para obtener:

$$m_k(p) - m_k(p^*) = \frac{1}{2}(p - p^*)^T(B_k + \lambda^* I)(p - p^*) + \frac{\lambda^*}{2}\left(\|p^*\|^2 - \|p\|^2\right). \tag{A}$$

Esta identidad es fundamental. Por (6), $B_k + \lambda^* I \succeq 0$, por lo que:

$$\frac{1}{2}(p - p^*)^T(B_k + \lambda^* I)(p - p^*) \geq 0. \tag{B}$$

Para el segundo término consideramos dos casos:

- **Caso 1 ($\lambda^* = 0$):** Entonces $\frac{\lambda^*}{2}\left(\|p^*\|^2 - \|p\|^2\right) = 0$. Por (A) y (B), $m_k(p) - m_k(p^*) \geq 0$.
- **Caso 2 ($\lambda^* > 0$):** De la condición de complementariedad (5), $\lambda^*(\Delta_k - \|p^*\|) = 0$, y puesto que $\lambda^* > 0$, tenemos $\|p^*\| = \Delta_k$. Como p es factible, $\|p\| \leq \Delta_k = \|p^*\|$, por tanto $\|p^*\|^2 - \|p\|^2 \geq 0$. Dado que $\lambda^* > 0$, resulta $\frac{\lambda^*}{2}\left(\|p^*\|^2 - \|p\|^2\right) \geq 0$. Junto con (B), nuevamente obtenemos $m_k(p) - m_k(p^*) \geq 0$.

Como p era un punto factible arbitrario, $m_k(p^*) \leq m_k(p)$ para todo p tal que $\|p\| \leq \Delta_k$. Por consiguiente, p^* es una solución global del subproblema.

$\Rightarrow$: La optimalidad global implica las tres condiciones. Supongamos ahora que p^* es una solución global de (2). La factibilidad es inmediata: $\|p^*\| \leq \Delta_k$. Definamos la restricción mediante $c(p) = \frac{1}{2}\left(\|p\|^2 - \Delta_k^2\right) \leq 0$. El subproblema queda entonces como:

$$\min_{p \in \mathbb{R}^n} m_k(p) \quad \text{sujeto a} \quad c(p) \leq 0.$$

Como $\Delta_k > 0$, el punto $p = 0$ satisface strictly la restricción: $c(0) = -\frac{1}{2}\Delta_k^2 < 0$. Por tanto, se satisface la condición de Slater y las condiciones KKT son necesarias para la optimalidad global. Existe entonces $\lambda^* \geq 0$ tal que:

$$\nabla m_k(p^*) + \lambda^* \nabla c(p^*) = 0, \quad c(p^*) \leq 0, \quad \lambda^* \geq 0, \quad \lambda^* c(p^*) = 0.$$

Como $\nabla m_k(p) = g_k + B_k p$ y $\nabla c(p) = p$, la condición de estacionariedad proporciona $g_k + B_k p^* + \lambda^* p^* = 0$, es decir:

$$(B_k + \lambda^* I)p^* = -g_k.$$

Esto demuestra (4). La condición de complementariedad es $\frac{1}{2}\lambda^*\left(\|p^*\|^2 - \Delta_k^2\right) = 0$, por tanto:

$$\lambda^*(\Delta_k^2 - \|p^*\|^2) = \lambda^*(\Delta_k - \|p^*\|)(\Delta_k + \|p^*\|) = 0.$$

Como $\Delta_k + \|p^*\| > 0$, obtenemos:

$$\lambda^*(\Delta_k - \|p^*\|) = 0.$$

Esto demuestra (5). Queda demostrar la condición esencial $B_k + \lambda^* I \succeq 0$.

Demostración de $B_k + \lambda^* I \succeq 0$: Definamos $H := B_k + \lambda^* I$. Por la condición de estacionariedad, $Hp^* = -g_k$. Supongamos, buscando una contradicción, que $H \not\succ 0$. Como H es simétrica, existe un autovalor negativo $\mu < 0$ y un autovector unitario v tales que:

$$Hv = \mu v, \qquad \|v\| = 1. \tag{D}$$

Distinguiremos dos casos:

- **Caso 1 ($v^T p^* \neq 0$):** Definamos $\alpha := v^T p^* \neq 0$ y consideremos el punto $\widehat{p} = p^* - 2\alpha v$. Como $\|v\| = 1$:

  $$\|\widehat{p}\|^2 = \|p^* - 2\alpha v\|^2 = \|p^*\|^2 - 4\alpha v^T p^* + 4\alpha^2 \|v\|^2 = \|p^*\|^2 - 4\alpha^2 + 4\alpha^2 = \|p^*\|^2.$$

  Por lo tanto, $\widehat{p}$ es factible. Además, $\widehat{p} - p^* = -2\alpha v$. Utilizando la identidad (A), que se deduce únicamente de la estacionariedad:

  $$m_k(\widehat{p}) - m_k(p^*) = \frac{1}{2}(\widehat{p} - p^*)^T H(\widehat{p} - p^*) + \frac{\lambda^*}{2}\left(\|p^*\|^2 - \|\widehat{p}\|^2\right).$$

  Como $\|\widehat{p}\| = \|p^*\|$, el segundo término desaparece. Por tanto:

  $$m_k(\widehat{p}) - m_k(p^*) = \frac{1}{2}(-2\alpha v)^T H(-2\alpha v) = 2\alpha^2 v^T H v = 2\alpha^2 \mu.$$

  Puesto que $\alpha \neq 0$ y $\mu < 0$, resulta $m_k(\widehat{p}) - m_k(p^*) < 0$, lo cual contradice la hipótesis de que p^* es un minimizador global. Por consiguiente, si H tuviera un autovalor negativo, necesariamente tendría que cumplirse $v^T p^* = 0$.

- **Caso 2 ($v^T p^* = 0$):** Consideremos, para $0 < t < \Delta_k$, el punto:

  $$p(t) = \sqrt{1 - \frac{t^2}{\Delta_k^2}}\, p^* + tv.$$

  Como $v^T p^* = 0$ y $\|p^*\| = \Delta_k$ (si p^* estuviera en el interior, $\lambda^* = 0$ y el resultado se deduce directamente):

  $$\|p(t)\|^2 = \left(1 - \frac{t^2}{\Delta_k^2}\right)\|p^*\|^2 + t^2\|v\|^2 = \left(1 - \frac{t^2}{\Delta_k^2}\right)\Delta_k^2 + t^2 = \Delta_k^2.$$

  Luego $p(t)$ pertenece a la frontera de la región de confianza y es factible. Definamos

  $$r(t) := \sqrt{1 - \frac{t^2}{\Delta_k^2}},$$

  cuya expansión de Taylor nos da

  $$r(t) - 1 = O(t^2), \text{ es decir } \exists\, c > 0 \text{ tal que } |r(t) - 1| \leq ct^2 \text{ para } |t| \text{ suff. pequeño.}$$

  En efecto. La fórmula general de Taylor para una función f centrada en 0 viene dada por

  $$f(x) = f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + O(x^3)$$

  Calculamos las derivadas de $f(x) = (1 - x)^{1/2}$:

  Evaluación en $x = 0$:

  $$f(0) = (1 - 0)^{1/2} = 1$$

Primera derivada:

$$f'(x) = -\frac{1}{2}(1-x)^{-1/2} \implies f'(0) = -\frac{1}{2}(1)^{-1/2} = -\frac{1}{2}$$

Segunda derivada:

$$f''(x) = -\frac{1}{4}(1-x)^{-3/2} \implies f''(0) = -\frac{1}{4}(1)^{-3/2} = -\frac{1}{4}$$

Sustituyendo estos valores en la serie de Taylor:

$$\sqrt{1-x} = 1 - \frac{1}{2}x - \frac{1}{8}x^2 + O(x^3).$$

Tomando $x = \frac{t^2}{\Delta_k^2}$ y aplicando la expansión obtenida en el paso anterior:

$$r(t) = 1 - \frac{1}{2}\left(\frac{t^2}{\Delta_k^2}\right) - \frac{1}{8}\left(\frac{t^2}{\Delta_k^2}\right)^2 + O\left(\left(\frac{t^2}{\Delta_k^2}\right)^3\right)$$

Simplificando los términos de potencia:

$$r(t) = 1 - \frac{1}{2\Delta_k^2}t^2 - \frac{1}{8\Delta_k^4}t^4 + O(t^6).$$

Dado que el término $-\frac{1}{8\Delta_k^4}t^4 + O(t^6)$ está dominado por t^4 para $t \to 0$, podemos agrupar todos los términos de orden igual o superior a 4 dentro de la notación $O(t^4)$:

$$r(t) - 1 = -\frac{1}{2\Delta_k^2}t^2 + O(t^4).$$

Afirmación: $-\frac{1}{2\Delta_k^2}t^2 + O(t^4) = O(t^2)$. Por definición de la notación O-grande, una función $g(t)$ es $O(t^2)$ cerca de $t = 0$ si existe una constante $C > 0$ tal que:

$$|g(t)| \leq Ct^2 \quad \text{para } |t| \text{ suff. pequeño.}$$

En nuestro caso, $g(t) = r(t) - 1 = -\frac{1}{2\Delta_k^2}t^2 + O(t^4)$. Dividiendo por t^2:

$$\lim_{t\to 0} \frac{|r(t)-1|}{t^2} = \lim_{t\to 0} \left| -\frac{1}{2\Delta_k^2} + O(t^2) \right| = \frac{1}{2\Delta_k^2} < \infty.$$

Entonces $p(t) - p^* = (r(t)-1)p^* + tv$. Como $Hv = \mu v$ y $v^T p^* = 0$, se tiene $v^T H p^* = (Hv)^T p^* = \mu v^T p^* = 0$. Por consiguiente:

$$(p(t)-p^*)^T H(p(t)-p^*) = (r(t)-1)^2 (p^*)^T H p^* + t^2 v^T H v = (r(t)-1)^2 (p^*)^T H p^* + \mu t^2.$$

Como $r(t) - 1 = O(t^2)$, se tiene $(r(t)-1)^2 = O(t^4)$, y por tanto:

$$(p(t)-p^*)^T H(p(t)-p^*) = \mu t^2 + O(t^4).$$

Dado que $\mu < 0$, para $t > 0$ suficientemente pequeño se cumple $\mu t^2 + O(t^4) < 0$. Además, $\|p(t)\| = \|p^*\| = \Delta_k$, por lo que el segundo término de la identidad (A) es cero. Así:

$$m_k(p(t)) - m_k(p^*) = \frac{1}{2}(p(t)-p^*)^T H(p(t)-p^*) < 0,$$

lo cual contradice nuevamente la optimalidad global de p^*.

Por consiguiente, tampoco puede existir un autovalor negativo de H. Concluimos que $H = B_k + \lambda^* I \succeq 0$, lo que demuestra (6).

Hemos demostrado que las tres condiciones son necesarias y suficientes para la optimalidad global del subproblema. □

Ejemplo de Aplicación: Sector Energético – Despacho Económico con Curvatura Negativa

En un sistema eléctrico de potencia con generadores eólicos y térmicos, la minimización de pérdidas de transmisión $f(x)$ presenta zonas no convexas debido a los efectos de punto de válvula. Supongamos que en la iteración x_k, el gradiente es $g_k = (2, -4)^T$ y la matriz Hessiana es indefinida:

$$B_k = \begin{pmatrix} -1 & 0 \\ 0 & 3 \end{pmatrix},$$

con radio de región de confianza $\Delta_k = 2$. Los autovalores de B_k son $\lambda_1 = -1$ y $\lambda_2 = 3$. Como B_k es indefinida, el mínimo no restringido no existe ($m_k(p) \to -\infty$ a lo largo del eje p_1).

Aplicamos el Teorema de Solución Exacta de Región de Confianza. Requerimos $\lambda^* \geq -\lambda_1(B_k) = 1$ para que $B_k + \lambda^* I \succeq 0$. Resolver $(B_k + \lambda I)p(\lambda) = -g_k$:

$$\begin{pmatrix} -1+\lambda & 0 \\ 0 & 3+\lambda \end{pmatrix} \begin{pmatrix} p_1(\lambda) \\ p_2(\lambda) \end{pmatrix} = \begin{pmatrix} -2 \\ 4 \end{pmatrix} \implies p_1(\lambda) = \frac{-2}{\lambda - 1}, \quad p_2(\lambda) = \frac{4}{\lambda + 3}.$$

Buscamos $\lambda^* > 1$ tal que $\|p(\lambda^*)\|^2 = \Delta_k^2 = 4$:

$$\frac{4}{(\lambda-1)^2} + \frac{16}{(\lambda+3)^2} = 4.$$

Evaluando para $\lambda = 2$:

$$\frac{4}{(2-1)^2} + \frac{16}{(2+3)^2} = 4 + \frac{16}{25} = 4.64 > 4.$$

Evaluando para $\lambda = 2.22$:

$$\frac{4}{(1.22)^2} + \frac{16}{(5.22)^2} \approx \frac{4}{1.488} + \frac{16}{27.25} \approx 2.68 + 0.587 = 3.267 < 4.$$

Por métodos de resolución de ecuaciones escalares de una variable[a], encontramos $\lambda^* \approx 2.083$, entregando un paso $p^* = (-1.846, 0.786)^T$ con $\|p^*\| = 2.0$, satisfaciendo exactamente las tres condiciones del Teorema de Solución Exacta.

[a] Se refiere a la aplicación del método de Newton unidimensional sobre la función transformada $\phi(\lambda) = \frac{1}{\|p(\lambda)\|} - \frac{1}{\Delta_k} = 0$. Moré y Sorensen (1983) demostraron que $\phi(\lambda)$ es casi lineal en $(\max\{0, -\lambda_1\}, \infty)$, a diferencia de $\|p(\lambda)\| - \Delta_k$, evitando oscilaciones y garantizando convergencia cuasi-cuadrática rápida. La regla de actualización de Newton resulta: $\lambda^{(l+1)} = \lambda^{(l)} + \left(\frac{\|p(\lambda^{(l)})\|}{\Delta_k} - 1\right) \frac{\|p(\lambda^{(l)})\|^2}{p(\lambda^{(l)})^T (B_k + \lambda^{(l)} I)^{-1} p(\lambda^{(l)})}$. Evaluando entre $\lambda = 2$ y $\lambda = 2.22$, el cambio de signo de $\phi(\lambda)$ confirma la existencia de la raíz, convergiendo a $\lambda^* \approx 2.083$.

3.1. Familia de Pasos Regularizados

Antes de introducir los métodos aproximados para resolver el subproblema de región de confianza, consideremos la familia de pasos regularizados

$$p(\lambda) = -(B_k + \lambda I)^{-1} g_k,$$

definida para los valores de $\lambda \geq 0$ para los cuales $B_k + \lambda I$ es invertible. Esta familia permite estudiar cómo la regularización de la matriz de curvatura modifica el paso de Newton.

Definición 3.1: Familia de Pasos Regularizados

Sea $B_k \in \mathbb{R}^{n\times n}$ una matriz simétrica y $g_k \in \mathbb{R}^n$. Definimos

$$\mathcal{D}_k = \{\lambda \geq 0 : B_k + \lambda I \text{ es invertible}\}.$$

Para cada $\lambda \in \mathcal{D}_k$, el paso regularizado $p(\lambda)$ se define como

$$p(\lambda) = -(B_k + \lambda I)^{-1} g_k. \tag{7}$$

Equivalentemente, $p(\lambda)$ satisface

$$(B_k + \lambda I)p(\lambda) = -g_k.$$

Proposición 3.1: Propiedades de la Familia Regularizada

Sea B_k simétrica y supongamos $g_k \neq 0$. En todo intervalo donde $B_k + \lambda I \succ 0$, se cumplen las siguientes propiedades:

1. **Continuidad y diferenciabilidad.** La función $\lambda \mapsto p(\lambda)$ es continuamente diferenciable y
$$p'(\lambda) = -(B_k + \lambda I)^{-1} p(\lambda).$$

2. **Decrecimiento estricto de la norma.** La función $\lambda \mapsto \|p(\lambda)\|$ es estrictamente decreciente. En efecto,
$$\frac{d}{d\lambda}\|p(\lambda)\|^2 = -2p(\lambda)^T (B_k + \lambda I)^{-1} p(\lambda) < 0.$$

3. **Comportamiento asintótico.** Cuando $\lambda \to +\infty$,
$$p(\lambda) \to 0, \qquad \|p(\lambda)\| \to 0.$$

4. **Relación con el paso de Newton.** Si $B_k \succ 0$, entonces
$$p(0) = -B_k^{-1} g_k = p_k^N,$$
donde p_k^N es el paso de Newton.

Demostración. La diferenciabilidad se deduce de la expresión (7). Derivando la identidad

$$(B_k + \lambda I)p(\lambda) = -g_k$$

respecto de λ, obtenemos

$$p(\lambda) + (B_k + \lambda I)p'(\lambda) = 0,$$

y, por tanto,

$$p'(\lambda) = -(B_k + \lambda I)^{-1} p(\lambda).$$

En consecuencia,

$$\begin{aligned}\frac{d}{d\lambda}\|p(\lambda)\|^2 &= 2p(\lambda)^T p'(\lambda) \\ &= -2p(\lambda)^T (B_k + \lambda I)^{-1} p(\lambda) < 0,\end{aligned}$$

puesto que $(B_k + \lambda I)^{-1} \succ 0$ y $p(\lambda) \neq 0$. Esto demuestra el decrecimiento estricto de la norma.

Finalmente, para λ suficientemente grande,

$$(B_k + \lambda I)^{-1} = \frac{1}{\lambda}\left(I + \frac{1}{\lambda}B_k\right)^{-1},$$

de donde se obtiene

$$p(\lambda) = -(B_k + \lambda I)^{-1} g_k \to 0$$

cuando $\lambda \to +\infty$. La última propiedad se deduce directamente de la definición del paso de Newton. □

Observación: Relación con la región de confianza

Si $B_k \succ 0$ y $\|p_k^N\| > \Delta_k$, la continuidad y el decrecimiento estricto de $\|p(\lambda)\|$ garantizan que existe un único $\lambda^* > 0$ tal que

$$\|p(\lambda^*)\| = \Delta_k.$$

Este parámetro permite obtener la solución exacta del subproblema de región de confianza en el caso considerado.
Si, en cambio, $\|p_k^N\| \leq \Delta_k$, el paso de Newton ya es factible y la solución exacta es p_k^N, con $\lambda^* = 0$.
Cuando B_k es indefinida, la familia debe estudiarse en el intervalo donde $B_k + \lambda I \succ 0$, es decir, para $\lambda > \max\{0, -\lambda_{\min}(B_k)\}$(*). **El caso límite** puede requerir un tratamiento adicional si la matriz es singular(*).

(*)El Caso Indefinido y el Caso Límite (Hard Case)

Cuando la matriz Hessiana (o su aproximación) B_k es indefinida, la función cuadrática no está acotada inferiormente en $\mathbb{R}^n$, por lo que el paso de Newton $p_k^N = -B_k^{-1} g_k$ no existe o corresponde a un punto de silla o máximo local. Para resolver el subproblema de región de confianza en esta situación, debemos analizar la familia de pasos regularizados $p(\lambda) = -(B_k + \lambda I)^{-1} g_k$ en el dominio adecuado.

1. Caracterización Espectral de la Familia Regularizada

Sea $B_k \in \mathbb{R}^{n\times n}$ una matriz simétrica con descomposición espectral

$$B_k = Q\Lambda Q^T = \sum_{i=1}^{n} \lambda_i q_i q_i^T,$$

donde $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$ son los autovalores ordenados de B_k, y $\{q_1, \ldots, q_n\}$ es una base ortonormal de autovectores.

Para cualquier $\lambda > -\lambda_1$, la matriz $(B_k + \lambda I)$ es estrictamente definida positiva ($(B_k + \lambda I) \succ 0$). Expresando el gradiente en la base de autovectores como $g_k = \sum_{i=1}^n \gamma_i q_i$, donde $\gamma_i = q_i^T g_k$, el paso regularizado adopta la representación espectral:

$$p(\lambda) = -(B_k + \lambda I)^{-1} g_k = -\sum_{i=1}^{n} \frac{\gamma_i}{\lambda_i + \lambda} q_i.$$

La norma al cuadrado del paso regularizado viene dada explícitamente por:

$$\psi(\lambda) := \|p(\lambda)\|^2 = \sum_{i=1}^{n} \frac{\gamma_i^2}{(\lambda_i + \lambda)^2}. \tag{8}$$

Dado que $\lambda_1 < 0$ (debido a la indefinición de B_k), se debe garantizar la condición de curvatura $B_k + \lambda I \succeq 0$, lo que impone la cota inferior $\lambda \geq -\lambda_1 > 0$. Analizamos dos escenarios fundamentalmente distintos según la componente del gradiente en el autodespacio asociado al autovalor mínimo λ_1.

2. Caso Fácil (*Easy Case*): $\gamma_i \neq 0$ para algún $i \in \mathcal{E}_1$

Definamos el conjunto de índices del autovalor mínimo como $\mathcal{E}_1 = \{i \in \{1, \ldots, n\} : \lambda_i = \lambda_1\}$.

Si existe algún $i \in \mathcal{E}_1$ tal que $\gamma_i = q_i^T g_k \neq 0$ (es decir, el gradiente g_k no es ortogonal al autodespacio asociado a λ_1), entonces:

$$\lim_{\lambda \to (-\lambda_1)^+} \psi(\lambda) = \lim_{\lambda \to (-\lambda_1)^+} \sum_{i=1}^{n} \frac{\gamma_i^2}{(\lambda_i + \lambda)^2} = +\infty.$$

Como $\psi(\lambda)$ es una función continua y estrictamente decreciente en el intervalo $(-\lambda_1, +\infty)$, con $\lim_{\lambda \to \infty} \psi(\lambda) = 0$, el **Teorema del Valor Intermedio** garantiza que para cualquier radio $\Delta_k > 0$, existe un **único** multiplicador $\lambda^* \in (-\lambda_1, +\infty)$ tal que:

$$\|p(\lambda^*)\| = \sqrt{\psi(\lambda^*)} = \Delta_k.$$

En este caso, la matriz $B_k + \lambda^* I \succ 0$ es estrictamente definida positiva y el paso óptimo es simplemente $p^* = p(\lambda^*) = -(B_k + \lambda^* I)^{-1} g_k$.

3. Caso Difícil (*Hard Case*): $q_i^T g_k = 0$ para todo $i \in \mathcal{E}_1$

El caso límite o **caso difícil** se presenta cuando el gradiente g_k es exactamente ortogonal al autodespacio correspondiente al autovalor mínimo λ_1, es decir:

$$\gamma_i = q_i^T g_k = 0 \quad \forall i \in \mathcal{E}_1.$$

Bajo esta condición, los términos asociados a λ_1 en la suma (8) se anulan, por lo que el límite de la norma cuando $\lambda \to -\lambda_1$ permanece **finito**:

$$\lim_{\lambda \to (-\lambda_1)^+} \|p(\lambda)\|^2 = \sum_{i \notin \mathcal{E}_1} \frac{\gamma_i^2}{(\lambda_i - \lambda_1)^2} =: \psi(-\lambda_1).$$

Surgen entonces dos subcasos según el tamaño del radio de confianza Δ_k:

a) **Si $\psi(-\lambda_1) \geq \Delta_k^2$:** Existe un único $\lambda^* \geq -\lambda_1$ tal que $\|p(\lambda^*)\| = \Delta_k$. La solución se obtiene de manera habitual dentro del intervalo $[-\lambda_1, \infty)$.

b) **Si $\psi(-\lambda_1) < \Delta_k^2$:** Puesto que la norma del paso regularizado puro $p(-\lambda_1)$ no alcanza la frontera de la bola ($\|p(-\lambda_1)\| < \Delta_k$), el paso $p(-\lambda_1)$ por sí solo no satisface la condición del teorema exacto ya que no satisface la condición de complementaridad:

$$-\lambda_1(\|p(-\lambda_1)\| - \Delta_k) = 0.$$

Para construir la solución óptima p^*, elegimos $\lambda^* = -\lambda_1$ y sumamos al paso regularizado una componente en la dirección de un autovector unitario $z \in \mathrm{Ker}(B_k - \lambda_1 I)$ con $\|z\| = 1$:

$$p^* = p(-\lambda_1) + \tau z = -\sum_{i \notin \mathcal{E}_1} \frac{\gamma_i}{\lambda_i - \lambda_1} q_i + \tau z. \tag{9}$$

Dado que $z \perp q_i$ para todo $i \notin \mathcal{E}_1$, la norma al cuadrado se descompone como:

$$\|p^*\|^2 = \|p(-\lambda_1)\|^2 + \tau^2 \|z\|^2 = \psi(-\lambda_1) + \tau^2.$$

Para forzar a que el paso se ubique exactamente en la frontera $\|p^*\| = \Delta_k$, determinamos el escalar τ como:

$$\tau = \sqrt{\Delta_k^2 - \psi(-\lambda_1)}. \tag{10}$$

Proposición 3.2: Verificación de Optimalidad en el *Hard Case*

El paso p^* construido en (9)–(10) satisface exactamente las tres condiciones necesarias y suficientes del Teorema 3.1:

1. **Estacionariedad:** Como $(B_k - \lambda_1 I)z = 0$ (por ser z autovector con autovalor λ_1), tenemos:

$$\begin{aligned}(B_k + \lambda^* I)p^* &= (B_k - \lambda_1 I)(p(-\lambda_1) + \tau z) \\ &= (B_k - \lambda_1 I)p(-\lambda_1) + \tau(B_k - \lambda_1 I)z \\ &= -g_k + 0 = -g_k.\end{aligned}$$

2. **Holgura Complementaria y Factibilidad:** Por construcción, $\|p^*\| = \Delta_k$, por lo que $\lambda^*(\|p^*\| - \Delta_k) = (-\lambda_1)(0) = 0$.

3. **Semidefinida Positiva:** $B_k + \lambda^* I = B_k - \lambda_1 I \succeq 0$, ya que todos sus autovalores son $\lambda_i - \lambda_1 \geq 0$.

4. Métodos Aproximados para la Resolución del Subproblema

La resolución exacta del subproblema de región de confianza (2) exige encontrar el multiplicador escalar $\lambda^* \geq 0$ tal que $\|p(\lambda^*)\| = \Delta_k$. Aunque esto es conceptualmente claro, su implementación en problemas de optimización de gran escala ($n \gg 10^3$) presenta limitaciones computacionales severas:

a. **Costo Algebraico Reagrupado por Iteración Escalar:** La determinación de λ^* mediante el método de Newton unidimensional sobre la función secular $\phi(\lambda) = \frac{1}{\|p(\lambda)\|} - \frac{1}{\Delta_k}$ requiere resolver el sistema lineal $(B_k + \lambda^{(l)} I)p^{(l)} = -g_k$ en cada subiteración l. En ausencia de estructura rala o aprovechable, cada prueba de $\lambda^{(l)}$ implica una factorización de Cholesky $O(n^3)$ operaciones de punto flotante (FLOPs), lo cual resulta excesivo cuando n crece.

b. **Factorizaciones Repetidas y Acceso a la Hessiana:** A diferencia de los métodos de búsqueda lineal donde la Hessiana (o su sistema lineal) se factoriza una sola vez por iteración externa k, la búsqueda exacta de λ^* modifica la diagonal de la matriz $(B_k + \lambda I)$, invalidando cualquier factorización previa (LL^T o LDL^T) y forzando a refactorizar desde cero en cada subiteración interna.

c. **Evaluación Impráctica del Caso Difícil (*Hard Case*):** Identificar numéricamente si nos encontramos en el *Hard Case* exige computar con extrema precisión el autovalor mínimo $\lambda_1 = \lambda_{\text{mín}}(B_k)$ y verificar la ortogonalidad estricta $q_1^T g_k = 0$. El cálculo explícito del espectro completo o del autodespacio dominante requiere métodos iterativos de autovalores (como Lanczos o Arnoldi) de alto costo adicional.

Por estas razones, la práctica numérica moderna prescinde de la solución exacta en favor de **métodos aproximados eficientes**. Estas técnicamente reducen el costo a un puñado de productos matriz-vector $B_k v$ (vía Krylov o poligonales como Dogleg) requiriendo únicamente satisfacer la *cota de reducción suficiente de Cauchy*, lo que preserva intacta la garantía de convergencia global a un costo computacional drásticamente inferior.

4.1. El Punto de Cauchy

El **Punto de Cauchy** p_k^C es la solución del subproblema de región de confianza restringido al rayo unidimensional generado por la dirección del gradiente descendente $-g_k$.

Definición 4.1: Punto de Cauchy

El paso de Cauchy p_k^C se define como $p_k^C = -\tau_k \frac{\Delta_k}{\|g_k\|} g_k$, donde el escalar $\tau_k > 0$ resuelve:

$$\tau_k = \arg\min_{\tau>0} m_k\left(-\tau \frac{\Delta_k}{\|g_k\|} g_k\right) \quad \text{s.a.} \quad \tau \leq 1. \tag{11}$$

La expresión explícita para p_k^C es:

$$p_k^C = -\alpha_k^C g_k, \quad \text{donde} \quad \alpha_k^C = \begin{cases} \frac{\|g_k\|^2}{g_k^T B_k g_k} & \text{si } g_k^T B_k g_k > 0 \text{ y } \frac{\|g_k\|^3}{g_k^T B_k g_k} \leq \Delta_k, \\ \frac{\Delta_k}{\|g_k\|} & \text{en otro caso.} \end{cases} \tag{12}$$

En efecto, Partimos de

$$p = -\alpha g_k, \qquad \alpha \geq 0.$$

Como p debe satisfacer $\|p\| \leq \Delta_k$,

$$\alpha \|g_k\| \leq \Delta_k \implies 0 \leq \alpha \leq \frac{\Delta_k}{\|g_k\|}.$$

Al sustituir $p = -\alpha g_k$ en

$$m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p,$$

obtenemos

$$\phi_k(\alpha) := m_k(-\alpha g_k) = f_k - \alpha \|g_k\|^2 + \frac{1}{2}\alpha^2 g_k^T B_k g_k.$$

Por tanto, debemos minimizar ϕ_k en $0 \leq \alpha \leq \frac{\Delta_k}{\|g_k\|}$. La derivada es

$$\phi_k'(\alpha) = -\|g_k\|^2 + \alpha g_k^T B_k g_k.$$

Si $g_k^T B_k g_k > 0$, el punto estacionario es

$$\alpha = \frac{\|g_k\|^2}{g_k^T B_k g_k}.$$

Este punto es admisible si

$$\frac{\|g_k\|^2}{g_k^T B_k g_k} \leq \frac{\Delta_k}{\|g_k\|}, \quad \text{equivalentemente,} \quad \frac{\|g_k\|^3}{g_k^T B_k g_k} \leq \Delta_k.$$

En caso contrario, el mínimo se encuentra en la frontera:

$$\alpha = \frac{\Delta_k}{\|g_k\|}.$$

Si $g_k^T B_k g_k \leq 0$, la función ϕ_k es decreciente para $\alpha \geq 0$, por lo que nuevamente el mínimo está en la frontera.

Así obtenemos

$$\boxed{\alpha_k^C = \begin{cases} \frac{\|g_k\|^2}{g_k^T B_k g_k}, & g_k^T B_k g_k > 0, \quad \frac{\|g_k\|^3}{g_k^T B_k g_k} \leq \Delta_k, \\ \frac{\Delta_k}{\|g_k\|}, & \text{en otro caso,} \end{cases}}$$

y finalmente

$$p_k^C = -\alpha_k^C g_k.$$

Proposición 4.1: Reducción del Modelo en el Punto de Cauchy

Para cualquier radio $\Delta_k > 0$, el punto de Cauchy p_k^C satisface la cota de reducción:

$$m_k(0) - m_k(p_k^C) \geq \frac{1}{2}\|g_k\| \min\left(\Delta_k, \frac{\|g_k\|}{\|B_k\|}\right). \tag{13}$$

Demostración. Analicemos la función escalar $g(\alpha) = m_k(-\alpha g_k) = f(x_k) - \alpha\|g_k\|^2 + \frac{1}{2}\alpha^2 g_k^T B_k g_k$ sujeta a $0 \leq \alpha \leq \frac{\Delta_k}{\|g_k\|}$.

Caso 1: Si $g_k^T B_k g_k \leq 0$, $g(\alpha)$ es una función cóncava o lineal decreciente. El mínimo en el intervalo se alcanza en el extremo $\alpha = \frac{\Delta_k}{\|g_k\|}$. Luego:

$$m_k(0) - m_k(p_k^C) = \Delta_k\|g_k\| - \frac{1}{2}\frac{\Delta_k^2}{\|g_k\|^2} g_k^T B_k g_k \geq \Delta_k\|g_k\| \geq \frac{1}{2}\|g_k\|\Delta_k.$$

Caso 2: Si $g_k^T B_k g_k > 0$, el mínimo no restringido de la parábola es $\alpha^* = \frac{\|g_k\|^2}{g_k^T B_k g_k}$.

- Subcaso 2a: Si $\alpha^* \leq \frac{\Delta_k}{\|g_k\|}$, se toma $\alpha_k^C = \alpha^*$. La reducción es:

$$m_k(0) - m_k(p_k^C) = \frac{\|g_k\|^4}{g_k^T B_k g_k} - \frac{1}{2}\frac{\|g_k\|^4}{g_k^T B_k g_k} = \frac{1}{2}\frac{\|g_k\|^4}{g_k^T B_k g_k} \geq \frac{1}{2}\frac{\|g_k\|^2}{\|B_k\|},$$

  donde se usó la desigualdad de Cauchy-Schwarz $g_k^T B_k g_k \leq \|B_k\|\|g_k\|^2$.

- Subcaso 2b: Si $\alpha^* > \frac{\Delta_k}{\|g_k\|}$, el mínimo restringido se alcanza en $\alpha_k^C = \frac{\Delta_k}{\|g_k\|}$. Dado que $g(\alpha)$ es monótona decreciente en $[0, \alpha^*]$, para toda $\alpha \leq \alpha^*$ la pendiente en origen $-g'(0) = \|g_k\|^2$ domina, garantizando:

$$m_k(0) - m_k(p_k^C) \geq \frac{1}{2}\|g_k\|\Delta_k.$$

Combinando ambos casos se obtiene la desigualdad deseada (13). □

Ejemplo de Aplicación: Sector Agricultura – Optimización del Riego y Fertilización

En la gestión de un sistema de agricultura de precisión para un cultivo de exportación, se optimizan los niveles de nitrógeno x_1 y agua x_2. La función de pérdida de rendimiento es evaluada con $g_k = (3,4)^T$ y $B_k = \begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix}$, con un radio de confianza de insumos $\Delta_k = 0.5$.

Tenemos $\|g_k\| = \sqrt{3^2+4^2} = 5$. Evaluamos $g_k^T B_k g_k = (3,4)\begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix}\begin{pmatrix} 3 \\ 4 \end{pmatrix} = 5(9+16) = 125 > 0$. El paso no restringido en la dirección del gradiente tiene longitud:

$$\alpha^* = \frac{\|g_k\|^2}{g_k^T B_k g_k} = \frac{25}{125} = 0.2.$$

El paso correspondiente es $\|-\alpha^* g_k\| = 0.2 \times 5 = 1.0$. Como $1.0 > \Delta_k = 0.5$, el punto de Cauchy debe ser truncado en la frontera de la región de confianza:

$$\alpha_k^C = \frac{\Delta_k}{\|g_k\|} = \frac{0.5}{5} = 0.1.$$

El punto de Cauchy es $p_k^C = -0.1(3,4)^T = (-0.3,-0.4)^T$, con $\|p_k^C\| = 0.5$.

4.2. El Método Dogleg

El **Método Dogleg** (pata de perro) introducido por Powell se aplica cuando la matriz Hessiana B_k es **definida positiva**. Construye una trayectoria lineal a trozos que conecta el origen 0 con el punto de Cauchy no restringido p_k^C y este a su vez con el paso de Newton completo p_k^N.

Definición 4.2: Trayectoria y Paso Dogleg

Sean $B_k \succ 0$, $p_k^N = -B_k^{-1} g_k$ el paso de Newton y $p_k^C = -\frac{g_k^T g_k}{g_k^T B_k g_k} g_k$ el mínimo del modelo a lo largo de la dirección del gradiente.

1. La **trayectoria Dogleg** $\tilde{p}(\tau)$ para $\tau \in [0,2]$ se parametriza como:

$$\tilde{p}(\tau) = \begin{cases} \tau p_k^C & \text{si } 0 \le \tau \le 1, \\ p_k^C + (\tau - 1)(p_k^N - p_k^C) & \text{si } 1 \le \tau \le 2. \end{cases} \tag{14}$$

2. El **paso Dogleg** p_k^{DL} se define como $p_k^{DL} = \tilde{p}(\tau^*)$, donde el parámetro $\tau^* \in [0,2]$ está dado explícitamente por:

$$\tau^* = \max\{\tau \in [0,2] : \|\tilde{p}(\tau)\| \le \Delta_k\}. \tag{15}$$

Es decir:

- Si $\|p_k^N\| \le \Delta_k$, se toma $\tau^* = 2$ y el paso es el de Newton completo: $p_k^{DL} = p_k^N$.
- Si $\|p_k^N\| > \Delta_k$, el paso $p_k^{DL} = \tilde{p}(\tau^*)$ se ubica exactamente sobre la frontera de la región de confianza, es decir, $\|\tilde{p}(\tau^*)\| = \Delta_k$.

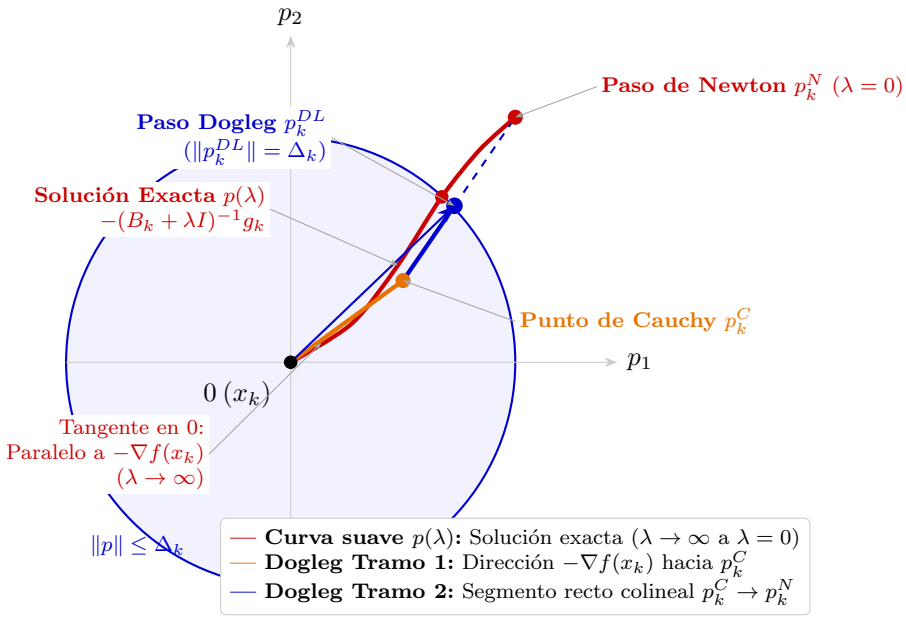


Figura 3: Geometría del Método Dogleg y separación visual clara frente a la curva suave de la solución exacta $p(\lambda)$.

Lema 4.1: Propiedades Fundamentales de la Trayectoria Dogleg

Si $B_k \succ 0$, la trayectoria Dogleg $\tilde{p}(\tau)$ satisface:

1. La distancia al origen $\|\tilde{p}(\tau)\|$ es una función estrictamente creciente de τ.
2. El modelo cuadrático $m_k(\tilde{p}(\tau))$ es una función estrictamente decreciente de τ.

Demostración. Demostremos ambas propiedades:

1. **Crecimiento de la norma:** Para $\tau \in [0,1]$, $\|\tilde{p}(\tau)\| = \tau \|p_k^C\|$, el cual es trivialmente creciente. Para $\tau \in [1,2]$, definamos $h(\tau) = \|p_k^C + (\tau - 1)(p_k^N - p_k^C)\|^2$. Se demuestra que $p_k^{CT}(p_k^N - p_k^C) \geq 0$ pues $B_k \succ 0$, lo que implica que $h'(\tau) > 0$ para todo $\tau \in [1,2]$.

2. **Decrecimiento del modelo:** Para $\tau \in [0,1]$, $\tilde{p}(\tau)$ recorre el rayo del gradiente descendente hasta su mínimo global en $\tau = 1$, por lo que m_k decrece estrictamente. Para $\tau \in [1,2]$, la derivada del modelo a lo largo de la línea de p_k^C a p_k^N satisface $\frac{d}{d\tau} m_k(\tilde{p}(\tau)) < 0$ debido a la convexidad estricta de m_k y la posición del minimizador global p_k^N. □

Observación

El paso Dogleg p_k^{DL} se elige como la intersección de la trayectoria $\tilde{p}(\tau)$ con la frontera de la región de confianza $\|\tilde{p}(\tau)\| = \Delta_k$, lo cual requiere resolver una ecuación cuadrática escalar de fácil cálculo.

Ejemplo de Aplicación: Paso Dogleg Completo

Considere $g_k = (2,2)^T$ y $B_k = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$ con $\Delta_k = 0.5$.

- Paso de Newton: $p_k^N = -B_k^{-1} g_k = -\begin{pmatrix} 1/2 & 0 \\ 0 & 1/8 \end{pmatrix}\begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} -1 \\ -0.25 \end{pmatrix}$. Norma: $\|p_k^N\| = \sqrt{1 + 0.0625} \approx 1.03 > \Delta_k$.
- Punto de Cauchy sin restr.: $g_k^T g_k = 8$, $g_k^T B_k g_k = 2(4) + 8(4) = 40$. $p_k^C = -\frac{8}{40}\begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} -0.4 \\ -0.4 \end{pmatrix}$. Norma: $\|p_k^C\| = \sqrt{0.32} \approx 0.565 > \Delta_k$.

Dado que $\|p_k^C\| > \Delta_k$, el paso Dogleg se interseca en el primer tramo ($\tau \in [0,1]$):

$$p_k^{DL} = \frac{\Delta_k}{\|p_k^C\|} p_k^C = \frac{0.5}{0.565}\begin{pmatrix} -0.4 \\ -0.4 \end{pmatrix} \approx \begin{pmatrix} -0.353 \\ -0.353 \end{pmatrix}.$$

Teorema 4.1: Conexión Dogleg – Reducción de Cauchy

El paso p_k^{DL} obtenido mediante el Método Dogleg satisface siempre la cota de reducción suficiente de Cauchy (13):

$$m_k(0) - m_k(p_k^{DL}) \geq m_k(0) - m_k(p_k^C) \geq \frac{1}{2}\|g_k\| \min\left(\Delta_k, \frac{\|g_k\|}{\|B_k\|}\right). \tag{16}$$

Por consiguiente, el Método Dogleg garantiza la **Convergencia Global** establecida en el Teorema 5.1, enunciado más abajo.

Demostración. Distinguimos los dos casos posibles para la intersección de la trayectoria con la frontera de la región de confianza:

- **Caso 1 ($\|p_k^C\| \geq \Delta_k$):** El paso Dogleg se trunca en el primer segmento ($\tau^* \in (0,1]$) con norma $\|\tilde{p}(\tau^*)\| = \Delta_k$. En este caso, $p_k^{DL} = -\frac{\Delta_k}{\|g_k\|} g_k$, lo cual coincide exactamente con el Paso de Cauchy p_k^C en la frontera. Por lo tanto, $m_k(0) - m_k(p_k^{DL}) = m_k(0) - m_k(p_k^C)$.
- **Caso 2 ($\|p_k^C\| < \Delta_k$):** El primer segmento de la trayectoria está totalmente contenido dentro de la región de confianza ($\tau = 1$). Dado que $\tau^* \geq 1$ y por la Monotonía Estricta del Modelo (Lema 4.1, Parte 2), se cumple:
$$m_k(p_k^{DL}) \leq m_k(p_k^C),$$
lo cual implica $m_k(0) - m_k(p_k^{DL}) \geq m_k(0) - m_k(p_k^C)$.

En ambos casos, el paso Dogleg satisface la cota de la Proposición 4.1, cumpliendo de manera estricta las hipótesis del Teorema 5.1 para garantizar $\lim_{k\to\infty} \|\nabla f(x_k)\| = 0$. □

Observación: Importancia Práctica de Dogleg

El resultado del Teorema 4.1 es de fundamental importancia práctica: demuestra que no es necesario resolver la ecuación no lineal del subproblema exacto mediante λ^* (Teorema 3.1) para asegurar convergencia global. El Método Dogleg ofrece una interpolación eficiente entre el paso de descenso gradiente (cauchy) y el paso de Newton completo p_k^N, manteniendo las mismas garantías teóricas de convergencia a un costo computacional drásticamente menor.

5. Teoremas de Convergencia Global

A continuación, establecemos la convergencia global del algoritmo de región de confianza hacia puntos estacionarios.

Teorema 5.1: Convergencia Global de Región de Confianza

Sea $f : \mathbb{R}^n \to \mathbb{R}$ de clase C^2 acotada inferiormente en el conjunto de nivel $\mathcal{S} = \{x \in \mathbb{R}^n : f(x) \leq f(x_0)\}$. Supongamos que la matriz de curvatura B_k permanece acotada en norma, i.e., existe $M > 0$ tal que $\|B_k\| \leq M$ para todo k. Si los pasos p_k satisfacen la condición de reducción de Cauchy (13) en cada iteración, entonces:

$$\lim_{k\to\infty} \|\nabla f(x_k)\| = 0. \tag{17}$$

Demostración. Demostración estructurada en tres pasos principales:

Paso 1: Acotación de la diferencia entre reducción real y predicha. Por el desarrollo de Taylor de primer orden con resto integral para $f(x_k + p_k)$:

$$f(x_k + p_k) = f(x_k) + g_k^T p_k + \int_0^1 (1-t) p_k^T \nabla^2 f(x_k + t p_k) p_k \, dt.$$

La reducción predicha por el modelo es $m_k(0) - m_k(p_k) = -g_k^T p_k - \frac{1}{2} p_k^T B_k p_k$. Restando ambos términos:

$$|(f(x_k) - f(x_k + p_k)) - (m_k(0) - m_k(p_k))| = \left| \frac{1}{2} p_k^T B_k p_k - \int_0^1 (1-t) p_k^T \nabla^2 f(x_k + t p_k) p_k \, dt \right|.$$

Dado que $\nabla^2 f$ es continua en el conjunto compacto de nivel y $\|B_k\| \leq M$, existe $L > 0$ tal que:

$$|(f(x_k) - f(x_k + p_k)) - (m_k(0) - m_k(p_k))| \leq L\|p_k\|^2 \leq L\Delta_k^2. \tag{18}$$

Paso 2: Acotación inferior del radio de confianza si no hay convergencia. Supongamos por contradicción que $\|\nabla f(x_k)\|$ no converge a cero. Entonces existen $\epsilon > 0$ e índices infinitos donde $\|g_k\| \geq \epsilon$. Sustituyendo $\|g_k\| \geq \epsilon$ en la cota de Cauchy (13):

$$m_k(0) - m_k(p_k) \geq \frac{1}{2} \epsilon \, \text{mín} \left(\Delta_k, \frac{\epsilon}{M} \right).$$

Evaluemos la razón ρ_k:

$$|\rho_k - 1| = \frac{|(f(x_k) - f(x_k + p_k)) - (m_k(0) - m_k(p_k))|}{m_k(0) - m_k(p_k)} \leq \frac{L\Delta_k^2}{\frac{1}{2}\epsilon \, \text{mín} \left(\Delta_k, \frac{\epsilon}{M} \right)}.$$

Si $\Delta_k \leq \frac{\epsilon \eta_1}{2L}$ (donde $\eta_1 < 1/4$), la fracción anterior es menor que $1 - \eta_1$, lo que garantiza que $\rho_k \geq \eta_1$. Por las reglas de actualización, el paso es aceptado y el radio Δ_k no se reduce. Esto implica que existe un radio mínimo uniforme $\bar{\Delta} > 0$ tal que $\Delta_k \geq \bar{\Delta}$ para todo k.

Paso 3: Contradicción por decrementos finitos. Para las iteraciones donde el paso es aceptado ($\rho_k \geq \eta_1$):

$$f(x_k) - f(x_{k+1}) \geq \eta_1 (m_k(0) - m_k(p_k)) \geq \frac{1}{2} \eta_1 \epsilon \, \text{mín} \left(\bar{\Delta}, \frac{\epsilon}{M} \right) = \gamma > 0.$$

Sumando esta cota fija sobre infinitos pasos aceptados:

$$f(x_0) - f(x_k) = \sum_{j=0}^{k-1} (f(x_j) - f(x_{j+1})) \geq N_{\text{aceptados}} \cdot \gamma \to \infty,$$

lo que contradice el hecho de que f está acotada inferiormente. Por lo tanto, $\lim_{k\to\infty} \|\nabla f(x_k)\| = 0$. □

6. Comparación: Región de Confianza vs. Búsqueda Lineal

Ambas estrategias buscan globalizar los métodos de optimización local[1], pero difieren fundamentalmente en su enfoque operativo y matemático.

Característica	**Búsqueda Lineal (*Line Search*)**	**Región de Confianza (*Trust Region*)**
Orden de elección	Primero elige dirección p_k, luego paso α_k.	Primero fija radio Δ_k, luego resuelve paso p_k.
Manejo de $B_k \not\succ 0$	Requiere modificar $B_k \leftarrow B_k + E_k$ para forzar descenso.	Acepta B_k indefinidas de forma natural.
Aprovechamiento de curvatura	Ignora direcciones de curvatura negativa directas.	Explotación explícita de direcciones de curvatura negativa.
Costo por iteración	Bajo (evaluaciones de f en la línea).	Medio/Alto (resolución de subproblemas n-dimensionales).
Robustez en problemas severos	Puede estancarse si las direcciones son malas.	Altamente robusto cerca de puntos de silla.

Tabla 1: Comparación estructural entre Búsqueda Lineal y Región de Confianza.

[1] En optimización continua, «globalizar» un método local no significa garantizar la convergencia al mínimo global absoluto de una función no convexa arbitraria, sino asegurar la convergencia global a un punto estacionario ($\lim_{k\to\infty} \|\nabla f(x_k)\| = 0$) independientemente del punto inicial x_0 elegido.

7. Ejercicios Resueltos

Ejemplo de Aplicación: Ejercicio Resuelto 1: Subproblema Bidimensional Exacto

Enunciado: Resuelva el subproblema de región de confianza para $g = (-2, -4)^T$ y $B = \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}$ con $\Delta = 1$.

Solución: 1. Calculamos el paso de Newton no restringido $p^N = -B^{-1}g$:

$$p^N = -\begin{pmatrix} 1/4 & 0 \\ 0 & 1/2 \end{pmatrix}\begin{pmatrix} -2 \\ -4 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 2.0 \end{pmatrix}.$$

2. Verificamos su norma: $\|p^N\| = \sqrt{(0.5)^2 + 2^2} = \sqrt{4.25} \approx 2.062 > 1 = \Delta$.
3. Dado que $\|p^N\| > \Delta$, la solución yace en la frontera $\|p(\lambda)\| = 1$ con $\lambda > 0$.
4. Expresamos $p(\lambda) = -(B + \lambda I)^{-1}g$:

$$p_1(\lambda) = \frac{2}{4+\lambda}, \quad p_2(\lambda) = \frac{4}{2+\lambda}.$$

5. Planteamos $\|p(\lambda)\|^2 = 1$:

$$\frac{4}{(4+\lambda)^2} + \frac{16}{(2+\lambda)^2} = 1.$$

Probando $\lambda = 2$: $\frac{4}{36} + \frac{16}{16} = \frac{1}{9} + 1 = 1.11 > 1$. Probando $\lambda = 2.27$: $\frac{4}{(6.27)^2} + \frac{16}{(4.27)^2} \approx \frac{4}{39.31} + \frac{16}{18.23} \approx 0.101 + 0.877 = 0.978$. Interpolando se obtiene $\lambda^* \approx 2.21$. El paso óptimo es $p^* = \left(\frac{2}{6.21}, \frac{4}{4.21}\right)^T \approx (0.322, 0.950)^T$, con $\|p^*\| = \sqrt{0.322^2 + 0.950^2} = 1.0$.

Ejemplo de Aplicación: Ejercicio Resuelto 2: Cálculo del Punto de Cauchy

Enunciado: Sea $g = (3, -4)^T$ y $B = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. Determine el punto de Cauchy p^C para $\Delta = 0.5$.

Solución: 1. Normas y productos: $\|g\| = \sqrt{9 + 16} = 5$.

$$g^T B g = (3, -4)\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}\begin{pmatrix} 3 \\ -4 \end{pmatrix} = (3, -4)\begin{pmatrix} 2 \\ -5 \end{pmatrix} = 6 + 20 = 26 > 0.$$

2. Longitud de paso no restringido en el rayo del gradiente:

$$\alpha^* = \frac{\|g\|^2}{g^T B g} = \frac{25}{26} \approx 0.9615.$$

El paso no restringido correspondiente tiene norma $\|\alpha^* g\| = 0.9615 \times 5 = 4.807$.
3. Como $4.807 > \Delta = 0.5$, el paso debe ser truncado por la región de confianza:

$$\alpha^C = \frac{\Delta}{\|g\|} = \frac{0.5}{5} = 0.1.$$

4. El paso de Cauchy resulta: $p^C = -\alpha^C g = -0.1(3, -4)^T = (-0.3, 0.4)^T$.

Ejemplo de Aplicación: Ejercicio Resuelto 3: Construcción del Paso Dogleg

Enunciado: Para $g = (1, 2)^T$ y $B = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$, calcule el paso Dogleg con $\Delta = 1.5$.

Solución: 1. Calculamos $p^N = -B^{-1}g = (-1/3, -2)^T$. Norma: $\|p^N\| = \sqrt{1/9 + 4} = \sqrt{37/9} \approx 2.027 > 1.5$.
2. Calculamos p^C: $\|g\|^2 = 5$, $g^T Bg = 1(3)(1) + 2(1)(2) = 7$.

$$p^C = -\frac{5}{7}\begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} -5/7 \\ -10/7 \end{pmatrix} \approx \begin{pmatrix} -0.714 \\ -1.428 \end{pmatrix}.$$

Norma: $\|p^C\| = \frac{5}{7}\sqrt{5} \approx 1.595 > 1.5$.
3. Como $\|p^C\| > \Delta$, el paso cae en el primer segmento de Dogleg:

$$p^{DL} = \frac{\Delta}{\|p^C\|}p^C = \frac{1.5}{1.595}\begin{pmatrix} -0.714 \\ -1.428 \end{pmatrix} \approx \begin{pmatrix} -0.671 \\ -1.343 \end{pmatrix}.$$

Ejemplo de Aplicación: Ejercicio Resuelto 4: Evaluación de la Razón ρ_k y Aceptación del Paso

Enunciado: Sea $f(x_k) = 100$, $x_k = (0, 0)^T$, $g_k = (-2, 0)^T$, $B_k = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$. Se propone el paso $p_k = (1, 0)^T$ con radio $\Delta_k = 1$. Si $f(x_k + p_k) = 98.8$, evalúe ρ_k y determine si el paso se acepta con $\eta_1 = 0.1$.
Solución: 1. Reducción predicha:

$$m_k(0) - m_k(p_k) = -g_k^T p_k - \frac{1}{2}p_k^T B_k p_k = -(-2)(1) - \frac{1}{2}(1)(2)(1) = 2 - 1 = 1.0.$$

2. Reducción real:

$$f(x_k) - f(x_k + p_k) = 100 - 98.8 = 1.2.$$

3. Razón ρ_k:

$$\rho_k = \frac{1.2}{1.0} = 1.2.$$

4. Como $\rho_k = 1.2 > \eta_1 = 0.1$, el paso **se acepta** ($x_{k+1} = (1, 0)^T$). Además, como $\rho_k > 0.75$ y $\|p_k\| = 1 = \Delta_k$, el radio para la siguiente iteración se duplica: $\Delta_{k+1} = 2$.

Ejemplo de Aplicación: Ejercicio Resuelto 5: Matriz Indefinida en el Sector Agricultura

Enunciado: Un modelo de rendimiento agrícola presenta $g_k = (0, -3)^T$ y $B_k = \begin{pmatrix} -4 & 0 \\ 0 & 2 \end{pmatrix}$ en x_k, con radio $\Delta_k = 1$. Obtenga el paso exacto que resuelve el subproblema.
Solución: 1. B_k tiene autovalores $\lambda_1 = -4$ y $\lambda_2 = 2$. Es indefinida.
2. Requerimos $\lambda^* \geq -\lambda_1 = 4$ para que $B_k + \lambda^* I \succeq 0$.
3. Para $\lambda > 4$:

$$p(\lambda) = -(B_k + \lambda I)^{-1} g_k \implies p_1(\lambda) = 0, \quad p_2(\lambda) = \frac{3}{2+\lambda}.$$

4. Exigimos $\|p(\lambda)\| = 1 \implies \frac{3}{2+\lambda} = 1 \implies 2 + \lambda = 3 \implies \lambda^* = 1$.
5. Sin embargo, $\lambda^* = 1 < 4$, lo que violaría $B_k + \lambda^* I \succeq 0$. Por ende, λ^* debe tomar el valor crítico $\lambda^* = 4$.
6. Para $\lambda^* = 4$, la matriz modificada es $B_k + 4I = \begin{pmatrix} 0 & 0 \\ 0 & 6 \end{pmatrix} \succeq 0$. El sistema $(B_k + 4I)p = -g_k$ da $0 \cdot p_1 = 0$ y $6p_2 = 3 \implies p_2 = 0.5$.
7. Para satisfacer $\|p\| = 1$, elegimos la componente p_1 en el espacio nulo de $B_k + 4I$:

$$p_1^2 + (0.5)^2 = 1 \implies p_1^2 = 0.75 \implies p_1 = \pm\frac{\sqrt{3}}{2} \approx \pm 0.866.$$

Cualquiera de los dos pasos $p^* = (\pm 0.866, 0.5)^T$ minimiza globalmente el subproblema.

8. Ejercicios Propuestos

Ejercicio Propuesto (1 – Fundamentos Teóricos)

Demuestre de forma detallada que si $B_k \succ 0$ y $\|B_k^{-1} g_k\| \leq \Delta_k$, entonces el paso de Newton $p_k^N = -B_k^{-1} g_k$ es la única solución global del subproblema de región de confianza (2).

Ejercicio Propuesto (2 – Propiedades de Monotonía de Dogleg)

Demuestre formalmente que la funcíon $h(\tau) = \|\tilde{p}(\tau)\|^2$ es strictly creciente en el intervalo $\tau \in [1, 2]$ para la trayectoria Dogleg definida en (14).

Ejercicio Propuesto (3 – Subproblema de Región de Confianza en Norma ℓ_∞)

Considere el subproblema de región de confianza formulado con la norma del supremo:

$$\min_{p \in \mathbb{R}^n} g_k^T p + \frac{1}{2} p^T B_k p \quad \text{s.a.} \quad \|p\|_\infty \leq \Delta_k.$$

Si B_k es una matriz diagonal con entradas positivas $d_i > 0$, obtenga la expresión analítica exacta para el paso óptimo p^*.

Ejercicio Propuesto (4 – Cálculo Explícito del Punto de Cauchy)

Sea $f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ (función de Rosenbrock). En el punto $x_0 = (-1.2, 1.0)^T$, calcule el gradiente g_0, la Hessiana B_0 y halle de forma explícita el paso de Cauchy p_0^C para $\Delta_0 = 0.25$.

Ejercicio Propuesto (5 – Construcción del Paso Dogleg)

Para el mismo punto de la función de Rosenbrock del ejercicio anterior, verifique si la Hessiana es definida positiva y construya el paso Dogleg completo p_0^{DL} para $\Delta_0 = 0.25$.

Ejercicio Propuesto (6 – Aplicación en el Sector Transporte)

Un modelo de ruteo de flotas urbanas presenta un costo $f(x)$ con gradiente $g_k = (5, -12)^T$ y matriz Hessiana $B_k = \begin{pmatrix} 6 & 2 \\ 2 & 3 \end{pmatrix}$. Si el radio de región de confianza es $\Delta_k = 1.0$, determine la solución exacta del subproblema mediante el método del multiplicador λ^*.

Ejercicio Propuesto (7 – Aplicación en el Sector Energético)

En el control de voltaje de una microred, el subproblema de optimización local presenta curvatura negativa con $g_k = (1, 1)^T$ y $B_k = \begin{pmatrix} -2 & 0 \\ 0 & 4 \end{pmatrix}$. Determine el paso óptimo exacto para $\Delta_k = 0.8$.

Ejercicio Propuesto (8 – Actualización del Radio de Confianza)

Suponga que en una iteración x_k se tiene $f(x_k) = 25.0$, $m_k(0) - m_k(p_k) = 4.0$, y se observa $f(x_k + p_k) = 21.8$. Si los parámetros del algoritmo son $\eta_1 = 0.1, \eta_2 = 0.75$, determine si el paso se acepta y calcule el nuevo radio Δ_{k+1} para $\Delta_k = 0.5$ (asuma $\|p_k\| = 0.5$).

Ejercicio Propuesto (9 – Convergencia con Pasos Inexactos)

Demuestre que el Teorema de Convergencia Global 5.1 se sigue cumpliendo si el paso p_k no es la solución exacta del subproblema, siempre que se cumpla la condición de reducción suficiente de Cauchy:

$$m_k(0) - m_k(p_k) \geq c_1(m_k(0) - m_k(p_k^C))$$

para una constante fija $c_1 \in (0, 1]$.

Ejercicio Propuesto (10 – Método de Gran Escala (Subespacio de Krylov))

Explique formalmente cómo el método de Gradiente Conjugado Truncado (Steihaug-CG)[a] resuelve aproximadamente el subproblema de región de confianza en grandes dimensiones sin calcular explícitamente la inversa de B_k, y analice en qué condición el algoritmo termina interrumpiendo la iteración por curvatura negativa.

[a] Será estudiado en el próximo capítulo.

Referencias

[1] Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer, New York, 2nd edition, 2006.

[2] Andrew R. Conn, Nicholas I. M. Gould, and Philippe L. Toint. *Trust Region Methods*. MPS-SIAM Series on Optimization. SIAM, Philadelphia, 2000.

[3] Roger Fletcher. *Practical Methods of Optimization*. John Wiley & Sons, Chichester, 2nd edition, 1987.