IMCA

Maestría en Modelización Matemática y Computacional

Curso: Optimización
Profesores: E. Oré & E. Ocaña

Semana 7: Gradiente Conjugado Lineal

1. Introducción y Motivación

En la resolución de problemas de optimización cuadrática a gran escala o en la resolución de sistemas lineales simétricos definidos positivos de alta dimensión n (del orden de 10^4 a 10^8 variables):

$$Ax = b, \qquad A \in \mathbb{R}^{n\times n}, \quad A = A^T \succ 0,$$

los métodos directos tradicionales como la factorización de Cholesky ($O(n^3)$ operaciones) o los métodos iterativos de primer orden como el Descenso por el Gradiente resultan ineficientes o poco práctico debido al costo computacional y al almacenamiento de matrices densas.

El método del **Gradiente Conjugado Lineal (CG)**, introducido originalmente por Hestenes y Stiefel (1952), constituye uno de los algoritmos iterativos más potentes para resolver sistemas $Ax = b$. Su propiedad fundamental radica en generar una secuencia de direcciones de búsqueda ortogonales respecto a la matriz A (A-conjugadas), garantizando la convergencia a la solución exacta en a lo sumo n iteraciones en aritmética exacta.

2. Gradiente Conjugado Lineal

Consideremos el problema de minimización cuadrática estrictamente convexo equivalente:

$$\min_{x\in\mathbb{R}^n} \phi(x) = \frac{1}{2}x^T Ax - b^T x,$$

donde $A \in \mathbb{R}^{n\times n}$ es una matriz simétrica y definida positiva ($A \succ 0$). La condición de primer orden $\nabla\phi(x) = Ax - b = 0$ es equivalente a resolver el sistema lineal $Ax = b$.

Definición 2.1: Direcciones A-Conjugadas

Un conjunto de vectores no nulos $\{p_0, p_1, \ldots, p_k\} \subset \mathbb{R}^n$ se dice que es **A-conjugado** (o **ortogonal respecto a** A) si satisface:

$$p_i^T A p_j = 0, \quad \forall\, i \neq j. \tag{1}$$

Interpretación Gráfica

Geométricamente, la conjugación deforma la métrica del espacio de modo que las curvas de nivel elípticas de la función cuadrática se transforman circularmente. En lugar de oscilar en un "callejón" como en el descenso por el gradiente, la optimización a lo largo de direcciones A-conjugadas garantiza alcanzar el mínimo exacto en a lo sumo n pasos.

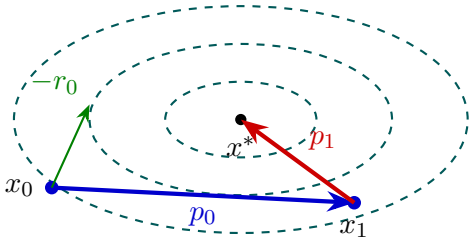


Figura 1: Generación de direcciones A-conjugadas p_0 y p_1 en $\mathbb{R}^2$. El mínimo exacto x^* se alcanza en exactamente 2 pasos.

2.1. El Método General de Direcciones Conjugadas

Dado un punto inicial arbitrario $x_0 \in \mathbb{R}^n$ y suponiendo conocido un conjunto de n direcciones no nulas y A-conjugadas $\{p_0, p_1, \ldots, p_{n-1}\}$, estas forman una base ortogonal de $\mathbb{R}^n$ respecto al producto interno inducido por A.

Sea x^* la solución única de $Ax = b$. El vector desplazamiento $x^* - x_0$ se expresa de forma única como combinación lineal de dicha base:

$$x^* = x_0 + \sum_{i=0}^{n-1} \alpha_i p_i \quad \Longleftrightarrow \quad x^* - x_0 = \sum_{i=0}^{n-1} \alpha_i p_i. \tag{2}$$

Generamos la secuencia de puntos iterativos mediante la recurrencia $x_{k+1} = x_k + \alpha_k p_k$, con lo cual:

$$x_k = x_0 + \sum_{i=0}^{k-1} \alpha_i p_i, \qquad \text{para } k = 1, \ldots, n.$$

Cálculo Analítico del Tamaño de Paso Exacto α_k

Dado el punto actual x_k y una dirección p_k, el coeficiente α_k se determina resolviendo el subproblema de optimización unidimensional:

$$\min_{\alpha \in \mathbb{R}} \phi(x_k + \alpha p_k) = \frac{1}{2}(x_k + \alpha p_k)^T A(x_k + \alpha p_k) - b^T(x_k + \alpha p_k).$$

Definiendo $h(\alpha) = \phi(x_k + \alpha p_k)$, calculamos su derivada e igualamos a cero:

$$h'(\alpha) = p_k^T A(x_k + \alpha p_k) - b^T p_k = p_k^T(Ax_k - b) + \alpha p_k^T A p_k = 0.$$

Denotando al residuo como $r_k := Ax_k - b = \nabla\phi(x_k)$, despejamos:

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}. \tag{3}$$

Teorema 2.1: Convergencia del Método General

Si $\{p_0, p_1, \ldots, p_{n-1}\}$ es un conjunto de direcciones A-conjugadas, la secuencia $x_{k+1} = x_k + \alpha_k p_k$ satisface $x_n = x^*$, alcanzando la solución exacta en a lo sumo n iteraciones.

Demostración. Multiplicando la ecuación (2) por $p_k^T A$ y aplicando la A-conjugación ($p_k^T A p_i = 0, \forall i \neq k$):

$$p_k^T A(x^* - x_0) = \sum_{i=0}^{n-1} \alpha_i p_k^T A p_i = \alpha_k p_k^T A p_k.$$

Como $Ax^* = b$, se cumple que $p_k^T A(x^* - x_0) = p_k^T(b - Ax_0) = -p_k^T r_0$. Puesto que $x_k = x_0 + \sum_{i=0}^{k-1} \alpha_i p_i$, multiplicando por A y restando b se tiene $r_k = r_0 + \sum_{i=0}^{k-1} \alpha_i A p_i$. Multiplicando por p_k^T por la izquierda y aplicando la A-conjugación $p_k^T A p_i = 0$ para $i < k$, deducimos que $p_k^T r_k = p_k^T r_0$, de donde:

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k},$$

lo que coincide con el minimizador exacto (3). Al cabo de n pasos se completa la base de direcciones y por lo tanto $x_n = x^*$. □

Observación: Limitación del Método General

Este esquema requiere conocer o precalcular previamente las n direcciones A-conjugadas $\{p_k\}$. Construirlas mediante un algoritmo de tipo Gram-Schmidt exigiría almacenar n vectores de dimensión n y un elevado costo en productos matriz-vector, lo cual resulta ineficiente a gran escala.

2.2. El Algoritmo de Gradiente Conjugado Lineal

Para superar las limitaciones del método general, buscamos generar cada dirección de búsqueda p_k **iterativamente sobre la marcha**.

Motivación y Construcción Iterativa de las Direcciones p_k

Partimos fijando la primera dirección en la de máximo descenso desde x_0:

$$p_0 = -r_0.$$

En el paso $k \geq 1$, no deseamos realizar una ortogonalización completa contra todo el historial $\{p_0, \ldots, p_{k-1}\}$. En su lugar, proponemos construir la nueva dirección p_k combinando la dirección de máximo descenso actual $-r_k$ con la dirección inmediatamente anterior p_{k-1}:

$$p_k = -r_k + \beta_k p_{k-1}. \tag{4}$$

Lema 2.1: Ortogonalidad del Residuo a la Dirección de Búsqueda Actual

Para todo $k \geq 0$, la elección del paso exacto α_k garantiza que el nuevo residuo $r_{k+1} = Ax_{k+1} - b$ es ortogonal a la dirección p_k:

$$r_{k+1}^T p_k = 0. \tag{5}$$

Demostración. Por definición, $\alpha_k = \arg\min_{\alpha \in \mathbb{R}} \phi(x_k + \alpha p_k)$. La condición necesaria de primer orden exige que:

$$\frac{d}{d\alpha}\phi(x_k + \alpha p_k)\Big|_{\alpha=\alpha_k} = \nabla\phi(x_{k+1})^T p_k = 0 \implies r_{k+1}^T p_k = 0.$$

□

Lema 2.2: Ortogonalidad del Residuo a Direcciones y Residuos Anteriores

En cada iteración $k \geq 1$ del algoritmo de Gradiente Conjugado Lineal, el residuo $r_k = Ax_k - b$ satisface simultáneamente:

$$r_k^T p_i = 0 \quad \text{y} \quad r_k^T r_i = 0, \quad \forall\, i = 0, 1, \ldots, k-1.$$

Demostración. Demostramos por inducción sobre $k \geq 1$ la validez simultánea de las siguientes tres proposiciones:

(I) $\mathcal{P}(k) : r_k^T p_i = 0, \quad \forall\, i = 0, \ldots, k-1,$

(II) $\mathcal{Q}(k) : r_k^T r_i = 0, \quad \forall\, i = 0, \ldots, k-1,$

(III) $\mathcal{S}(k) : \text{span}\{p_0, \ldots, p_{k-1}\} = \text{span}\{r_0, \ldots, r_{k-1}\}.$

Caso Base ($k = 1$):

- Por la condición de primer orden de la optimización unidimensional exacto sobre la dirección p_0, $x_1 = x_0 + \alpha_0 p_0$ satisface $\nabla\phi(x_1)^T p_0 = 0 \implies r_1^T p_0 = 0$, lo que prueba $\mathcal{P}(1)$.
- Puesto que $p_0 = -r_0$, sustituyendo se tiene $r_1^T(-r_0) = 0 \implies r_1^T r_0 = 0$, demostrando $\mathcal{Q}(1)$.
- Por definición de la primera dirección, $\text{span}\{p_0\} = \text{span}\{-r_0\} = \text{span}\{r_0\}$, lo que establece $\mathcal{S}(1)$.

Paso Inductivo: Asumamos como hipótesis de inducción que $\mathcal{P}(j)$, $\mathcal{Q}(j)$ y $\mathcal{S}(j)$ son ciertas para todo $j \leq k$. Queremos demostrar que $\mathcal{P}(k+1)$, $\mathcal{Q}(k+1)$ y $\mathcal{S}(k+1)$ se verifican.

1. Demostración de $\mathcal{P}(k+1)$ ($r_{k+1}^T p_i = 0$ para todo $i \leq k$): Premultiplicando la actualización del residuo $r_{k+1} = r_k + \alpha_k A p_k$ por p_i^T, obtenemos:

$$p_i^T r_{k+1} = p_i^T r_k + \alpha_k p_i^T A p_k. \tag{6}$$

Analizamos los casos para el índice $i \leq k$:

- **Si $i = k$:** La minimización exacta sobre la dirección p_k exige que $\frac{d}{d\alpha}\phi(x_k + \alpha p_k)\big|_{\alpha=\alpha_k} = \nabla\phi(x_{k+1})^T p_k = 0 \implies r_{k+1}^T p_k = 0$.
- **Si $i < k$:** Por la hipótesis inductiva $\mathcal{P}(k)$, el primer término es nulo: $p_i^T r_k = 0$.

  Distinguimos dos subcasos para $i < k$:

  1. **Subcaso $i < k-1$:** Puesto que $i < k-1 \implies i+1 \leq k-1 < k$, los subíndices i e $i+1$ son estrictamente menores que k.
     Evaluamos primeramente el término $r_k^T A p_i$ sustituyendo $Ap_i = \frac{r_{i+1} - r_i}{\alpha_i}$:

     $$r_k^T A p_i = \frac{r_k^T r_{i+1} - r_k^T r_i}{\alpha_i} = \frac{0 - 0}{\alpha_i} = 0.$$

     Para evaluar la proyección de la dirección p_k, expresamos $p_k = -r_k + \beta_k p_{k-1}$ y premultiplicamos por $p_i^T A$:

     $$p_k^T A p_i = -r_k^T A p_i + \beta_k (p_{k-1}^T A p_i).$$

     Por la hipótesis inductiva de A-conjugación entre las direcciones previas $\{p_0, \ldots, p_{k-1}\}$, puesto que $i < k-1$, se tiene $p_{k-1}^T A p_i = p_i^T(\frac{r_k - r_{k-1}}{\alpha_{k-1}}) = 0$. Sustituyendo ambos resultados, concluimos que:

     $$p_k^T A p_i = -0 + \beta_k(0) = 0, \quad \forall\, i < k-1.$$

2. **Subcaso $i = k-1$:** Evaluando $p_k^T A p_{k-1}$ con $Ap_{k-1} = \frac{r_k - r_{k-1}}{\alpha_{k-1}}$:

$$p_k^T A p_{k-1} = (-r_k + \beta_k p_{k-1})^T A p_{k-1}.$$

Por $\mathcal{Q}(k)$, $r_k^T r_{k-1} = 0 \implies -r_k^T A p_{k-1} = -\frac{\|r_k\|^2}{\alpha_{k-1}}$. Sustituyendo las expresiones exactas $\beta_k = \frac{\|r_k\|^2}{\|r_{k-1}\|^2}$ y $\alpha_{k-1} = \frac{\|r_{k-1}\|^2}{p_{k-1}^T A p_{k-1}}$, el otro término (el segundo) resulta:

$$\beta_k p_{k-1}^T A p_{k-1} = \frac{\|r_k\|^2}{\|r_{k-1}\|^2}\left(\frac{\|r_{k-1}\|^2}{\alpha_{k-1}}\right) = \frac{\|r_k\|^2}{\alpha_{k-1}}.$$

Por ende, $p_k^T A p_{k-1} = -\frac{\|r_k\|^2}{\alpha_{k-1}} + \frac{\|r_k\|^2}{\alpha_{k-1}} = 0$.

Sustituyendo en (6), concluimos que $r_{k+1}^T p_i = 0$ para todo $i < k$.

Esto demuestra la validez de $\mathcal{P}(k+1)$.

Determinemos las expresiones de α_{k-1} y β_k:

1. **Cálculo de α_{k-1}:** De la minimización exacta $p_{k-1}^T r_k = 0$ aplicada a $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$, y sabiendo que $p_{k-1}^T r_{k-1} = -\|r_{k-1}\|^2$, despejamos directamente:

$$\alpha_{k-1} = \frac{\|r_{k-1}\|^2}{p_{k-1}^T A p_{k-1}}.$$

2. **Cálculo de β_k:** Imponiendo la A-conjugación $p_k^T A p_{k-1} = 0$ sobre la dirección $p_k = -r_k + \beta_k p_{k-1}$, se obtiene $\beta_k = \frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}$. Sustituyendo $Ap_{k-1} = \frac{r_k - r_{k-1}}{\alpha_{k-1}}$ y aplicando la ortogonalidad de residuos $r_k^T r_{k-1} = 0$, el numerador se convierte en $\frac{\|r_k\|^2}{\alpha_{k-1}}$.

Sustituyendo $\alpha_{k-1}(p_{k-1}^T A p_{k-1}) = \|r_{k-1}\|^2$ en el denominador, se concluye la definición exacta del escalar de Fletcher-Reeves:

$$\beta_k = \frac{\|r_k\|^2}{\|r_{k-1}\|^2}.$$

2. Demostración de $\mathcal{Q}(k+1)$ ($r_{k+1}^T r_i = 0$ para todo $i \le k$): Despejando $r_i = -p_i + \beta_i p_{i-1}$ (donde $p_{-1} = 0$), evaluamos el producto escalar:

$$r_{k+1}^T r_i = r_{k+1}^T(-p_i + \beta_i p_{i-1}) = -r_{k+1}^T p_i + \beta_i r_{k+1}^T p_{i-1}.$$

Puesto que por $\mathcal{P}(k+1)$ ya sabemos que $r_{k+1}^T p_m = 0$ para todo $m \le k$, ambos términos son estrictamente nulos ($0 + 0 = 0$), probando $\mathcal{Q}(k+1)$.

3. Demostración de $\mathcal{S}(k+1)$: Por la regla de definición de la dirección $p_k = -r_k + \beta_k p_{k-1}$, tenemos que $p_k \in \text{span}\{r_0, \ldots, r_k, p_{k-1}\}$. Aplicando la hipótesis inductiva $\mathcal{S}(k)$, sabemos que $p_{k-1} \in \text{span}\{r_0, \ldots, r_{k-1}\}$, lo cual extiende la equivalencia de subespacios:

$$\text{span}\{p_0, \ldots, p_k\} = \text{span}\{r_0, \ldots, r_k\}.$$

Esto demuestra $\mathcal{S}(k+1)$ y completa el paso inductivo. □

Lema 2.3: Propiedad de A-Conjugación Inicial

En el algoritmo de Gradiente Conjugado Lineal, la primera dirección $p_0 = -r_0$ y la segunda dirección $p_1 = -r_1 + \beta_1 p_0$ con $\beta_1 = \frac{r_1^T r_1}{r_0^T r_0}$ satisfacen directamente la propiedad de A-conjugación:

$$p_0^T A p_1 = 0.$$

Demostración. Por construcción $p_1 = -r_1 + \beta_1 p_0$, de donde

$$p_0^T A p_1 = -p_0^T A r_1 + \beta_1 p_0^T A p_0.$$

De la regla de actualización del residuo $r_1 = r_0 + \alpha_0 A p_0$, despejamos el producto $Ap_0 = \frac{r_1 - r_0}{\alpha_0}$. Sustituyendo en el numerador:

$$r_1^T A p_0 = r_1^T \left(\frac{r_1 - r_0}{\alpha_0} \right) = \frac{r_1^T r_1 - r_1^T r_0}{\alpha_0}.$$

Igualmente,

$$r_0^T A p_0 = r_0^T \left(\frac{r_1 - r_0}{\alpha_0} \right) = \frac{r_0^T r_1 - r_0^T r_0}{\alpha_0}.$$

Por el lema anterior resulta

$$r_1^T A p_0 = \frac{r_1^T r_1}{\alpha_0} \quad \text{y} \quad r_0^T A p_0 = \frac{r_0^T r_0}{\alpha_0}.$$

Se deduce por lo tanto que $p_0^T A p_1 = 0$. □

Teorema 2.2: Demostración de la A-Conjugación Global de $\{p_k\}$

La secuencia de direcciones $\{p_0, p_1, \ldots, p_k\}$ construidas mediante la regla $p_k = -r_k + \beta_k p_{k-1}$ con el escalar $\beta_k = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}$ satisface la propiedad de A-conjugación global:

$$p_i^T A p_k = 0, \quad \forall\, i \neq k.$$

Demostración. Demostramos por inducción sobre k.

Caso Base ($k = 1$): Se deduce del Lema 2.3.

Paso Inductivo: Asumamos como hipótesis de inducción que $\{p_0, p_1, \ldots, p_{k-1}\}$ son A-conjugadas entre sí. Queremos probar que $p_i^T A p_k = 0$ para todo $i < k$.

- Para $i = k - 1$: $p_{k-1}^T A p_k = 0$ se demuestra siguiendo la misma idea del Lema 2.3.

- Para $i < k - 1$: Multiplicamos la ecuación de la dirección ($p_k = -r_k + \beta_k p_{k-1}$) por $p_i^T A$ por la izquierda:

$$p_i^T A p_k = -p_i^T A r_k + \beta_k p_i^T A p_{k-1}.$$

Por hipótesis inductiva, $p_i^T A p_{k-1} = 0$ para $i < k - 1$. Por otro lado, desglosando $Ap_i = \frac{r_{i+1} - r_i}{\alpha_i}$, evaluamos:

$$p_i^T A r_k = r_k^T A p_i = \frac{r_k^T r_{i+1} - r_k^T r_i}{\alpha_i}.$$

Dado que $i < k - 1 \implies i + 1 < k$, los residuos r_{i+1} y r_i son ortogonales a r_k (Lema 2.2).

Por lo tanto, $p_i^T A p_k = 0$ para todo $i < k$, completando la demostración. □

Algoritmo: Gradiente Conjugado Lineal

1. Dado un punto inicial $x_0 \in \mathbb{R}^n$, calcular $r_0 = Ax_0 - b$ y fijar la dirección inicial $p_0 = -r_0$.
2. Para $k = 0, 1, 2, \ldots$ hasta convergencia:

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = r_k + \alpha_k A p_k$$

$$\beta_{k+1} = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$$

$$p_{k+1} = -r_{k+1} + \beta_{k+1} p_k$$

2.3. Subespacios de Krylov y Propiedades de Convergencia

Teorema 2.3: Propiedad del Subespacio de Krylov

Sea $\{x_k\}$ la secuencia generada por el algoritmo de Gradiente Conjugado Lineal comenzando en x_0. El residuo $r_k = Ax_k - b = \nabla\phi(x_k)$ y la dirección p_k satisfacen:

1. $r_k^T r_i = 0$ para todo $i < k$.
2. $\text{span}\{r_0, r_1, \ldots, r_{k-1}\} = \text{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\} = \mathcal{K}_k(A, r_0)$.
3. x_k minimiza la función $\phi(x)$ en la variedad afín $x_0 + \mathcal{K}_k(A, r_0)$.

Demostración. Demostramos cada ítem haciendo uso de los resultados establecidos anteriormente:

Demostración del Ítem 1: Demostrada en el Lema 2.2.

Demostración del Ítem 2: Probamos por inducción sobre $k \geq 1$ que $\text{span}\{r_0, \ldots, r_{k-1}\} = \mathcal{K}_k(A, r_0) = \text{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$:

- **Caso Base ($k = 1$):** Por definición del subespacio de Krylov de dimensión 1, $\mathcal{K}_1(A, r_0) = \text{span}\{r_0\}$.
- **Paso Inductivo:** Supongamos cierto para k, es decir, $\text{span}\{r_0, \ldots, r_{k-1}\} = \mathcal{K}_k(A, r_0)$. Por la proposición $\mathcal{S}(k)$ del Lema 2.2, sabemos que $\text{span}\{p_0, \ldots, p_{k-1}\} = \text{span}\{r_0, \ldots, r_{k-1}\} = \mathcal{K}_k(A, r_0)$.

  De la regla de actualización del residuo $r_k = r_{k-1} + \alpha_{k-1} A p_{k-1}$, se tiene que $r_k \in \text{span}\{r_{k-1}, Ap_{k-1}\}$. Como $p_{k-1} \in \mathcal{K}_k(A, r_0)$, se cumple que $Ap_{k-1} \in A\mathcal{K}_k(A, r_0) \subset \mathcal{K}_{k+1}(A, r_0)$. Por lo tanto, $r_k \in \mathcal{K}_{k+1}(A, r_0)$, lo cual concluye que:

$$\text{span}\{r_0, r_1, \ldots, r_k\} = \text{span}\{r_0, Ar_0, \ldots, A^k r_0\} = \mathcal{K}_{k+1}(A, r_0).$$

Demostración del Ítem 3: Cualquier punto en la variedad afín $x \in x_0 + \mathcal{K}_k(A, r_0)$ puede expresarse unívocamente como $x = x_0 + \sum_{i=0}^{k-1} \gamma_i p_i$, dado que $\{p_0, \ldots, p_{k-1}\}$ forma una base de $\mathcal{K}_k(A, r_0)$.

Definiendo la función $h(\gamma_0, \ldots, \gamma_{k-1}) = \phi\left(x_0 + \sum_{i=0}^{k-1} \gamma_i p_i\right)$, la condición de primer orden para minimizar h respecto a cada γ_j $(j = 0, \ldots, k-1)$ exige:

$$\frac{\partial h}{\partial \gamma_j} = \nabla\phi(x)^T p_j = 0 \implies (Ax - b)^T p_j = 0.$$

Para el punto generado por el algoritmo $x_k = x_0 + \sum_{i=0}^{k-1} \alpha_i p_i$, el gradiente correspondiente es el residuo r_k. Por la proposición $\mathcal{P}(k)$ del Lema 2.2, sabemos que $r_k^T p_j = 0$ para todo $j < k$. Dado que $A \succ 0$, la función $\phi(x)$ es strictly convexa, por lo que x_k es el minimizador único en $x_0 + \mathcal{K}_k(A, r_0)$. □

Teorema 2.4: Tasa de Convergencia y Cota de Error

Sea $A \succ 0$ con número de condición $\kappa(A) = \frac{\lambda_{\text{máx}}(A)}{\lambda_{\text{mín}}(A)} \geq 1$. El error de las iteraciones del Gradiente Conjugado Lineal en la norma de la energía $\|e_k\|_A = \sqrt{e_k^T A e_k}$ (donde $e_k = x_k - x^*$) satisface la cota:

$$\|x_k - x^*\|_A \leq 2\left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1}\right)^k \|x_0 - x^*\|_A. \tag{7}$$

Observación: Impacto del Número de Condición y Agrupamiento Espectral

A diferencia del Descenso por el Gradiente (cuya tasa depende de $\frac{\kappa-1}{\kappa+1}$), el Gradiente Conjugado depende de la raíz cuadrada $\sqrt{\kappa(A)}$, lo cual acelera drásticamente la convergencia en sistemas mal condicionados. Además, si la matriz A posee solo $m < n$ autovalores distintos, el algoritmo converge exactamente en a lo sumo m iteraciones.

3. Ejercicios Resueltos

Ejemplo de Aplicación: Ejercicio Resuelto 1: Gradiente Conjugado Lineal

Enunciado: Dado el sistema $Ax = b$ con:

$$A = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}, \qquad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \qquad x_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Calcule el paso x_1 y verifique la ortogonalidad del residuo r_1 respecto a r_0.

Solución:

1. **Residuo inicial:** $r_0 = Ax_0 - b = (0,0)^T - (1,2)^T = (-1,-2)^T$.
2. **Dirección inicial:** $p_0 = -r_0 = (1,2)^T$.
3. **Longitud de paso α_0:**

$$r_0^T r_0 = (-1)^2 + (-2)^2 = 5.$$

$$Ap_0 = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 6 \\ 7 \end{pmatrix} \implies p_0^T Ap_0 = (1,2) \begin{pmatrix} 6 \\ 7 \end{pmatrix} = 6 + 14 = 20.$$

$$\alpha_0 = \frac{r_0^T r_0}{p_0^T Ap_0} = \frac{5}{20} = 0.25.$$

4. **Actualización de la solución y residuo:**

$$x_1 = x_0 + \alpha_0 p_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0.25 \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0.25 \\ 0.50 \end{pmatrix}.$$

$$r_1 = r_0 + \alpha_0 Ap_0 = \begin{pmatrix} -1 \\ -2 \end{pmatrix} + 0.25 \begin{pmatrix} 6 \\ 7 \end{pmatrix} = \begin{pmatrix} 0.50 \\ -0.25 \end{pmatrix}.$$

5. **Verificación de ortogonalidad:**

$$r_0^T r_1 = (-1)(0.50) + (-2)(-0.25) = -0.50 + 0.50 = 0.$$

Ejemplo de Aplicación: Ejercicio Resuelto 2: Parámetro Fletcher-Reeves vs. Polak-Ribière

Enunciado: Suponga que en una iteración de un método no lineal se tienen los gradientes $g_{k-1} = (1, 2)^T$ y $g_k = (0.5, 1)^T$. Calcule β_k^{FR} y β_k^{PR}.

Solución:

1. **Productos escalares requeridos:**

$$g_{k-1}^T g_{k-1} = 1^2 + 2^2 = 5.$$

$$g_k^T g_k = 0.5^2 + 1^2 = 1.25.$$

$$y_{k-1} = g_k - g_{k-1} = \begin{pmatrix} 0.5 - 1 \\ 1 - 2 \end{pmatrix} = \begin{pmatrix} -0.5 \\ -1.0 \end{pmatrix}.$$

$$g_k^T y_{k-1} = (0.5)(-0.5) + (1)(-1.0) = -0.25 - 1.0 = -1.25.$$

2. **Parámetro Fletcher-Reeves:**

$$\beta_k^{FR} = \frac{g_k^T g_k}{g_{k-1}^T g_{k-1}} = \frac{1.25}{5} = 0.25.$$

3. **Parámetro Polak-Ribière:**

$$\beta_k^{PR} = \frac{g_k^T y_{k-1}}{g_{k-1}^T g_{k-1}} = \frac{-1.25}{5} = -0.25.$$

Ejemplo de Aplicación: Ejercicio Resuelto 3: Verificación de A-Conjugación

Enunciado: Determine si los vectores $p_0 = (1, 1)^T$ y $p_1 = (1, -2)^T$ son A-conjugados para $A = \begin{pmatrix} 2 & 1 \\ 1 & 1.5 \end{pmatrix}$.

Solución: Calculamos la forma cuadrática $p_0^T A p_1$:

$$Ap_1 = \begin{pmatrix} 2 & 1 \\ 1 & 1.5 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 - 2 \\ 1 - 3 \end{pmatrix} = \begin{pmatrix} 0 \\ -2 \end{pmatrix}.$$

$$p_0^T A p_1 = (1, 1) \begin{pmatrix} 0 \\ -2 \end{pmatrix} = 0 - 2 = -2 \neq 0.$$

Por lo tanto, los vectores **no son A-conjugados**.

Ejemplo de Aplicación: Ejercicio Resuelto 4: Complejidad Computacional de L-BFGS

Enunciado: Muestre formalmente que la recursión de dos ciclos de L-BFGS requiere a lo sumo $4mn + O(m)$ operaciones en coma flotante (FLOPs) por iteración.

Solución:

1. **Primer ciclo:** Para cada uno de los m pasos se realiza:
   - Producto escalar $s_i^T q$: $2n$ FLOPs.
   - Actualización del vector $q \leftarrow q - \alpha_i y_i$: $2n$ FLOPs.

   Total primer ciclo: $m \cdot 4n = 4mn$ FLOPs.
2. **Escalado intermedio:** Constante escalar por vector: n FLOPs.
3. **Segundo ciclo:** Para cada uno de los m pasos:
   - Producto escalar $y_i^T r$: $2n$ FLOPs.
   - Actualización $r \leftarrow r + s_i(\dots)$: $2n$ FLOPs.

   Total segundo ciclo: $4mn$ FLOPs.

Total global: $8mn + O(n)$ FLOPs, el cual es estrictamente lineal en la dimensión n.

Ejemplo de Aplicación: Ejercicio Resuelto 5: Aplicación en Agricultura de Precisión

Enunciado: Un modelo de optimización de nutrientes para suelos utiliza un funcional no convexo $f(x)$ con 10^5 zonas de cultivo. Si se opta por L-BFGS con memoria $m = 5$, calcule la cantidad de memoria (en megabytes) requerida para almacenar la matriz implícita usando flotantes de 64 bits.

Solución:

1. L-BFGS guarda m pares de vectores $(s_i, y_i) \in \mathbb{R}^n \times \mathbb{R}^n$.
2. Número total de escalares guardados: $2 \cdot m \cdot n = 2 \cdot 5 \cdot 10^5 = 10^6$ valores.
3. En formato de doble precisión (8 bytes por valor):

$$10^6 \times 8 \text{ bytes} = 8 \times 10^6 \text{ bytes} \approx 8.0 \text{ MB}.$$

Esto demuestra la tremenda eficiencia de memoria frente a BFGS completo (10^{10} valores ≈ 80 GB).

4. Ejercicios Propuestos

Ejercicio Propuesto (1 — Demostración Teórica de Ortogonalidad)

Demuestre formalmente por inducción que en el algoritmo de Gradiente Conjugado Lineal, los residuos satisfacen $r_i^T r_j = 0$ para todo $i \neq j$.

Ejercicio Propuesto (2 — Paso Exacto del GC Lineal)

Considere el problema de minimizar $\phi(x) = \frac{1}{2}x^T Ax - b^T x$. Demuestre que el paso óptimo α_k que minimiza $\phi(x_k + \alpha p_k)$ coincide exactamente con la expresión:

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$$

empleada en el algoritmo del Gradiente Conjugado Lineal.

Ejercicio Propuesto (3 — Convergencia en n Pasos del GC Lineal)

Demuestre que el algoritmo de Gradiente Conjugado Lineal converge a la solución exacta x^* de $Ax = b$ en a lo sumo n iteraciones (en aritmética exacta).

Ejercicio Propuesto (4 — Equivalencia de Fórmulas No Lineales)

Demuestre que las fórmulas de Fletcher-Reeves y Polak-Ribière son equivalentes a la fórmula del Gradiente Conjugado Lineal si la función objetivo $f(x)$ es una función cuadrática estrictamente convexa y la búsqueda de línea es exacta.

Ejercicio Propuesto (5 — Propiedad de Reinicio en CG)

Explique la razón teórica por la cual el algoritmo de Gradiente Conjugado No Lineal debe reiniciarse en la dirección del gradiente negativo ($p_k = -g_k$) cada n iteraciones.

Ejercicio Propuesto (6 — Implementación de L-BFGS)

Escriba en seudocódigo detallado la versión completa de L-BFGS con búsqueda de línea de Wolfe.

Ejercicio Propuesto (7 — Cota de Error mediante Polinomios de Chebyshev)

Sea $A \in \mathbb{R}^{n\times n}$ una matriz simétrica definida positiva con número de condición $\kappa = \frac{\lambda_{\text{máx}}(A)}{\lambda_{\text{mín}}(A)}$. Recordando que los polinomios de Chebyshev de primera especie $T_k(t)$ satisfacen:

I) Dentro del intervalo $[-1, 1]$ ($|t| \leq 1$):

$$T_k(t) = \cos(k \arccos(t)) \implies |T_k(t)| \leq 1.$$

II) Fuera del intervalo $[-1, 1]$ ($|t| > 1$):

$$T_k(t) = \cosh(k\text{arccosh}(t)) = \frac{1}{2}\left[(t + \sqrt{t^2-1})^k + (t - \sqrt{t^2-1})^k\right].$$

Utilice las propiedades del polinomio minimax escalado:

$$P_k^*(\lambda) = \frac{T_k\left(\frac{\kappa+1-2\lambda/\lambda_{\text{mín}}}{\kappa-1}\right)}{T_k\left(\frac{\kappa+1}{\kappa-1}\right)},$$

sabiendo que el máximo del error en el espectro satisface:

$$\max_{\lambda\in[\lambda_{\text{mín}},\lambda_{\text{máx}}]} |P_k^*(\lambda)| = \frac{1}{T_k\left(\frac{\kappa+1}{\kappa-1}\right)},$$

para demostrar que el error en la norma A del método de Gradiente Conjugado Lineal satisface la cota de convergencia:

$$\|x_k - x^*\|_A \leq 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k \|x_0 - x^*\|_A.$$

Ejercicio Propuesto (8 — Aplicación en el Sector Transporte)

Considere un problema de calibración de matriz origen-destino con $n = 50\,000$ variables. Formule el subproblema de paso de Fletcher-Reeves y calcule la primera dirección si $g_0 = (2, -1, 3, \dots)^T$.

Ejercicio Propuesto (9 — Comparación de Tasas de Convergencia)

Compare analíticamente la tasa de convergencia del método del Descenso por el Gradiente frente a Gradiente Conjugado Lineal para un problema cuadrático con número de condición $\kappa(A) = 1000$.

Ejercicio Propuesto (10 — Sensibilidad de Polak-Ribière)

Construya un contraejemplo donde $\beta_k^{PR} < 0$ e interprete geométricamente la dirección resultante.

Ejercicio Propuesto (11 — Escala Masiva en Redes de Agregación Energética)

Un problema de despacho distribuido de energía renovable de $n = 10^6$ variables se resuelve con L-BFGS. Si se dispone de un servidor con 4 GB de RAM, ¿cuál es el valor máximo del parámetro de memoria m que puede utilizarse?

Ejercicio Propuesto (12 — Propiedad de Escalado Inicial en L-BFGS)

Demuestre por qué el escalado de la matriz inicial $H_0^{(k)} = \gamma_k I$ con $\gamma_k = \frac{s_{k-1}^T y_{k-1}}{y_{k-1}^T y_{k-1}}$ asegura que la magnitud del paso sea cercana a la del método de Newton.