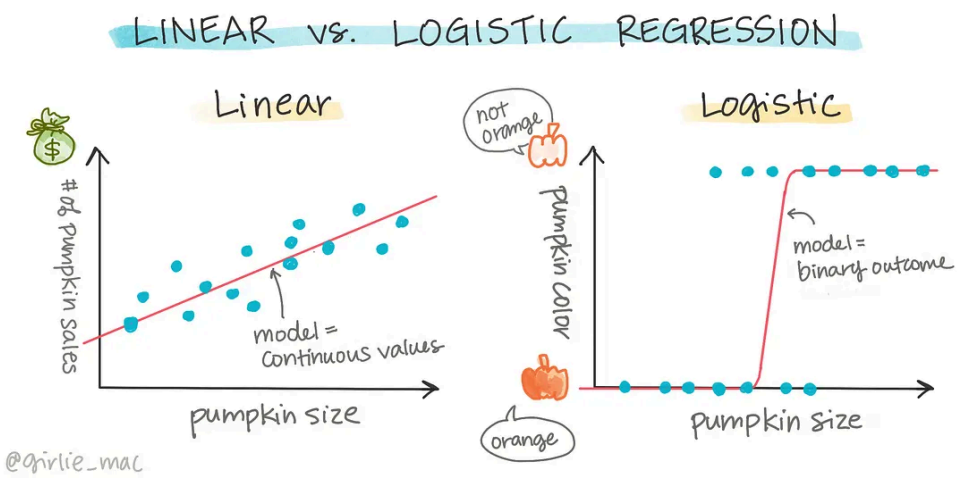
Regresión logística



Dentro del aprendizaje supervisado, la regresión logística es un modelo de clasificación binaria. Este modelo busca predecir la probabilidad de una observación de pertenecer a una clase (dentro de dos posibles).

Representamos cada observación mediante un vector de características $\mathbf{x}_i \in \mathbb{R}^d$ y una etiqueta $y_i \in \{0, 1\}$. Disponemos de un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, donde $\mathbf{x}_i = (x_{i1}, \ldots, x_{id})^T$.

Objetivo

Construir una funcion que estime

$$p(\mathbf{x}) = P(y = 1 \mid \mathbf{x}),$$

es decir, la probabilidad de que la etiqueta de $\mathbf{x}$ sea 1. La probabilidad de tener etiqueta 0 es por lo tanto $1 - p(\mathbf{x})$.

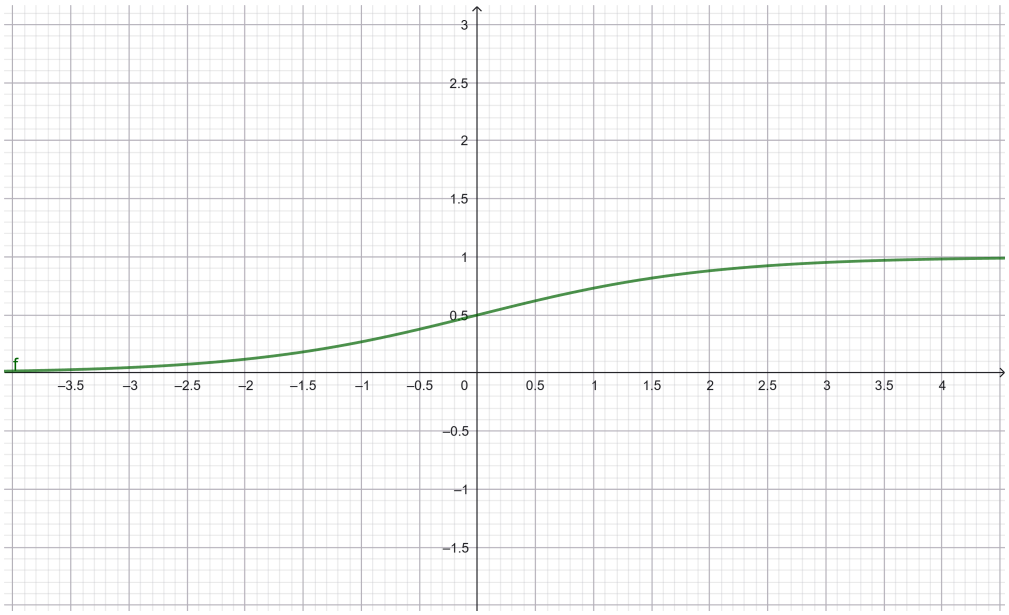
Para un vector $\mathbf{x} = (x_1, \ldots, x_d)^T$, una primera propuesta podria ser

$$p(x) \approx \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d.$$

Sin embargo, debido a que $p(\mathbf{x})$ representa una probabilidad, se debe tener $0 \leq p(\mathbf{x}) \leq 1$, lo cual es una restriccion imposible de cumplir para un modelo de regresion lineal.

Funcion logistica/sigmoide

Es la funcion $\sigma : \mathbb{R} \to \langle 0, 1 \rangle$, con $\sigma(x) = \dfrac{1}{1+e^{-x}} = \dfrac{e^x}{1+e^x}$.



La funcion σ es inyectiva, por lo cual tiene una funcion inversa. En efecto, si $y = \sigma(x) = \dfrac{1}{1+e^{-x}}$, entonces $\dfrac{1}{y} = 1 + e^{-x}$, luego $\dfrac{1}{y} - 1 = \dfrac{1-y}{y} = e^{-x}$, asi que $x = -\ln\left(\dfrac{1-y}{y}\right) = \ln\left(\dfrac{y}{1-y}\right)$. Esto nos da la funcion $logit : \langle 0, 1 \rangle \to \mathbb{R}$, con $logit(y) = \ln\left(\dfrac{y}{1-y}\right)$.

Obs: $\sigma'(x) = \sigma(x)(1-\sigma)(x)$.

De este modo, aunque $p(\mathbf{x})$ solo tome valores entre 0 y 1, $logit(p(\mathbf{x}))$ es arbitrariamente grande o pequeño (tanto positivo como negativo). Ahora, podemos aproximar $logit(p(\mathbf{x}))$ usando regresion lineal, es decir

$$logit(p(\mathbf{x})) \approx \beta_0 + \beta_1 x_1 + \ \cdots \ + \beta_d x_d$$

Ahora, como σ es la funcion inversa de $logit$, se tiene

$$p(x) = \sigma(logit(p(\mathbf{x}))) \approx \sigma(\beta_0 + \beta_1 x_1 + \ \cdots \ + \beta_d x_d) \in \langle 0, 1 \rangle$$

Ejm

Considere el modelo $p(\mathbf{x}) = \sigma(-1 + 0.8x_1 - 0.4x_2)$

a) Calcule $P(y = 0 \mid \mathbf{x} = 0)$ para $\mathbf{x} = (2, 1)^T$.
b) Si el umbral de clasificacion es 0.5, determine la clase predicha.
c) Encuentre la ecuacion de la frontera de decision.

Sol

a)
$p(y = 0 \mid \mathbf{x}) = 1 - p(\mathbf{x}) = 1 - \sigma(-1 + 0.8(2) - 0.4(1)) = 1 - \sigma(0.2) \approx 1 - 0.5498 = 0.45016.$

b) Como $p(\mathbf{x}) \approx 0.5498 > 0.5$, el modelo predice que la etiqueta de $\mathbf{x}$ es 1.

c) La frontera de decision es el conjunto de puntos $\mathbf{x} = (x_1, x_2)^T$, con $p(\mathbf{x}) = 0.5$, es decir

$$\sigma(-1 + 0.8x_1 - 0.4x_2) = 0.5,$$

entonces $-1 + 0.8x_1 - 0.4x_2 = logit(0.5) = \ln\left(\frac{0.5}{1 - 0.5}\right) = \ln(1) = 0$, entonces
$-10 + 8x_1 - 4x_2 = 0$, luego $x_2 = 2x_1 - 2.5$.

La frontera de decision es, por lo tanto, $\left\{(x_1, x_2)^T \mid x_2 = x_1 - 2.5\right\}$.

Entropia cruzada binaria

Dada una observacion $\mathbf{x}_i = (x_{i1}, \ \ldots, x_{id})^T$con etiqueta $y_i \in \{0, 1\}$ y un vector de parametros $\beta = (\beta_0, \beta_1, \ \ldots, \beta_d)^T$, denotamos

$$p_i = p_\beta(\mathbf{x}_i) = \sigma(\beta_0 + \beta_1 x_{i1} + \ \cdots \ + \beta_d x_{id})$$

El producto $p_i^{y_i}(1 - p_i)^{1 - y_i}$ resulta en:

- p_i, si $y_i = 1$

- $1 - p_i$, si $y_i = 0$

Definimos la funcion *verosimilitud*

$$L(\beta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i}$$

Maximizar esta funcion implica hallar los parametros que asignen altras probabilidades a las etiquetas ya observadas. Para dicho fin, podemos tomar el logaritmo:

$$\ln(L(\beta)) = \sum_{i=1}^{n} \ln\left(p_i^{y_i}(1 - p_i)^{1-y_i}\right) = \sum_{i=1}^{n} y_i \ln(p_i) + (1 - y_i)\ln(1 - p_i)$$

De este modo, maximizar $L(\beta)$ equivale a maximizar $\ln(L(\beta))$. Ahora, como usualmente deseamos minimizar una funcion, podemos considerar $-\ln(L(\beta))$ (verosimilitud log negativa).

Por ultimo, si promediamos la suma, esto esto no afecta al minimizador:

$$E(\beta) = \frac{1}{n}\sum_{i=1}^{n} - y_i \ln(p_i) - (1 - y_i)\ln(1 - p_i).$$

Esta funcion, la cual compara y_i con p_i, es llamada *entropia cruzada binaria (promedio) o perdida logistica promedio.*

Obs: En apariencia, otra alternativa como funcion de error/perdida pudo ser

$$M(\beta) = \frac{1}{2n}\sum_{i=1}^{n} (y_i - p_i)^2$$

Sin embargo, esta funcion no resulta ser convexa, por lo que un punto critico cualquiera podria no ser minimo global. Sin embargo, $E(\beta)$ si es convexa.

Gradiente de $E(\beta)$

$E(\beta) = \frac{1}{n}\sum_{i=1}^{n} - y_i \ln(p_i) - (1 - y_i)\ln(1 - p_i) = \frac{1}{n}\sum_{i=1}^{n} l(y_i, p_i)$, donde
$l(y_i, p_i) = - y_i \ln(p_i) - (1 - y_i)\ln(1 - p_i)$. Denotemos $z_i = \beta_0 + \beta_1 x_{i1} + \cdots \beta_d x_{id}$, de modo

que $p_i = \sigma(z_i)$. Se tiene entonces

$$\begin{aligned} l(y_i, p_i) &= l(y_i, \sigma(z_i)) \\ &= -y_i \ln(\sigma(z_i)) - (1-y_i)\ln(1-\sigma(z_i)) \\ &= -y_i \ln\left(\frac{e^{z_i}}{1+e^{z_i}}\right) - (1-y_i)\ln\left(\frac{1}{1+e^{z_i}}\right) \\ &= -y_i\left(z_i - \ln\left(1+e^{z_i}\right)\right) - (1-y_i)\left[-\ln\left(1+e^{z_i}\right)\right] \\ &= -y_i z_i + y_i \ln\left(1+e^{z_i}\right) + (1-y_i)\ln\left(1+e^{z_i}\right) \\ &= \ln\left(1+e^{z_i}\right) - y_i z_i \end{aligned}$$

Obs: $\frac{d}{dz}\ln(y_i, \sigma(z)) = \frac{d}{dz}\left[\ln\left(1+e^{z}\right) - y_i z\right] = \frac{1}{1+e^{z}}\left(e^{z}\right) - y_i = \frac{e^{z}}{1+e^{z}} - y_i = \sigma(z) - y_i.$

En particular, para $z = z_i$, se tiene $\frac{d}{dz}\left[\ln\left(1+e^{z}\right) - y_i z\right] = \sigma(z_i) - y_i = p_i - y_i.$

Ejm

Calcule $l(y, p) = -y \ln p - (1-y)\ln(1-p)$ para $p \in \{0.9, 0.6, 0.1\}$, primero con $y = 1$ y luego con $y = 0$. Organice los seis resultados en una tabla y explique como penaliza la perdida una prediccion segura, pero incorrecta.

Sol

$l(1, p) = l(0, 1-p)$

Si $y = 1$, entonces $l(1, p) = -\ln p$
Si $y = 0$, entonces $l(0, p) = -\ln(1-p)$

	$p = 0.9$	$p = 0.6$	$p = 0.1$
$y = 1$	0.1054	0.5108	2.3026
$y = 0$	2.3026	0.9163	0.1054

Ejm

Las etiquetas reales y las predicciones de dos modelos son

i	1	2	3	4	5
y_i	1	0	1	1	0
$p_i^{(A)}$	0.9	0.2	0.65	0.55	0.1
$p_i^{(B)}$	0.7	0.05	0.8	0.4	0.3

Calcule la entropia cruzada binaria promedio de cada modelo. ¿Cuál de los dos elegiría, según este criterio?

Sol

Por simplicidad, denotemos $l_i = -y_i \ln p_i - (1-y_i)\ln(1-p_i)$

Recordemos que, si $y_i = 1$, entonces $l_i = -\ln p_i$ y si $y_i = 0$, entonces $l_i = -\ln(1-p_i)$

Para el modelo A, se tiene

$$l_1^{(A)} = -\ln(0.9) = 0.1054$$
$$l_2^{(A)} = -\ln(1-0.2) = -\ln(0.8) = 0.2231$$
$$l_3^{(A)} = -\ln(0.65) = 0.4308$$
$$l_4^{(A)} = -\ln(0.55) = 0.5978$$
$$l_5^{(A)} = -\ln(1-0.1) = -\ln(0.9) = 0.1054$$

Finalmente, $E_A = \frac{1}{5}(0.1054 + 0.2231 + 0.4308 + 0.5978 + 0.1054) = 0.2025$

Similarmente, se obtiene $E_B = 0.3808$. Como $E_A < E_B$, elegimos el modelo A.

Obs: A clasifica correctamente las cinco observaciones, mientras B clasifica erroneamente la cuarta observacion.

Continuando con el gradiente de $E(\beta)$:

Consideremos los vectores $\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{bmatrix}$, $\mathbf{p} = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_n \end{bmatrix} = \begin{bmatrix} \sigma(z_1) \\ \sigma(z_2) \\ \vdots \\ \sigma(z_n) \end{bmatrix}$ y $y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$. Por la definicion de $\mathbf{z}$, se tiene $\mathbf{z} = X\beta$, donde X es la matriz de diseño usada en regresion lineal.

Por otro lado, sabemos que $E(\beta) = \frac{1}{n}\sum_{i=1}^{n} \ln\left(1 + e^{z_i}\right) - y_i z_i$, donde $z_i = \beta_0 + \beta_1 x_{i1} + \ \cdots \ + \beta_d x_{id}$.

Por la regla de la cadena, se tiene $(\nabla E(\beta))^T = Jac_\beta E(\beta) = (Jac_{\mathbf{z}}\ E(\beta))\ (Jac_\beta\ \mathbf{z})$

$$Jac_{\mathbf{z}}\left[\frac{1}{n}\sum_{i=1}^{n}\left(\ln\left(1+e^{z_i}\right) - y_i z_i\right)\right] = \left(\nabla_{\mathbf{z}}\left[\frac{1}{n}\sum_{i=1}^{n}\left(\ln\left(1+e^{z_i}\right) - y_i z_i\right)\right]\right)^T$$

$$= \frac{1}{n}\begin{bmatrix} \sigma(z_1) - y_1 \\ \sigma(z_2) - y_2 \\ \vdots \\ \sigma(z_n) - y_n \end{bmatrix}^T = \frac{1}{n}\begin{bmatrix} p_1 - y_1 \\ p_2 - y_2 \\ \vdots \\ p_n - y_n \end{bmatrix}^T = \frac{1}{n}(\mathbf{p} - \mathbf{y})^T.$$

Por otro lado, $Jac_\beta\ \mathbf{z} = Jac_\beta\ X\beta = X$. Por lo tanto, $Jac_\beta E(\beta) = \frac{1}{n}(\mathbf{p} - \mathbf{y})^T X$, finalemnte

$$\nabla E(\beta) = \left(\frac{1}{n}(\mathbf{p} - \mathbf{y})^T X\right)^T = \frac{1}{n}X^T(\mathbf{p} - \mathbf{y}).$$

Descenso del gradiente

Comenzamos con algun vector $\beta^{(0)}$ y alguna tasa de aprendizaje $\alpha > 0$. Generamos entonces la sucesion $\beta^{(k)}$ haciendo

$$\mathbf{z}^{(k-1)} = X\beta^{(k-1)}$$

$$\mathbf{p}^{(k-1)} = \begin{bmatrix} \sigma\left(z_1^{(k-1)}\right) \\ \sigma\left(z_2^{(k-1)}\right) \\ \vdots \\ \sigma\left(z_n^{(k-1)}\right) \end{bmatrix}$$

$$\beta^{(k)} = \beta^{(k-1)} - \alpha \nabla E(\beta) = \beta^{(k-1)} - \frac{\alpha}{n} X^T(\mathbf{p} - \mathbf{y})$$

Ejm

Supongamos que $X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$, $\mathbf{y} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$, $\beta^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\alpha = 1$.

$\mathbf{z}^{(0)} = X\beta^{(0)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$, $\mathbf{p}^{(0)} = \begin{bmatrix} 0.5 \\ 0.5 \\ 0.5 \end{bmatrix}$, entonces $\left(\mathbf{p}^{(0)} - \mathbf{y}\right) = \begin{bmatrix} 0.5 \\ 0.5 \\ -0.5 \end{bmatrix}$. Finalemente

$$\beta^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \frac{1}{n} \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 0.5 \\ 0.5 \\ -0.5 \end{bmatrix} = \begin{bmatrix} -1/6 \\ 1/6 \end{bmatrix}.$$