Lista de Ejercicios
MMC IMCA

Indicaciones. En todos los ejercicios use

$$\sigma(z) = \frac{1}{1+e^{-z}}, \qquad \operatorname{logit}(p) = \ln\!\left(\frac{p}{1-p}\right).$$

Cuando sea necesario, redondee los resultados numéricos a cuatro cifras decimales y muestre el procedimiento. Salvo que se indique otro valor, use un umbral de clasificación de 0.5: prediga la clase 1 si $p \geq t$ y la clase 0 si $p < t$.

Función logística y clasificación

1. Considere el modelo

$$p(\mathbf{x}) = P(y = 1 \mid \mathbf{x}) = \sigma(-0.8 + 1.2x_1 - 0.5x_2).$$

Para cada uno de los puntos $\mathbf{x}^{(1)} = (1, 2)^T$, $\mathbf{x}^{(2)} = (2, -1)^T$ y $\mathbf{x}^{(3)} = (0, 0)^T$:

   a) calcule el predictor lineal z;

   b) halle $P(y = 1 \mid \mathbf{x})$ y $P(y = 0 \mid \mathbf{x})$;

   c) determine la clase predicha.

2. Un modelo produce las probabilidades siguientes:

observación	A	B	C	D	E
p_i	0.18	0.42	0.50	0.67	0.91

Determine las clases predichas al usar los umbrales 0.3, 0.5 y 0.7. Describa qué ocurre con la cantidad de observaciones clasificadas como clase 1 cuando el umbral aumenta.

3. Sea

$$p(\mathbf{x}) = \sigma(1 - 2x_1 + 0.5x_2).$$

   a) Obtenga la ecuación de la frontera de decisión para un umbral de 0.5 y escríbala en la forma $x_2 = mx_1 + b$.

   b) Clasifique los puntos $(0, 0)^T$, $(1, 1)^T$ y $(2, 8)^T$.

   c) Dibuje la frontera e indique en qué semiplano se predice la clase 1.

4. Demuestre que, para $p(\mathbf{x}) = \sigma(\beta_0+\beta_1 x_1+\beta_2 x_2)$, la frontera correspondiente a un umbral $t \in (0,1)$ satisface

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 = \ln\left(\frac{t}{1-t}\right).$$

Después encuentre la frontera del modelo del ejercicio anterior cuando $t = 0.7$ y compárela con la frontera obtenida para $t = 0.5$.

Distribución binomial y verosimilitud

5. En 10 repeticiones independientes, la probabilidad de éxito en cada repetición es $p = 0.3$.

   a) Calcule la probabilidad de una secuencia específica que contenga exactamente cuatro éxitos y seis fracasos.

   b) Determine cuántas secuencias distintas tienen esa composición.

   c) Calcule la probabilidad de obtener exactamente cuatro éxitos.

6. Para cuatro observaciones se tienen

$$\mathbf{y} = (1,0,1,0)^T, \qquad \mathbf{p} = (0.8, 0.4, 0.7, 0.3)^T.$$

   a) Evalúe cada factor $p_i^{y_i}(1-p_i)^{1-y_i}$.

   b) Calcule la verosimilitud $L = \prod_{i=1}^{4} p_i^{y_i}(1-p_i)^{1-y_i}$.

   c) Calcule $\ln L$ y verifique que coincide con $\sum_{i=1}^{4}[y_i \ln p_i + (1-y_i)\ln(1-p_i)]$.

7. Considere

$$X = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & -1 \end{pmatrix}, \qquad \mathbf{y} = \begin{pmatrix} 0 \\ 1 \\ 1 \\ 0 \end{pmatrix}, \qquad \boldsymbol{\beta} = \begin{pmatrix} -0.5 \\ 0.8 \\ -0.4 \end{pmatrix}.$$

   a) Calcule $\mathbf{z} = X\boldsymbol{\beta}$ y $p_i = \sigma(z_i)$.

   b) Halle la verosimilitud de las etiquetas observadas.

   c) Calcule la entropía cruzada binaria promedio

$$E(\boldsymbol{\beta}) = -\frac{1}{4}\sum_{i=1}^{4}\big[y_i \ln p_i + (1-y_i)\ln(1-p_i)\big].$$

Entropía cruzada y gradiente

8. Calcule

$$\ell(y,p) = -y\ln p - (1-y)\ln(1-p)$$

para $p \in \{0.9, 0.6, 0.1\}$, primero con $y = 1$ y luego con $y = 0$. Organice los seis resultados en una tabla y explique cómo penaliza la pérdida una predicción segura pero incorrecta.

9. Las etiquetas reales y las predicciones de dos modelos son

i	1	2	3	4	5
y_i	1	0	1	1	0
$p_i^{(A)}$	0.90	0.20	0.65	0.55	0.10
$p_i^{(B)}$	0.70	0.05	0.80	0.40	0.30

Calcule la entropía cruzada binaria promedio de cada modelo. ¿Cuál de los dos elegiría según este criterio? Identifique además la observación que aporta la mayor pérdida en cada modelo.

10. Partiendo de $p = \sigma(z)$ y de la definición de $\ell(y, p)$:

a) demuestre que

$$\ell\big(y, \sigma(z)\big) = \ln(1 + e^z) - yz;$$

b) derive la expresión anterior respecto de z y obtenga

$$\frac{d}{dz}\ell\big(y, \sigma(z)\big) = \sigma(z) - y.$$

11. Sean

$$X = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 2 & 1 \\ 1 & -1 & 2 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 0 \\ 1 \\ 1 \\ 0 \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} 0 \\ \ln 2 \\ 0 \end{pmatrix}.$$

Calcule $\mathbf{z} = X\boldsymbol{\beta}$, el vector de probabilidades $\mathbf{p}$ y el gradiente

$$\nabla E(\boldsymbol{\beta}) = \frac{1}{4} X^T(\mathbf{p} - \mathbf{y}).$$

Indique las dimensiones de cada matriz o vector que interviene en el producto.

12. Considere

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \mathbf{y} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \qquad \boldsymbol{\beta}^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \qquad \alpha = 1.$$

Use la regla

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} - \frac{\alpha}{3} X^T\big(\mathbf{p}^{(k)} - \mathbf{y}\big)$$

para calcular $\boldsymbol{\beta}^{(1)}$ y $\boldsymbol{\beta}^{(2)}$. En cada iteración muestre $\mathbf{z}^{(k)}$, $\mathbf{p}^{(k)}$ y el gradiente. Compare también $E(\boldsymbol{\beta}^{(0)})$, $E(\boldsymbol{\beta}^{(1)})$ y $E(\boldsymbol{\beta}^{(2)})$.

13. Considere una sola observación con $x = 1$, $y = 1$ y predictor $z = \beta$.

a) Para el error cuadrático $M(\beta) = (\sigma(\beta) - 1)^2$, calcule $M''(\beta)$ y encuentre valores de β para los cuales sea negativo. Concluya que esta función no es convexa en todo $\mathbb{R}$.

b) Para la pérdida logística $E(\beta) = \ln(1 + e^\beta) - \beta$, demuestre que

$$E''(\beta) = \sigma(\beta)\big(1 - \sigma(\beta)\big) > 0.$$

c) Explique brevemente por qué la convexidad resulta conveniente al minimizar mediante descenso por gradiente.

14. Considere un modelo logístico sin intercepto, $p_i(\beta) = \sigma(x_i\beta)$, con $\beta \in [-10, 10]$, y los datos

i	1	2	3	4	5
x_i	1	2	-1	-1	5
y_i	1	1	0	0	0

Suponga que, en lugar de la entropía cruzada, se elige como función de costo el error cuadrático medio

$$M(\beta) = \frac{1}{5}\sum_{i=1}^{5}\big(\sigma(x_i\beta) - y_i\big)^2.$$

a) Demuestre que

$$M'(\beta) = \frac{2}{5}\sum_{i=1}^{5}\big(\sigma(x_i\beta) - y_i\big)\,\sigma(x_i\beta)\big(1 - \sigma(x_i\beta)\big)x_i.$$

b) Use como dato la segunda derivada

$$M''(\beta) = \frac{2}{5}\sum_{i=1}^{5} x_i^2\left[q_i^2 + (p_i - y_i)q_i(1 - 2p_i)\right],$$

donde

$$p_i = \sigma(x_i\beta), \qquad q_i = p_i(1 - p_i).$$

Verifique que

$$M(0) = \frac{1}{4}, \qquad M'(0) = 0, \qquad M''(0) = \frac{4}{5} > 0,$$

y concluya que $\beta = 0$ es un mínimo local estricto.

c) Calcule $M(10)$ y compruebe que $M(10) < M(0)$. Explique por qué esto demuestra que el mínimo local $\beta = 0$ no es el mínimo global en $[-10, 10]$.

d) Aplique el descenso por gradiente

$$\beta^{(k+1)} = \beta^{(k)} - \alpha M'(\beta^{(k)}), \qquad \alpha > 0,$$

con $\beta^{(0)} = 0$. Demuestre por inducción que $\beta^{(k)} = 0$ para todo k y concluya que, con esta inicialización, el algoritmo queda atrapado en un mínimo local y no converge al mínimo global. Comente qué muestra este ejemplo sobre la elección de la función de costo y la inicialización.

Método de Newton

15. Considere

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \mathbf{y} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \qquad \boldsymbol{\beta}^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Para la entropía cruzada binaria promedio, sean

$$\mathbf{p} = \sigma(X\boldsymbol{\beta}), \qquad W = \operatorname{diag}\big(p_i(1-p_i)\big),$$

de modo que

$$\nabla E(\boldsymbol{\beta}) = \frac{1}{3}X^T(\mathbf{p}-\mathbf{y}), \qquad H(\boldsymbol{\beta}) = \frac{1}{3}X^T W X.$$

Use la actualización de Newton

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} - H(\boldsymbol{\beta}^{(k)})^{-1}\nabla E(\boldsymbol{\beta}^{(k)}).$$

a) Calcule $\mathbf{p}^{(0)}$, $W^{(0)}$, el gradiente y la Hessiana en $\boldsymbol{\beta}^{(0)}$. Obtenga $\boldsymbol{\beta}^{(1)}$.

b) Realice una segunda iteración para calcular $\boldsymbol{\beta}^{(2)}$.

c) Verifique que

$$\boldsymbol{\beta}^{*} = \begin{pmatrix} -\ln 2 \\ 0 \end{pmatrix}$$

anula el gradiente y explique por qué es el mínimo global.

d) Compare las dos aproximaciones con $\boldsymbol{\beta}^{*}$ y calcule la pérdida en cada iteración.