IMCA

Maestría en Modelización Matemática y Computacional

Curso: Optimización
Profesores: E. Oré & E. Ocaña

Semana 2: Métodos de Búsqueda Lineal (Line Search)

1. Introducción y Esquema General

En esta sesión abordamos el problema de optimización continua no restringida:

$$\min_{x\in\mathbb{R}^n} f(x), \tag{1}$$

donde $f:\mathbb{R}^n\to\mathbb{R}$ es una función una o dos veces continuamente diferenciable, denotado resp. como C^1 y C^2.

Teorema 1.1: (Teorema de Taylor)

Suponga que $f:\mathbb{R}^n\to\mathbb{R}$ es continuamente diferenciable (C^1), y que $p\in\mathbb{R}^n$. Entonces se tiene que

$$f(x+p)=f(x)+\int_0^1 \nabla f(x+tp)^T p\,dt, \tag{2}$$

y también

$$f(x+p)=f(x)+\nabla f(x+tp)^T p, \tag{3}$$

para algún $t\in(0,1)$. Además, si f es dos veces continuamente diferenciable (C^2), se tiene que

$$\nabla f(x+p)=\nabla f(x)+\int_0^1 \nabla^2 f(x+tp)p\,dt, \tag{4}$$

$$f(x+p)=f(x)+\nabla f(x)^T p+\int_0^1 (1-t)\,p^T\nabla^2 f(x+tp)p\,dt, \tag{5}$$

$$f(x+p)=f(x)+\nabla f(x)^T p+\frac{1}{2}p^T\nabla^2 f(x+tp)p, \tag{6}$$

para algún $t\in(0,1)$.

Los algoritmos iterativos de **búsqueda lineal (Line Search)** generan una sucesión $\{x_k\}$ mediante el esquema:

$$x_{k+1}=x_k+\alpha_k p_k, \tag{7}$$

donde $p_k\in\mathbb{R}^n$ representa la **dirección de búsqueda** y $\alpha_k>0$ es la **longitud o magnitud de paso**.

Definición 1.1: Dirección de Descenso

Diremos que un vector $p_k \in \mathbb{R}^n \setminus \{0\}$ es una **dirección de descenso** para f en el punto x_k si cumple:

$$\nabla f(x_k)^T p_k < 0.$$

2. Condiciones de aceptación del paso: Armijo y Wolfe

Si bien una búsqueda exacta requeriría resolver $\min_{\alpha>0} \phi(\alpha) := f(x_k+\alpha p_k)$, esto resulta computacionalmente ineficiente. Por ello, se emplean **búsquedas inexactas** mediante condiciones que aseguren un descenso suficiente y eviten pasos excesivamente pequeños.

Definición 2.1: Condición de Armijo (Suficiente Descenso)

Dado $c_1 \in (0,1)$, la longitud de paso $\alpha_k > 0$ satisface la condición de Armijo si:

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T p_k.$$

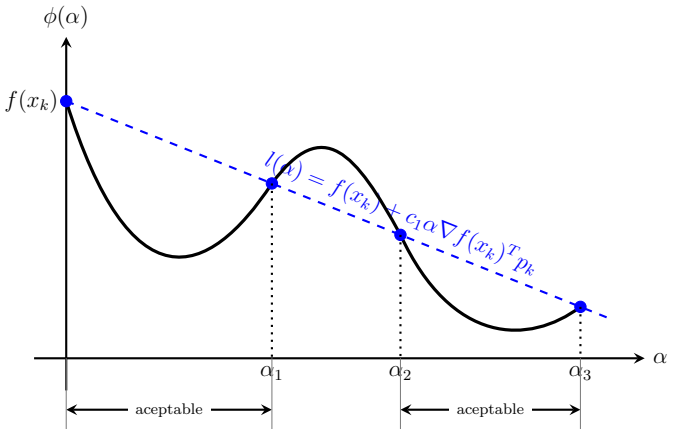


Figura 1: Condición de Armijo: los intervalos aceptables $[0, \alpha_1]$ y $[\alpha_2, \alpha_3]$ coinciden exactamente con los puntos donde la curva $\phi(\alpha)$ está por debajo de la recta l.

Definición 2.2: Condiciones de Wolfe (Débiles y Estrictas)

Dada la condición de Armijo con $c_1 \in (0,1)$, se añade la **condición de curvatura** con $c_2 \in (c_1, 1)$:

a) **Wolfe Débil:**

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k.$$

b) **Wolfe Estricta / Fuerte:**

$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|.$$

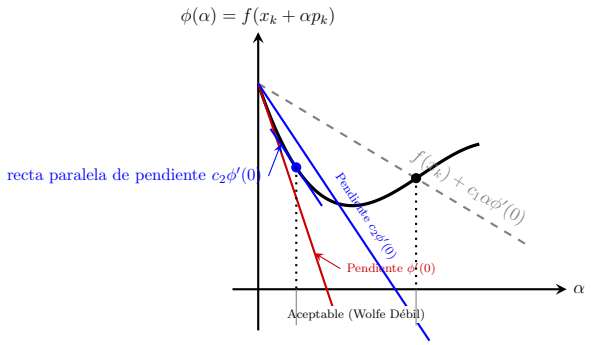


Figura 2: Condición de Wolfe Débil

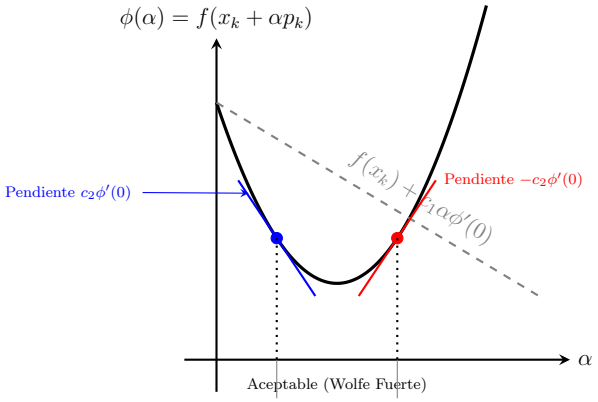


Figura 3: Condición de Wolfe Fuerte.

Lema 2.1: Lema de Existencia de Pasos de Wolfe

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función continuamente diferenciable y acotada inferiormente a lo largo de la semirrecta $\{x_k + \alpha p_k \mid \alpha > 0\}$. Si p_k es una dirección de descenso $(\nabla f(x_k)^T p_k < 0)$ y las constantes satisfacen $0 < c_1 < c_2 < 1$, entonces existe al menos un intervalo de tamaños de paso $\alpha > 0$ que cumplen las condiciones de Wolfe (tanto en su variante débil como fuerte).

Esbozo de la demostración. La existencia de un paso que satisfaga las condiciones de Wolfe se demuestra analizando la función unidimensional $\phi(\alpha) = f(x_k + \alpha p_k)$ mediante el siguiente esquema:

1. **Construcción de la recta de Armijo:** Se define la recta $l(\alpha) = f(x_k) + c_1\alpha\phi'(0)$. Dado que $c_1 \in (0, 1)$ y $\phi'(0) < 0$, esta recta decrece de forma más suave que la tangente inicial $\phi'(0)$.

2. **Punto de intersección (α'):** Como f está acotada inferiormente a lo largo del rayo $\alpha > 0$, la función $\phi(\alpha)$ no puede decrecer indefinidamente. Por continuidad, la recta $l(\alpha) \to -\infty$ termina cortando a $\phi(\alpha)$. Se define $\alpha' > 0$ como la primera intersección, garantizando la condición de Armijo para todo $\alpha \in (0, \alpha')$.

3. **Aplicación del Teorema del Valor Medio:** En el intervalo $[0, \alpha']$, el Teorema del Valor Medio asegura la existencia de un $\alpha_k \in (0, \alpha')$ tal que:

$$\phi'(\alpha_k) = \frac{\phi(\alpha') - \phi(0)}{\alpha'} = c_1\phi'(0).$$

4. **Verificación de la condición de curvatura:** Como $c_1 < c_2$ y $\phi'(0) < 0$, se deduce la desigualdad $c_1\phi'(0) > c_2\phi'(0)$. Esto implica directamente que $\phi'(\alpha_k) > c_2\phi'(0)$, lo que confirma que α_k satisface simultáneamente el decremento suficiente y la curvatura (variantes débil y fuerte).

□

Observación Crítica y Contraejemplo: Necesidad de la condición de curvatura

¿Qué ocurre si eliminamos la condición de curvatura y usamos únicamente el criterio ingenuo de decremento $f(x_{k+1}) < f(x_k)$?. **Aquí un contraejemplo de pasos infinitesimales:** Considérese $f(x) = x^2$ con punto inicial $x_0 = 2$. Si elegimos la dirección de descenso fija $p_k = -1$ (que satisface $\nabla f(x_k)p_k < 0$ para $x_k > 0$) y los pasos $\alpha_k = (1/2)^{k+1}$, el esquema $x_{k+1} = x_k + \alpha_k p_k$ genera la sucesión:

$$x_k = 2 - \sum_{j=1}^{k} \left(\frac{1}{2}\right)^j \implies \lim_{k\to\infty} x_k = 1.$$

Aunque el costo reduce en cada iteración ($f(x_{k+1}) < f(x_k)$), el algoritmo converge a $x = 1$ y jamás alcanza el mínimo global $x^* = 0$. La ausencia de la condición de curvatura (o de Armijo) permite que la magnitud de los pasos se reduzca tan rápido que el algoritmo queda "estancado" antes de llegar a un punto estacionario.

3. Teorema de Zoutendijk

El Teorema de Zoutendijk establece formalmente que bajo condiciones suaves y aceptación de paso de Wolfe, el gradiente de la función tiende a cero a menos que las direcciones elegidas se vuelvan casi ortogonales al gradiente.

Teorema 3.1: Teorema de Zoutendijk (Nocedal & Wright, Teorema 3.2)

Sea $f : \mathbb{R}^n \to \mathbb{R}$ continuamente diferenciable y acotada inferiormente en $\mathbb{R}^n$. Suponga que ∇f es Lipschitz continua con constante $L > 0$, es decir:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathbb{R}^n.$$

Considere cualquier algoritmo de la forma $x_{k+1} = x_k + \alpha_k p_k$, donde p_k es una dirección de descenso y α_k satisface las condiciones de Wolfe. Entonces:

$$\sum_{k=0}^{\infty} \cos^2\theta_k \|\nabla f(x_k)\|^2 < \infty,$$

donde θ_k es el ángulo entre p_k y el gradiente negativo $-\nabla f(x_k)$, dado por:

$$\cos\theta_k = \frac{-\nabla f(x_k)^T p_k}{\|\nabla f(x_k)\|\|p_k\|}.$$

Esbozo de la demostración. La demostración del Teorema de Zoutendijk se basa en acotar el decremento de la función en cada paso utilizando la continuidad Lipschitz del gradiente y las condiciones de Wolfe:

1. **Cota inferior para el paso (α_k):** Restando $\nabla f(x_k)^T p_k$ en ambos lados de la condición de curvatura de Wolfe ($\nabla f(x_{k+1})^T p_k \geq c_2 \nabla f(x_k)^T p_k$), se obtiene:

$$(\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \geq (c_2 - 1)\nabla f(x_k)^T p_k.$$

   Aplicando la desigualdad de Cauchy-Schwarz y la continuidad Lipschitz de ∇f, el miembro izquierdo se acota por $L\alpha_k \|p_k\|^2$. Despejando α_k, se establece la cota inferior:

$$\alpha_k \geq \left(\frac{1 - c_2}{L}\right)\left(\frac{-\nabla f(x_k)^T p_k}{\|p_k\|^2}\right).$$

2. **Decremento en la condición de Armijo:** Sustituyendo esta cota de α_k en la condición de Armijo ($f(x_{k+1}) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T p_k$), se obtiene un decremento proporcional al cuadrado del coseno del ángulo θ_k:

$$f(x_k) - f(x_{k+1}) \geq c \cos^2 \theta_k \|\nabla f(x_k)\|^2, \quad \text{con } c = \frac{c_1(1 - c_2)}{L} > 0.$$

3. **Suma telescópica y acotación global:** Sumando la desigualdad para $k = 0, 1, \ldots, N$:

$$\sum_{k=0}^{N} \cos^2 \theta_k \|\nabla f(x_k)\|^2 \leq \frac{1}{c}(f(x_0) - f(x_{N+1})).$$

   Como f está acotada inferiormente por un valor f^*, la suma de las diferencias está acotada por $(f(x_0) - f^*)$ de forma independiente de N. Tomando el límite cuando $N \to \infty$, la serie converge.

□

Observación Crítica y Contraejemplo: Importancia de la Continuidad Lipschitz del Gradiente

La hipótesis de que ∇f sea Lipschitz continua es fundamental para asegurar que el gradiente no varíe de forma infinitamente rápida en trayectorias cortas.
Si ∇f no satisface la condición Lipschitz (por ejemplo, $f(x) = |x|^{4/3}$, donde $f'(x) = \frac{4}{3}\text{sgn}(x)|x|^{1/3}$ no es Lipschitz en $x = 0$), no existe una constante $L > 0$ finita. Como resultado, la cota inferior del paso se degrada a $\alpha_k \geq 0$ (pues $L \to \infty$), perdiendo toda capacidad de garantizar un tamaño de paso mínimo. Esto invalida la demostración del decremento suficiente e impide asegurar la convergencia global del algoritmo.

4. Método del gradiente descendente y tasa de convergencia

En el método del gradiente descendente, elegimos la dirección de máxima pendiente local:

$$p_k = -\nabla f(x_k).$$

Por ende, $\cos\theta_k = 1$. Del Teorema de Zoutendijk se deduce de inmediato que

$$\lim_{k\to\infty} \|\nabla f(x_k)\| = 0.$$

Definición 4.1: Convexidad Estricta

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función continuamente diferenciable. Se dice que f es **estrictamente convexa** si para cualesquiera $x, y \in \mathbb{R}^n$ con $x \neq y$, se satisface:

$$f(y) > f(x) + \nabla f(x)^T(y - x).$$

Se nota claramente que estricta convexidad implica convexidad.

Teorema 4.1: Unicidad de Solución bajo Convexidad Estricta

Si $f : \mathbb{R}^n \to \mathbb{R}$ es estrictamente convexa y admite un mínimo global $x^* \in \mathbb{R}^n$, entonces x^* es el **único mínimo global** de f. Recordemos que en el caso convexo, mínimo local implica mínimo global.

Demostración. Puesto que x^* es un mínimo global (que pertenece al interior del conjunto admisible), satisface la condición necesaria de primer orden $\nabla f(x^*) = 0$.

Supóngase por contradicción la existencia de otro mínimo global $y \in \mathbb{R}^n$ tal que $y \neq x^*$, lo cual implica que $f(y) = f(x^*)$. Aplicando la condición de convexidad estricta (Definición 4.1) en el punto x^*:

$$f(y) > f(x^*) + \underbrace{\nabla f(x^*)^T(y - x^*)}_{=0} = f(x^*).$$

De aquí se deduce que $f(y) > f(x^*)$, lo cual contradice la hipótesis inicial de que y es un mínimo global ($f(y) = f(x^*)$). Por consiguiente, el mínimo global x^* es único. □

Definición 4.2: Fuerte Convexidad y Coercividad

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función continuamente diferenciable.

i) Se dice que f es m-**fuertemente convexa** con constante $m > 0$ si satisface:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{m}{2}\|y - x\|^2, \quad \forall x, y \in \mathbb{R}^n.$$

ii) Se dice que f es **coerciva** si sus conjuntos subnivel son acotados, es decir, $\lim_{\|x\|\to\infty} f(x) = +\infty$.

Teorema 4.2: Caracterización Hessiana de la Fuerte Convexidad

Sea $f : \mathbb{R}^n \to \mathbb{R}$ dos veces continuamente diferenciable (C^2). La función f es m-fuertemente convexa ($m > 0$) si y solo si los valores propios de su matriz Hessiana están acotados inferiormente por m de manera uniforme:

$$y^T\nabla^2 f(x)y \geq m\|y\|^2, \quad \forall x, y \in \mathbb{R}^n.$$

Demostración. ($\Leftarrow$) **Suficiencia:** Sean $x, y \in \mathbb{R}^n$, definamos la función auxiliar $g(t) = f(x + t(y - x))$ para $t \in [0, 1]$. Por la regla de la cadena, sus derivadas son

$$g'(t) = \nabla f(x + t(y - x))^T (y - x) \quad \text{y} \quad g''(t) = (y - x)^T \nabla^2 f(x + t(y - x))(y - x).$$

Aplicando el **Teorema de Taylor de segundo orden con resto de Lagrange** a la función escalar $g(t)$ alrededor de $t = 0$, existe $\tau \in (0, 1)$ tal que:

$$g(1) = g(0) + g'(0) + \frac{1}{2} g''(\tau).$$

Traduciendo esta relación a la función multivariable f, existe un punto intermedio $z = x + \tau(y - x)$ en el segmento $[x, y]$ tal que:

$$f(y) = f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T \nabla^2 f(z)(y - x).$$

Sustituyendo la hipótesis $(y - x)^T \nabla^2 f(z)(y - x) \geq m\|y - x\|^2$, se deduce la condición de m-fuerte convexidad:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{m}{2} \|y - x\|^2.$$

($\Rightarrow$) **Necesidad:** Supóngase que f es m-fuertemente convexa. Fijando $x \in \mathbb{R}^n$, un vector de dirección $v \in \mathbb{R}^n$ arbitrario y $t > 0$, evaluamos la definición de m-fuerte convexidad en el punto $y = x + tv$:

$$f(x + tv) \geq f(x) + t\nabla f(x)^T v + \frac{m}{2} t^2 \|v\|^2.$$

Por el **Teorema de Taylor de segundo orden** alrededor de $t = 0$, existe un $\tau_t \in (0, t)$ tal que:

$$f(x + tv) = f(x) + t\nabla f(x)^T v + \frac{t^2}{2} v^T \nabla^2 f(x + \tau_t v) v.$$

Igualando ambas expresiones y restando $f(x) + t\nabla f(x)^T v$:

$$\frac{t^2}{2} v^T \nabla^2 f(x + \tau_t v) v \geq \frac{m}{2} t^2 \|v\|^2.$$

Dividiendo por $\frac{t^2}{2} > 0$:

$$v^T \nabla^2 f(x + \tau_t v) v \geq m\|v\|^2.$$

Puesto que $f \in C^2$, la matriz Hessiana es continua. Tomando el límite cuando $t \to 0^+$, se tiene que $\tau_t \to 0$ y por lo tanto $x + \tau_t v \to x$, lo que concluye:

$$v^T \nabla^2 f(x) v \geq m\|v\|^2, \quad \forall x, v \in \mathbb{R}^n.$$

□

Teorema 4.3: Existencia y Unicidad bajo Fuerte Convexidad

Si $f : \mathbb{R}^n \to \mathbb{R}$ es C^1 y m-fuertemente convexa ($m > 0$), entonces f es coerciva y posee un **único mínimo global** $x^* \in \mathbb{R}^n$.

Demostración. **Coercividad y Existencia:** Fijando $x_0 \in \mathbb{R}^n$ en la condición de m-fuerte convexidad y aplicando la desigualdad de Cauchy-Schwarz:

$$f(x) \geq f(x_0) - \|\nabla f(x_0)\|\|x - x_0\| + \frac{m}{2}\|x - x_0\|^2.$$

Al tomar $\|x\| \to \infty$, el término cuadrático domina, implicando $f(x) \to \infty$ (coercividad). Por el Teorema de Weierstrass, el conjunto subnivel $S_0 = \{x \in \mathbb{R}^n \mid f(x) \leq f(x_0)\}$ es compacto, lo que garantiza la **existencia** de al menos un mínimo global x^*.

Unicidad: Como la m-fuerte convexidad implica convexidad estricta (puesto que $\frac{m}{2}\|y - x\|^2 > 0$ para $y \neq x$), la **unicidad** se sigue directamente del Teorema 4.1. □

4.1. Tasa de convergencia: El caso cuadrático

Considérese la función cuadrática fuertemente convexa $f : \mathbb{R}^n \to \mathbb{R}$ definida por:

$$f(x) = \frac{1}{2}x^T Q x - b^T x, \tag{8}$$

donde $Q \in \mathbb{R}^{n\times n}$ es una matriz simétrica y definida positiva ($Q \succ 0$), y $b \in \mathbb{R}^n$. Los autovalores de Q satisfacen:

$$0 < \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n. \tag{9}$$

Puesto que Q es definida positiva, el gradiente de f viene dado por $\nabla f(x) = Qx - b$. El único mínimo global $x^* \in \mathbb{R}^n$ satisface la condición de primer orden $\nabla f(x^*) = 0$, es decir:

$$Qx^* = b \implies x^* = Q^{-1}b. \tag{10}$$

Para medir el error de un punto iterado $x \in \mathbb{R}^n$ respecto a la solución óptima x^*, introducimos la **norma ponderada por la matriz** Q (o Q-norma):

Definición 4.3: Q-Norma y relación con la función objetivo

Para cualquier vector $v \in \mathbb{R}^n$, la Q-norma se define como:

$$\|v\|_Q = \sqrt{v^T Q v}.$$

En particular, para el error $x - x^*$, se verifica directamente la siguiente relación con el valor residual de la función objetivo:

$$\frac{1}{2}\|x - x^*\|_Q^2 = \frac{1}{2}(x - x^*)^T Q(x - x^*) = f(x) - f(x^*). \tag{11}$$

Lema 4.1: Desigualdad de Kantorovich

Para cualquier vector no nulo $g \in \mathbb{R}^n$ y matriz Q definida positiva con autovalores $0 < m = \lambda_1 \leq \cdots \leq \lambda_n = M$, la **Desigualdad de Kantorovich** establece la cota inferior:

$$\frac{(g^T g)^2}{(g^T Q g)(g^T Q^{-1} g)} \geq \frac{4Mm}{(M + m)^2}.$$

Demostración. Dado que el cociente es invariante ante el escalamiento de g (es decir, reemplazando g por γg con $\gamma \neq 0$ el resultado no cambia), asumimos sin pérdida de generalidad que $\|g\| = 1$, por lo cual $g^T g = 1$.

Por el Teorema Espectral, existe una base ortonormal de autovectores $\{v_1, \ldots, v_n\}$ con autovalores asociados $\lambda_i \in [m, M]$. Expresando a g en dicha base:

$$g = \sum_{i=1}^{n} x_i v_i, \quad \text{de donde } \; 1 = \|g\|^2 = \sum_{i=1}^{n} x_i^2.$$

Definiendo los pesos $p_i = x_i^2 \geq 0$, la condición $\sum_{i=1}^{n} p_i = 1$ nos permite interpretar a $\{p_i\}$ como una distribución de probabilidad discreta. Reescribiendo las formas cuadráticas:

$$g^T Q g = \sum_{i=1}^{n} p_i \lambda_i = \mathbb{E}[\lambda], \quad g^T Q^{-1} g = \sum_{i=1}^{n} p_i \frac{1}{\lambda_i} = \mathbb{E}\left[\frac{1}{\lambda}\right].$$

La desigualdad requerida se reduce a acotar el producto $\mathbb{E}[\lambda] \cdot \mathbb{E}\left[\frac{1}{\lambda}\right]$ por arriba:

$$(g^T Q g)(g^T Q^{-1} g) = \left(\sum_{i=1}^{n} p_i \lambda_i\right)\left(\sum_{i=1}^{n} p_i \frac{1}{\lambda_i}\right) \leq \frac{(M+m)^2}{4Mm}.$$

En efecto, expresamos a todo $\lambda_i \in [m, M]$ como combinación convexa de los extremos del intervalo $[m, M]$:

$$\lambda_i = \theta_i m + (1 - \theta_i) M, \quad \text{donde } \theta_i = \frac{M - \lambda_i}{M - m} \in [0, 1].$$

Por la convexidad de $h(t) = \frac{1}{t}$ para $t > 0$, tenemos $h(\lambda_i) \leq \theta_i h(m) + (1 - \theta_i) h(M)$, de donde

$$\frac{1}{\lambda_i} \leq \theta_i \frac{1}{m} + (1 - \theta_i)\frac{1}{M} = \frac{M - \lambda_i}{M - m} \cdot \frac{1}{m} + \frac{\lambda_i - m}{M - m} \cdot \frac{1}{M} = \frac{M + m - \lambda_i}{Mm}.$$

De este se sigue que

$$g^T Q^{-1} g = \sum_{i=1}^{n} p_i \frac{1}{\lambda_i} \leq \sum_{i=1}^{n} p_i \left(\frac{M + m - \lambda_i}{Mm}\right) = \frac{M + m - \sum_{i=1}^{n} p_i \lambda_i}{Mm} = \frac{M + m - g^T Q g}{Mm}.$$

Llamando $u = g^T Q g$ (note que $m \leq u \leq M$), tenemos

$$(g^T Q g)(g^T Q^{-1} g) \leq u \cdot \left(\frac{M + m - u}{Mm}\right) = \frac{(M+m)u - u^2}{Mm} := \phi(u).$$

Busquemos una cota superior de $\phi(u)$: Siento esta fuertemente cóncava (i.e., -ϕ es fuertemente convexa), su máximo global se alcanza donde su derivada es cero:

$$\phi'(u) = \frac{(M+m) - 2u}{Mm} = 0 \implies u^* = \frac{M+m}{2}.$$

Evaluando $\phi(u^*)$:

$$\phi\left(\frac{M+m}{2}\right) = \frac{(M+m)\left(\frac{M+m}{2}\right) - \left(\frac{M+m}{2}\right)^2}{Mm} = \frac{\left(\frac{M+m}{2}\right)^2}{Mm} = \frac{(M+m)^2}{4Mm}.$$

Por lo tanto, obtenemos la cota superior siguiente:

$$(g^T Qg)(g^T Q^{-1} g) \leq \frac{(M+m)^2}{4Mm}.$$

Tomando el recíproco en ambos lados e invirtiendo la desigualdad, concluimos finalmente la desigualdad de Kantorovich:

$$\frac{(g^T g)^2}{(g^T Qg)(g^T Q^{-1} g)} \geq \frac{4Mm}{(M+m)^2}.$$

□

Teorema 4.4: Convergencia del Gradiente Descendente para funciones cuadráticas

Cuando el método del gradiente descendente con búsqueda lineal exacta:

$$x_{k+1} = x_k + \alpha_k p_k, \quad \text{con } p_k = -\nabla f(x_k) = -\left(Qx_k - b\right), \tag{12}$$

se aplica a la función cuadrática fuertemente convexa (8), la norma del error satisface:

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 \|x_k - x^*\|_Q^2, \tag{13}$$

donde $0 < \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$ son los autovalores de Q.

Demostración. Denotemos el vector de gradiente en la iteración k por $g_k = \nabla f(x_k) = Qx_k - b$. Observamos que:

$$g_k = Qx_k - Qx^* = Q(x_k - x^*). \tag{14}$$

Derivación del tamaño de paso exacto α_k. La búsqueda lineal exacta determina α_k mediante la minimización unidimensional:

$$\alpha_k = \arg\min_{\alpha > 0} h(\alpha) := f(x_k - \alpha g_k).$$

Sustituyendo la definición de $f(x)$ dada en (8):

$$h(\alpha) = \frac{1}{2}(x_k - \alpha g_k)^T Q(x_k - \alpha g_k) - b^T(x_k - \alpha g_k).$$

Expandiendo la expresión:

$$h(\alpha) = f(x_k) - \alpha g_k^T g_k + \frac{1}{2}\alpha^2 g_k^T Q g_k.$$

Igualando a cero la derivada $h'(\alpha) = -g_k^T g_k + \alpha g_k^T Q g_k = 0$, obtenemos:

$$\alpha_k = \frac{g_k^T g_k}{g_k^T Q g_k}.$$

Expresión del decrecimiento del error en Q-norma. Sustituyendo $x_{k+1} = x_k - \alpha_k g_k$ y restando x^*:

$$x_{k+1} - x^* = (x_k - x^*) - \alpha_k g_k.$$

Calculando la Q-norma al cuadrado de $x_{k+1} - x^*$:

$$\begin{aligned}\|x_{k+1} - x^*\|_Q^2 &= (x_{k+1} - x^*)^T Q(x_{k+1} - x^*) \\ &= (x_k - x^*)^T Q(x_k - x^*) - 2\alpha_k g_k^T Q(x_k - x^*) + \alpha_k^2 g_k^T Q g_k.\end{aligned}$$

Usando la relación $Q(x_k - x^*) = g_k$, se deduce que $g_k^T Q(x_k - x^*) = g_k^T g_k$. Por lo tanto:

$$\|x_{k+1} - x^*\|_Q^2 = \|x_k - x^*\|_Q^2 - 2\alpha_k g_k^T g_k + \alpha_k^2 g_k^T Q g_k.$$

Sustituyendo la expresión de α_k:

$$\|x_{k+1} - x^*\|_Q^2 = \|x_k - x^*\|_Q^2 - \frac{(g_k^T g_k)^2}{g_k^T Q g_k}.$$

Factorizando $\|x_k - x^*\|_Q^2$ y observando que $\|x_k - x^*\|_Q^2 = g_k^T Q^{-1} g_k$:

$$\|x_{k+1} - x^*\|_Q^2 = \left(1 - \frac{(g_k^T g_k)^2}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)}\right) \|x_k - x^*\|_Q^2. \tag{15}$$

Por la **Desigualdad de Kantorovich** (Lema 4.1):

$$\frac{(g_k^T g_k)^2}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)} \geq \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2}.$$

Sustituyendo esta cota inferior en la ecuación (15):

$$1 - \frac{(g_k^T g_k)^2}{(g_k^T Q g_k)(g_k^T Q^{-1} g_k)} \leq 1 - \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2} = \frac{(\lambda_n - \lambda_1)^2}{(\lambda_n + \lambda_1)^2}.$$

Por lo tanto:

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 \|x_k - x^*\|_Q^2.$$

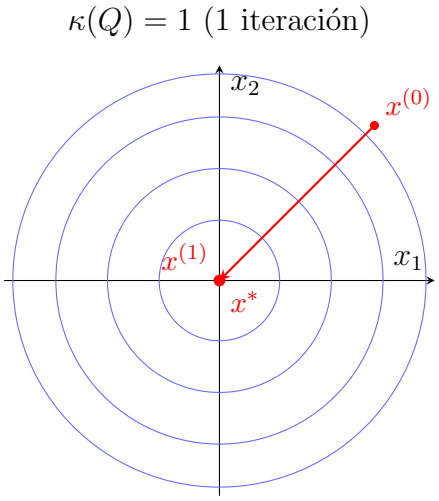
□

Observación Crítica y Contraejemplo: Interpretación del Número de Condición y Convergencia

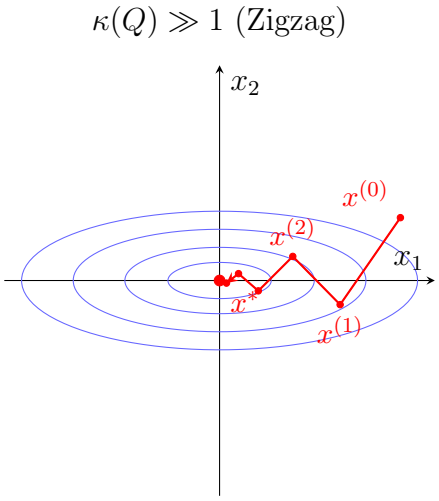
Definiendo el número de condición de la matriz Q como $\kappa(Q) = \frac{\lambda_n}{\lambda_1} \geq 1$, el factor de reducción del error se expresa como:

$$\left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 = \left(\frac{\kappa(Q) - 1}{\kappa(Q) + 1}\right)^2.$$

- Si $\kappa(Q) = 1$, la tasa de reducción es 0, por lo que el método converge exactamente en **1 sola iteración**.
- Si $\kappa(Q) \gg 1$, la tasa de reducción se aproxima a 1, provocando una velocidad de convergencia lineal muy lenta y un patrón en zig-zag.



(a) Curvas circulares: el gradiente apunta directamente al mínimo x^*.



(b) Curvas elípticas: los pasos ortogonales generan avance lento.

Figura 4: Efecto del número de condición $\kappa(Q)$ en la velocidad de convergencia del descenso del gradiente.

4.2. Tasa de convergencia: El caso general

Teorema 4.5: Convergencia Local del Método del Gradiente Descendente

uponga que $f : \mathbb{R}^n \to \mathbb{R}$ es dos veces continuamente diferenciable (C^2), y que la sucesión $\{x_k\}$ generada por el método del gradiente descendente con búsqueda lineal exacta:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k), \quad \text{donde } \alpha_k = \arg\min_{\alpha>0} f(x_k - \alpha \nabla f(x_k)),$$

converge a un punto x^* en el cual la matriz Hessiana $\nabla^2 f(x^*)$ es definida positiva. Sea $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$ la ordenación de los autovalores de $\nabla^2 f(x^*)$. Sea r cualquier escalar que satisfaga:

$$r \in \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}, 1 \right).$$

Entonces, para todo k suficientemente grande, se satisface la tasa de convergencia:

$$f(x_{k+1}) - f(x^*) \leq r^2 \left[f(x_k) - f(x^*) \right].$$

Demostración. Puesto que $x_k \to x^*$ y $\nabla^2 f(x^*)$ es definida positiva, por la continuidad de $\nabla^2 f$ existen constantes $0 < m \leq M < \infty$ y una vecindad $B(x^*, \delta)$ en la cual:

$$mI \preceq \nabla^2 f(x) \preceq MI, \quad \forall x \in B(x^*, \delta).$$

Dado que $x_k \to x^*$, para todo $k \geq K_0$ (suficientemente grande), los iterados x_k y los segmentos $[x^*, x_k]$ permanecen dentro de $B(x^*, \delta)$.

Denotemos $g_k = \nabla f(x_k)$. **Dado que x^* es un mínimo local estricto**, la condición de primer orden establece $\nabla f(x^*) = 0$. Por el Teorema Fundamental del Cálculo aplicado

al gradiente, se tiene

$$g_k = \nabla f(x_k) - \nabla f(x^*) = \left(\int_0^1 \nabla^2 f(x^* + t(x_k - x^*))\, dt \right) (x_k - x^*).$$

Definimos la **Hessiana promedio a lo largo del segmento** $[x^*, x_k]$:

$$A_k := \int_0^1 \nabla^2 f(x^* + t(x_k - x^*))\, dt.$$

Puesto que $\nabla^2 f(x) \to \nabla^2 f(x^*)$ cuando $x \to x^*$, la propiedad de continuidad de la integral implica que:

$$\lim_{k\to\infty} A_k = \nabla^2 f(x^*). \tag{16}$$

Además, $g_k = A_k(x_k - x^*)$, de modo que $(x_k - x^*) = A_k^{-1} g_k$.

Análogamente, al expandir la función objetivo mediante el Teorema de Taylor con resto integral alrededor de x^*:

$$f(x_k) - f(x^*) = \frac{1}{2}(x_k - x^*)^T H_k (x_k - x^*), \tag{17}$$

donde

$$H_k := 2 \int_0^1 (1-t) \nabla^2 f(x^* + t(x_k - x^*))\, dt.$$

Como $2\int_0^1 (1-t)\, dt = 1$, el mismo argumento de continuidad garantiza que:

$$\lim_{k\to\infty} H_k = \nabla^2 f(x^*). \tag{18}$$

Relación de valor residual $f(x_k) - f(x^*)$ en términos del gradiente g_k: Sustituyendo $x_k - x^* = A_k^{-1} g_k$ en la expresión (17), tenemos

$$f(x_k) - f(x^*) = \frac{1}{2} g_k^T A_k^{-1} H_k A_k^{-1} g_k. \tag{19}$$

Definimos la matriz simétrica y definida positiva:

$$B_k := A_k^{-1} H_k A_k^{-1}.$$

Aprovechando los límites (16) y (18), se deduce directamente que:

$$\lim_{k\to\infty} B_k = \left(\nabla^2 f(x^*)\right)^{-1} \left(\nabla^2 f(x^*)\right) \left(\nabla^2 f(x^*)\right)^{-1} = \left(\nabla^2 f(x^*)\right)^{-1}.$$

Por tanto, (19) se escribe como:

$$f(x_k) - f(x^*) = \frac{1}{2} g_k^T B_k g_k. \tag{20}$$

Cota superior para la iteración $f(x_{k+1})$: Dado que α_k se selecciona mediante una búsqueda lineal exacta en la dirección $-g_k$, la definición del mínimo unidimensional impone que para cualquier $\alpha > 0$ arbitrario:

$$f(x_{k+1}) = f(x_k - \alpha_k g_k) \leq f(x_k - \alpha g_k). \tag{21}$$

Elegimos en particular el paso $t_k > 0$ que minimiza la aproximación cuadrática local con la Hessiana promedio: $m_k(t) = f(x_k) - tg_k^T g_k + \frac{1}{2}t^2 g_k^T A_k g_k$, es decir, el paso de tipo Newton/Cuadrático exacto:

$$t_k = \frac{g_k^T g_k}{g_k^T A_k g_k}. \tag{22}$$

Expandiendo $f(x_k - t_k g_k) - f(x^*)$ utilizando la expansión de Taylor alrededor de x_k:

$$f(x_k - t_k g_k) = f(x_k) - t_k g_k^T g_k + \frac{1}{2}t_k^2 g_k^T \tilde{H}_k g_k, \tag{23}$$

donde $\tilde{H}_k = 2\int_0^1 (1-t)\nabla^2 f(x_k - tt_k g_k)\, dt$. Notemos que dado que $x_k \to x^*$ y $g_k \to 0$, se tiene también que $\lim_{k\to\infty} \tilde{H}_k = \nabla^2 f(x^*)$. De (21), (22) y (23), tenemos

$$f(x_{k+1}) - f(x^*) \leq f(x_k) - f(x^*) - \frac{(g_k^T g_k)^2}{g_k^T A_k g_k} + \frac{1}{2}\frac{(g_k^T g_k)^2}{(g_k^T A_k g_k)^2} g_k^T \tilde{H}_k g_k.$$

Sustituyendo (20) para $f(x_k) - f(x^*)$, tenemos

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq 1 - \frac{2\frac{(g_k^T g_k)^2}{g_k^T A_k g_k} - \frac{(g_k^T g_k)^2}{(g_k^T A_k g_k)^2} g_k^T \tilde{H}_k g_k}{g_k^T B_k g_k}.$$

o equivalentemente, haciendo $u_k = \frac{g_k}{\|g_k\|}$ (que pertenece a la esfera unitaria – compacto),

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq 1 - \frac{\frac{2}{u_k^T A_k u_k} - \frac{1}{(u_k^T A_k u_k)^2} u_k^T \tilde{H}_k u_k}{u_k^T B_k u_k}. \tag{24}$$

Comportamiento asintótico: Notemos que cuando $k \to \infty$:

$$A_k \to \nabla^2 f(x^*), \quad \tilde{H}_k \to \nabla^2 f(x^*), \quad B_k \to (\nabla^2 f(x^*))^{-1}.$$

De la relación (24), se deduce que para cualquier $\epsilon > 0$, existe un K suficientemente grande tal que para todo $k \geq K$:

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq 1 - \frac{1}{(u_k^T \nabla^2 f(x^*) u_k)(u_k^T (\nabla^2 f(x^*))^{-1} u_k)} + \epsilon.$$

o equivalentemente

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq 1 - \frac{(g_k^T g_k)^2}{(g_k^T \nabla^2 f(x^*) g_k)(g_k^T (\nabla^2 f(x^*))^{-1} g_k)} + \epsilon. \tag{25}$$

Aplicando la **Desigualdad de Kantorovich** a la matriz definida positiva $\nabla^2 f(x^*)$, cuyos autovalores son $0 < \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$:

$$\frac{(g_k^T g_k)^2}{(g_k^T \nabla^2 f(x^*) g_k)(g_k^T (\nabla^2 f(x^*))^{-1} g_k)} \geq \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2}.$$

Insertando la cota de Kantorovich en (25):

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq 1 - \frac{4\lambda_1 \lambda_n}{(\lambda_1 + \lambda_n)^2} + \epsilon = \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 + \epsilon.$$

Dado que por hipótesis $r > \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$, elegimos $\epsilon > 0$ suficientemente pequeño tal que:

$$\left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^2 + \epsilon \leq r^2.$$

En consecuencia, existe un entero K tal que para todo $k \geq K$:

$$\frac{f(x_{k+1}) - f(x^*)}{f(x_k) - f(x^*)} \leq r^2 \implies f(x_{k+1}) - f(x^*) \leq r^2 \left[f(x_k) - f(x^*)\right].$$

□

Observación Crítica y Contraejemplo: Distinción entre el Caso Cuadrático y el Caso General

- **Caso Cuadrático (Teorema 3.3):** La matriz Hessiana es constante ($\nabla^2 f(x) \equiv Q$). Por ende, la cota $r_0 = \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$ se satisface de forma **global y exacta** para toda iteración $k \geq 0$.
- **Caso General C^2 (Teorema 3.4):** La matriz Hessiana $\nabla^2 f(x)$ varía a lo largo de las iteraciones. Por ello, la cota se cumple de forma **asintótica y local** para cualquier escalar $r \in (r_0, 1)$ a partir de un k suficientemente grande ($k \geq K$).

Observación (Efecto del Mal Acondicionamiento): Si $r = 1$, la tasa $\left(\frac{r-1}{r+1}\right)^2 = 0$, lo que implica convergencia en un solo paso. Si $r = 1000$, $\left(\frac{999}{1001}\right)^2 \approx 0{,}996$, lo cual exige cientos de iteraciones para reducir el error de optimización en un 1 %. Esto demuestra que la velocidad del gradiente descendente no depende primordialmente de la dimensión n, sino de la geometría cuadrática (autovalores del Hessiano).

5. Ejercicios Propuestos

Ejercicio Propuesto (Verificación de Condiciones de Wolfe en Funciones Cuadráticas)

Considere la función $f(x_1, x_2) = 10x_1^2 + x_2^2$. Desde el punto inicial $x_0 = (1, 1)^T$, determine la dirección de máximo descenso $p_0 = -\nabla f(x_0)$.

a) Calcule el paso exacto α^* que minimiza $\phi(\alpha) = f(x_0 + \alpha p_0)$.

b) Demuestre analíticamente que para cualquier $c_1 \in (0, 0{,}5)$ y $c_2 \in (c_1, 1)$, el paso exacto α^* satisface las condiciones de Wolfe débiles.

Ejercicio Propuesto (Construcción de Contraejemplo sin Condición de Armijo)

Sea la función $f(x) = x^2$. Suponga un algoritmo de búsqueda lineal sin la condición de Armijo donde se elige la dirección $p_k = -\text{signo}(x_k)$ y el paso $\alpha_k = 2 + 3 \cdot 2^{-(k+1)}$.

a) Muestre que p_k es una dirección de descenso para todo k.

b) Demuestre que la sucesión oscila o no converge al mínimo $x^* = 0$, explicando qué condición falló.

Ejercicio Propuesto (Análisis del Impacto del Número de Condición en Convergencia Local)

Considere la función no lineal de Rosenbrock $f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$.

a) Verifique que $x^* = (1, 1)^T$ es el único mínimo global y calcule la matriz Hessiana $\nabla^2 f(x^*)$.

b) Determine los autovalores λ_1, λ_2 de $\nabla^2 f(x^*)$ y el número de condición $\kappa(\nabla^2 f(x^*))$.

c) Calcule la tasa asintótica de convergencia teórica $r_0 = \frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1}$ garantizada por el Teorema 3.4 para el método del gradiente descendente.