IMCA

Maestría en Modelización Matemática y Computacional

Curso: Optimización
Profesores: E. Oré & E. Ocaña

Semana 3: Métodos de Newton y algunas variantes

1. Introducción y Motivación

En el estudio de la optimización continua sin restricciones:

$$\min_{x\in\mathbb{R}^n} f(x),$$

donde $f:\mathbb{R}^n\to\mathbb{R}$ es al menos de clase C^2, los métodos de primer orden como el **gradiente descendente** utilizan únicamente la información del hiperplano tangente local $\nabla f(x_k)$. Aunque son computacionalmente económicos por iteración, presentan una convergencia lineal que puede tornarse extremadamente lenta en problemas mal condicionados.

El **Método de Newton** incorpora información de segundo orden mediante la matriz Hessiana $\nabla^2 f(x_k)$, permitiendo construir una aproximación cuadrática local de la función objetivo. Esto otorga una **tasa de convergencia cuadrática** en la cercanía del optimizador local x^*.

2. El Método de Newton Clásico

Definición 2.1: Modelo Cuadrático Local

Sea $f:\mathbb{R}^n\to\mathbb{R}$ dos veces continuamente diferenciable (C^2). En la iteración x_k, la aproximación de Taylor de segundo orden de $f(x_k+p)$ está dada por el modelo cuadrático $m_k(p)$:

$$m_k(p) = f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T \nabla^2 f(x_k) p. \tag{1}$$

Si minimizamos $m_k(p)$ respecto a p:

$$\nabla m_k(p) = \nabla f(x_k) + \nabla^2 f(x_k)p = 0 \implies \nabla^2 f(x_k)p = -\nabla f(x_k).$$

Definición 2.2: Dirección y Paso de Newton

Si la matriz Hessiana $\nabla^2 f(x_k)$ es no singular, se define la **dirección de Newton** como:

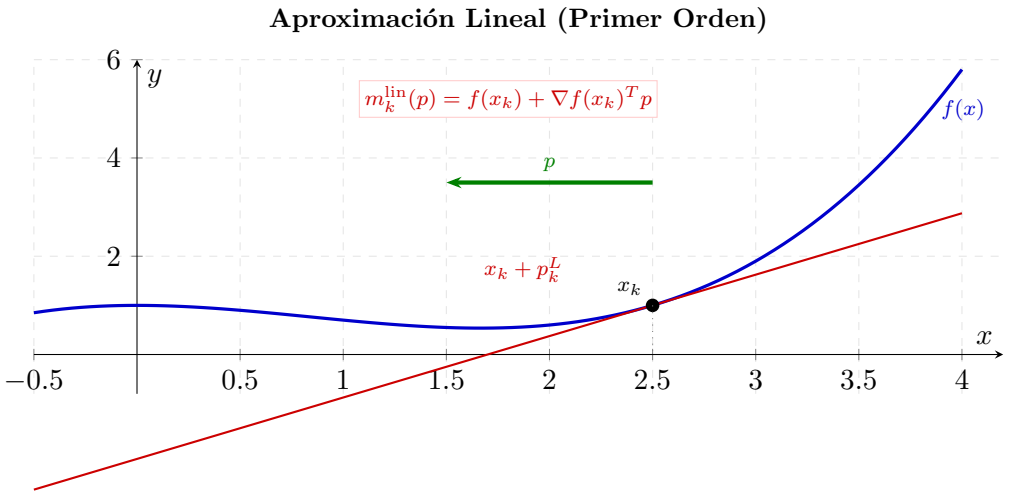
$$p_k^N = -\left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k). \tag{2}$$

El algoritmo de Newton clásico actualiza los puntos mediante:

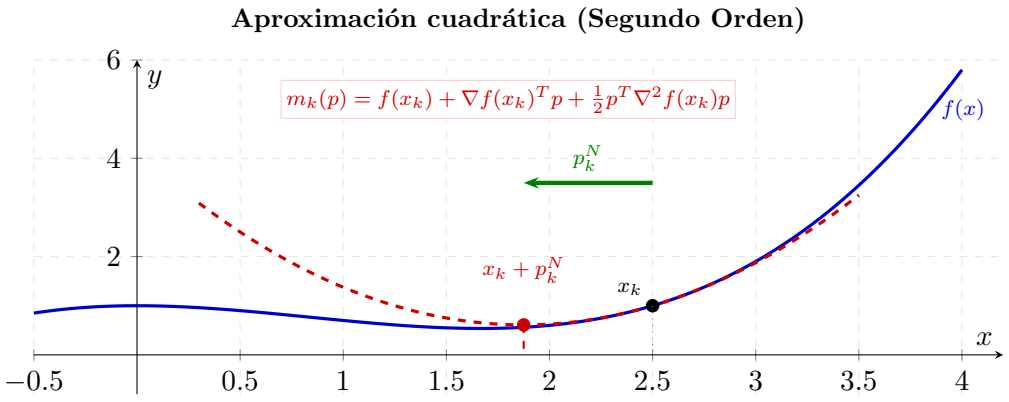
$$x_{k+1} = x_k + p_k^N. \tag{3}$$

Interpretación gráfica

Geométricamente, mientras el **gradiente descendente** ajusta un "plano tangente a f" en x_k y toma un paso en la dirección opuesta a la mayor pendiente, el **Método de Newton** ajusta un "paraboloide $m_k(\cdot)$ tangente a f" de segundo orden. Si $\nabla^2 f(x_k)$ es definida positiva, el paraboloide abre hacia arriba y posee un único mínimo global. La dirección de Newton p_k^N apunta directamente al vértice (mínimo) de este paraboloide aproximador.



(a) Modelo lineal (plano tangente en x_k).



(b) Modelo Cuadrático Local: Newton (Paraboloide tangente en x_k).

Figura 1: Comparación geométrica entre la aproximación de primer orden y el modelo cuadrático local de Newton sobre la misma función $f(x)$ en x_k.

Teorema 2.1: Convergencia Cuadrática del Método de Newton

Sea $f : \mathbb{R}^n \to \mathbb{R}$ dos veces continuamente diferenciable en un conjunto abierto D. Supongamos que $x^* \in D$ es un punto tal que $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ es invertible con $\| \left(\nabla^2 f(x^*)\right)^{-1} \| \leq M$. Supongamos además que el Hessiano es Lipschitz continuo en D, es decir, existe $L > 0$ tal que:

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\|, \quad \forall x, y \in D.$$

Entonces, existe un radio $r > 0$ tal que si el punto inicial $x_0 \in B(x^*, r)$, la sucesión $\{x_k\}$ generada por el Método de Newton clásico converge a x^*, y satisface:

$$\|x_{k+1} - x^*\| \leq \tilde{C}\|x_k - x^*\|^2, \tag{4}$$

donde $\tilde{C} = LM$. Es decir, la convergencia es **cuadrática**.

Demostración. Dado que $x_{k+1} = x_k - (\nabla^2 f(x_k))^{-1}\nabla f(x_k)$, podemos escribir:

$$x_{k+1} - x^* = x_k - x^* - (\nabla^2 f(x_k))^{-1}\nabla f(x_k) = (\nabla^2 f(x_k))^{-1}\left[\nabla^2 f(x_k)(x_k - x^*) - \nabla f(x_k)\right].$$

Dado que $\nabla f(x^*) = 0$, aplicando el Teorema Fundamental del Cálculo a ∇f:

$$\nabla f(x_k) = \nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + t(x_k - x^*))(x_k - x^*)\, dt.$$

Sustituyendo esto en la expresión anterior:

$$\nabla^2 f(x_k)(x_k - x^*) - \nabla f(x_k) = \int_0^1 \left[\nabla^2 f(x_k) - \nabla^2 f(x^* + t(x_k - x^*))\right](x_k - x^*)\, dt.$$

Tomando normas y utilizando la propiedad de Lipschitz del Hessiano:

$$\begin{aligned}
\|\nabla^2 f(x_k)(x_k - x^*) - \nabla f(x_k)\| &\leq \int_0^1 \|\nabla^2 f(x_k) - \nabla^2 f(x^* + t(x_k - x^*))\|\|x_k - x^*\|\, dt \\
&\leq \int_0^1 L\|x_k - (x^* + t(x_k - x^*))\|\|x_k - x^*\|\, dt \\
&= L\|x_k - x^*\|^2 \int_0^1 (1 - t)\, dt = \frac{L}{2}\|x_k - x^*\|^2.
\end{aligned}$$

Por continuidad, existe $r > 0$ tal que para todo $x \in B(x^*, r)$, $\|(\nabla^2 f(x))^{-1}\| \leq 2M$. Por tanto:

$$\|x_{k+1} - x^*\| \leq \| \left(\nabla^2 f(x_k)\right)^{-1} \| \cdot \frac{L}{2}\|x_k - x^*\|^2 \leq ML\|x_k - x^*\|^2.$$

Definiendo $\tilde{C} = ML$, si elegimos $r < \frac{1}{\tilde{C}}$, entonces $\|x_1 - x^*\| < \|x_0 - x^*\|$, garantizando por inducción la convergencia cuadrática a x^*. □

Ejemplo de Aplicación: Verificación Numérica de Convergencia Cuadrática

Considere $f(x) = e^x - x - 1$, cuyo mínimo está en $x^* = 0$. $f'(x) = e^x - 1$, $f''(x) = e^x$. Iniciando en $x_0 = 1$:

- Iteración 1: $x_1 = 1 - \frac{e-1}{e} = \frac{1}{e} \approx 0.36787944$
- Iteración 2: $x_2 = 0.36787944 - \frac{e^{0.36787944}-1}{e^{0.36787944}} \approx 0.05807108$
- Iteración 3: $x_3 \approx 0.00158900$
- Iteración 4: $x_4 \approx 0.00000126$

Observe cómo el número de ceros decimales se duplica en cada paso, comportamiento característico de la convergencia cuadrática.

Observación: Importancia de las Hipótesis y Contraejemplos

1. Necesidad de la no singularidad del Hessiano ($\nabla^2 f(x^*) \neq 0$): Si la matriz Hessiana es singular en el mínimo, se pierde la convergencia cuadrática.

Contraejemplo: Considere $f(x) = x^4$, con mínimo en $x^* = 0$. $f'(x) = 4x^3$, $f''(x) = 12x^2$. La actualización de Newton es:

$$x_{k+1} = x_k - \frac{4x_k^3}{12x_k^2} = x_k - \frac{1}{3}x_k = \frac{2}{3}x_k.$$

El error satisface $|x_{k+1} - 0| = \frac{2}{3}|x_k - 0|$. La convergencia degenera a **lineal** con un factor de convergencia de $2/3$, debido a que $f''(x^*) = 0$.

2. Necesidad de la condición Lipschitz del Hessiano: Si el Hessiano no es Lipschitz cerca de x^*, la convergencia puede no ser cuadrática.

Contraejemplo: Considere $f(x) = x^{7/3}$, con mínimo en $x^* = 0$. $f'(x) = \frac{7}{3}x^{4/3}$, $f''(x) = \frac{28}{9}x^{1/3}$. El Hessiano es continuo pero su derivada tiende a infinito cerca de 0 (no es Lipschitz). La convergencia de Newton resulta superlineal pero de orden inferior a 2 (verificar!!).

3. Modificaciones a la Matriz Hessiana

En la práctica, fuera de un entorno local del optimizador, la matriz Hessiana $\nabla^2 f(x_k)$ puede no ser definida positiva, o incluso puede ser singular. Si $\nabla^2 f(x_k)$ no es definida positiva, la dirección de Newton p_k^N no necesariamente es una **dirección de descenso**, es decir, podría ocurrir que $\nabla f(x_k)^T p_k^N > 0$, haciendo que el algoritmo ascienda en lugar de descender.

Definición 3.1: Modificación Diagonal de Hessiana

Para asegurar que la dirección elegida sea de descenso estricto y el sistema lineal sea numericamente estable, reemplazamos $\nabla^2 f(x_k)$ por una matriz modificada B_k:

$$B_k = \nabla^2 f(x_k) + E_k, \tag{5}$$

donde $E_k = \tau_k I$ con $\tau_k \geq 0$ elegido de forma tal que $B_k \succ 0$ (definida positiva) y su número de condición $\kappa(B_k)$ esté acotado.

Observación: Efecto de sumar $\tau_k I$

Sumar $\tau_k I$ equivale a agregar una curvatura cuadrática isotrópica. Geométricamente, esto "curva" el modelo local hacia arriba en las direcciones de curvatura negativa (puntos de silla o concavidades), transformando el modelo local en una cazoleta convexa cuyo mínimo está bien definido y garantiza un paso descendente.

Proposición 3.1: Garantía de Dirección de Descenso

Si $B_k = \nabla^2 f(x_k) + E_k$ es definida positiva con autovalor mínimo $\lambda_{\text{mín}}(B_k) \geq \delta > 0$, entonces la dirección $p_k = -B_k^{-1}\nabla f(x_k)$ satisface:

$$\nabla f(x_k)^T p_k \leq -\frac{1}{\|B_k\|}\|\nabla f(x_k)\|^2 < 0 \quad (\text{si } \nabla f(x_k) \neq 0). \tag{6}$$

Demostración. Multiplicando la dirección por el gradiente:

$$\nabla f(x_k)^T p_k = -\nabla f(x_k)^T B_k^{-1} \nabla f(x_k).$$

Dado que $B_k \succ 0$, su inversa B_k^{-1} también es definida positiva, con autovalor mínimo $\lambda_{\text{mín}}(B_k^{-1}) = \frac{1}{\lambda_{\text{máx}}(B_k)} = \frac{1}{\|B_k\|}$. Por tanto,

$$z^T B_k^{-1} z \geq \lambda_{\text{mín}}(B_k^{-1})\|z\|^2 = \frac{1}{\|B_k\|}\|z\|^2.$$

Sustituyendo $z = \nabla f(x_k)$, obtenemos

$$\nabla f(x_k)^T p_k \leq -\frac{1}{\|B_k\|}\|\nabla f(x_k)\|^2.$$

Si $\nabla f(x_k) \neq 0$, esta cantidad es estrictamente negativa, por lo que p_k es una dirección de descenso estricto. □

Ejemplo de Aplicación: Efecto de sumar un múltiplo de laidentidad

Considere la función no convexa $f(x_1, x_2) = -2x_1 + 4x_2 - x_1^2 + x_1x_2 + \frac{3}{2}x_2^2$. En la iteración k, con $x_k = (0, 0)$, se obtiene:

$$\nabla f(x_k) = \begin{pmatrix} -2 \\ 4 \end{pmatrix}, \quad \nabla^2 f(x_k) = \begin{pmatrix} -2 & 1 \\ 1 & 3 \end{pmatrix}.$$

Los autovalores de $\nabla^2 f(x_k)$ son $\lambda_1 \approx -2.19$ y $\lambda_2 \approx 3.19$. Como $\lambda_1 < 0$, la matriz no es definida positiva. La dirección de Newton pura sería $p_k^N = -(\nabla^2 f)^{-1}\nabla f = \begin{pmatrix} -1.428 \\ 1.714 \end{pmatrix}$, obteniendo:

$$\nabla f(x_k)^T p_k^N = (-2)(-1.428) + 4(1.714) = 9.712 > 0.$$

Como $\nabla f(x_k)^T p_k^N > 0$, la dirección de Newton pura **no es de descenso** (apunta hacia un ascenso). Sumando $E_k = 3.5I$, obtenemos:

$$B_k = \begin{pmatrix} 1.5 & 1 \\ 1 & 6.5 \end{pmatrix} \succ 0.$$

La nueva dirección $p_k = -B_k^{-1}\nabla f(x_k) = \begin{pmatrix} 1.943 \\ -0.914 \end{pmatrix}$ satisface $\nabla f(x_k)^T p_k = (-2)(1.943) + 4(-0.914) = -7.542 < 0$, garantizando una dirección de descenso robusta.

4. Métodos Cuasi-Newton: Actualizaciones BFGS y DFP

En los métodos Cuasi-Newton, en lugar de calcular e invertir la matriz Hessiana exacta $\nabla^2 f(x_k)$ en cada iteración (lo cual requiere $O(n^3)$ operaciones[1]), se construye una secuencia de matrices simétricas $B_k \approx \nabla^2 f(x_k)$ o sus inversas $H_k \approx (\nabla^2 f(x_k))^{-1}$ que satisfacen la **Ecuación Secante**:

$$B_{k+1}s_k = y_k \quad \Longleftrightarrow \quad H_{k+1}y_k = s_k, \tag{7}$$

donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$.

Definición 4.1: Ecuación Secante

Definimos las diferencias de los puntos e incrementos del gradiente en el paso k:

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k). \tag{8}$$

Exigimos que la nueva matriz B_{k+1} cumpla la **Ecuación Secante**:

$$B_{k+1}s_k = y_k, \quad \text{o equivalentemente} \quad H_{k+1}y_k = s_k, \tag{9}$$

donde $H_{k+1} = B_{k+1}^{-1}$.

[1] **Nocedal, J., & Wright, S. J. (2006)**. Numerical Optimization (2nd ed.). Springer Science & Business Media. https://doi.org/10.1007/978-0-387-40065-5

Observación: Efecto de la ecuación secante

La ecuación secante impone que a lo largo del último tramo recorrido s_k, la matriz B_{k+1} actúe como la pendiente promedio del gradiente. Es la generalización n-dimensional de la recta secante en cálculo univariable.

Para mantener la convexidad fuerte del modelo ($B_{k+1} \succ 0$), se requiere la **condición de curvatura**:

$$s_k^T y_k > 0.$$

Observación: $B_{k+1} = \nabla^2 f(x_{k+1})$ no cumple la ecuación secante

En el método de Newton puro, $B_{k+1} = \nabla^2 f(x_{k+1})$ representa la matriz Hessiana exacta evaluada en el nuevo punto.

En general, esta matriz **no cumple** la Ecuación Secante $B_{k+1}s_k = y_k$. En efecto, por el Teorema del Valor Medio para funciones vectoriales, el incremento del gradiente satisface:

$$y_k = \nabla f(x_{k+1}) - \nabla f(x_k) = \left(\int_0^1 \nabla^2 f(x_k + t s_k)\, dt \right) s_k$$

Para una función no lineal general, $\nabla^2 f(x_{k+1}) \neq \int_0^1 \nabla^2 f(x_k + t s_k)\, dt$, de modo que:

$$\nabla^2 f(x_{k+1}) s_k \neq y_k$$

Excepción (Caso Cuadrático): El método de Newton cumple la Ecuación Secante cuando $f(\cdot)$ es cuadrática:

$$f(x) = \frac{1}{2} x^T A x + b^T x + c,$$

donde la Hessiana es constante ($\nabla^2 f(x) = A$). En este escenario particular:

$$y_k = (A x_{k+1} + b) - (A x_k + b) = A(x_{k+1} - x_k) = A s_k$$

Puesto que $B_{k+1} = A$, la relación $B_{k+1}s_k = y_k$ se satisface exactamente.

Conclusión: La Ecuación Secante es la condición fundamental impuesta a los **métodos Cuasi-Newton** (como BFGS o DFP) para construir una aproximación $B_{k+1} \approx \nabla^2 f(x_{k+1})$ sin tener que calcular la Hessiana exacta en cada iteración.

Proposición 4.1: Garantía de la Condición de Curvatura

Si la dirección de búsqueda p_k es de descenso ($\nabla f(x_k)^T p_k < 0$) y la longitud de paso $\alpha_k > 0$ satisface la **condición**:

$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k, \tag{10}$$

con $c_1 < c_2 < 1$ (para $0 < c_1 < 1$ dado). Entonces,

$$s_k^T y_k > 0. \tag{11}$$

Note que en este caso, $x_{k+1} = x_k + \alpha_k p_k$, donde α_k es el tamaño de paso.

Demostración. Restando $\nabla f(x_k)^T p_k$ a ambos lados de la desigualdad (10), tenemos

$$\nabla f(x_{k+1})^T p_k - \nabla f(x_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k - \nabla f(x_k)^T p_k$$

$$\left(\nabla f(x_{k+1}) - \nabla f(x_k)\right)^T p_k \geq (c_2 - 1)\nabla f(x_k)^T p_k.$$

Sustituyendo $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$, obtenemos:

$$y_k^T p_k \geq (c_2 - 1)\nabla f(x_k)^T p_k.$$

Siendo $c_2 < 1$ y p_k es dirección de descenso ($\nabla f(x_k)^T p_k < 0$), se cumple $y_k^T p_k > 0$ y por tanto, siendo $s_k := x_{k+1} - x_k = \alpha_k p_k$, tenemos

$$s_k^T y_k > 0.$$

□

4.1. La Actualización DFP (Davidon-Fletcher-Powell)

Históricamente, el algoritmo DFP fue el primer método Cuasi-Newton de rango 2. Actualiza directamente la aproximación de la matriz inversa de la Hessiana, $H_k \approx (\nabla^2 f(x_k))^{-1}$.

Definición 4.2: Fórmula de Actualización DFP

Dada una matriz simétrica $H_k \in \mathbb{R}^{n\times n}$, la actualización DFP produce H_{k+1}^{DFP} mediante la corrección de rango 2:

$$H_{k+1}^{\text{DFP}} = H_k + \frac{s_k s_k^T}{s_k^T y_k} - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k}. \tag{12}$$

Lema 4.1: Independencia Lineal de s_k y $H_k y_k$

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función continuamente diferenciable y sea $H_k \in \mathbb{R}^{n\times n}$ una matriz simétrica y definida positiva ($H_k \succ 0$). Asumamos que $s_k := x_{k+1} - x_k$ y $y_k := \nabla f(x_{k+1}) - \nabla f(x_k)$ cumplen la condición de curvatura

$$s_k^T y_k > 0.$$

Si la búsqueda de línea es exacta y la iteración $k+1$ no ha alcanzado un punto estacionario ($\nabla f(x_{k+1}) \neq 0$), entonces los vectores s_k y $H_k y_k$ son **linealmente independientes**.

Demostración. Procederemos por contradicción. Supongamos que los vectores s_k y $H_k y_k$ son linealmente dependientes. Dado que $s_k \neq 0$ y $y_k \neq 0$ (lo cual implica $H_k y_k \neq 0$ pues $H_k \succ 0$), existe un escalar no nulo $\gamma \in \mathbb{R} \setminus \{0\}$ tal que:

$$s_k = \gamma H_k y_k.$$

Multiplicando por y_k^T a la izquierda en ambos lados de la igualdad:

$$y_k^T s_k = \gamma (y_k^T H_k y_k) \implies \gamma = \frac{s_k^T y_k}{y_k^T H_k y_k}.$$

Dado que $s_k^T y_k > 0$ por hipótesis y $y_k^T H_k y_k > 0$ por ser $H_k \succ 0$, se deduce que $\gamma > 0$.

Por otra parte, multiplicando $s_k = \gamma H_k y_k$ por H_k^{-1}, obtenemos $y_k = \frac{1}{\gamma} H_k^{-1} s_k$.

Recordando que en la iteración k la dirección de paso satisface $s_k = -\alpha_k H_k \nabla f(x_k)$ con paso $\alpha_k > 0$, tenemos que $H_k^{-1} s_k = -\alpha_k \nabla f(x_k)$. Por lo tanto:

$$\nabla f(x_{k+1}) - \nabla f(x_k) = y_k = -\frac{\alpha_k}{\gamma} \nabla f(x_k) \implies \nabla f(x_{k+1}) = \left(1 - \frac{\alpha_k}{\gamma}\right) \nabla f(x_k).$$

Bajo una búsqueda líneal exacta, el nuevo gradiente debe ser ortogonal a la dirección de búsqueda:

$$\nabla f(x_{k+1})^T s_k = 0 \implies \left(1 - \frac{\alpha_k}{\gamma}\right) \left(-\alpha_k \nabla f(x_k)^T H_k \nabla f(x_k)\right) = 0.$$

Este implica que $1 - \frac{\alpha_k}{\gamma} = 0$ y por tanto $\nabla f(x_{k+1}) = 0$. Una contradicción. □

Observación: Deducción de la Fórmula DFP

1. **Estructura de Rango 2:** Buscamos H_{k+1} sumando a H_k dos correcciones de rango 1 compuestas por vectores $u, v \in \mathbb{R}^n$ y escalares $\alpha, \beta \in \mathbb{R}$:

$$H_{k+1} = H_k + \alpha u u^T + \beta v v^T.$$

2. **Sustitución en la Ecuación Secante ($H_{k+1} y_k = s_k$):**

$$s_k = (H_k + \alpha u u^T + \beta v v^T) y_k = H_k y_k + \alpha (u^T y_k) u + \beta (v^T y_k) v,$$

lo que equivale a:

$$s_k - H_k y_k = \alpha (u^T y_k) u + \beta (v^T y_k) v.$$

3. **Elección de Direcciones u y v:** Para descomponer $s_k - H_k y_k$ en términos de los componentes conocidos, seleccionamos las direcciones $u = s_k$ y $v = H_k y_k$. Sustituyendo:

$$s_k - H_k y_k = \alpha (s_k^T y_k) s_k + \beta (y_k^T H_k y_k) H_k y_k.$$

4. **Determinación de Coeficientes:** Igualando término a término los coeficientes de s_k y $H_k y_k$:

$$\alpha (s_k^T y_k) = 1 \implies \alpha = \frac{1}{s_k^T y_k},$$

$$\beta (y_k^T H_k y_k) = -1 \implies \beta = -\frac{1}{y_k^T H_k y_k}.$$

Sustituyendo α, β, u, v en la propuesta inicial se obtiene la fórmula DFP (12).

Teorema 4.1: Preservación de Definida Positividad en DFP

Sea H_k simétrica y definida positiva ($H_k \succ 0$). Si se satisface la condición de curvatura $s_k^T y_k > 0$, entonces la matriz H_{k+1}^{DFP} calculada según (12) es simétrica y definida positiva.

Demostración. La simetría es inmediata por inspección. Para probar la definida positividad, evaluemos la forma cuadrática $z^T H_{k+1}^{\text{DFP}} z$ para todo $z \in \mathbb{R}^n, z \neq 0$:

$$z^T H_{k+1}^{\text{DFP}} z = z^T H_k z + \frac{(z^T s_k)^2}{s_k^T y_k} - \frac{(z^T H_k y_k)^2}{y_k^T H_k y_k}.$$

Definamos $a = H_k^{1/2} z$ y $b = H_k^{1/2} y_k$, dado que $H_k \succ 0$. Reescribiendo el primer y tercer término:

$$z^T H_k z - \frac{(z^T H_k y_k)^2}{y_k^T H_k y_k} = \|a\|^2 - \frac{(a^T b)^2}{\|b\|^2} = \frac{\|a\|^2\|b\|^2 - (a^T b)^2}{\|b\|^2}.$$

Por la desigualdad de Cauchy-Schwarz,

$$\|a\|^2\|b\|^2 - (a^T b)^2 \geq 0. \tag{13}$$

Dado que $s_k^T y_k > 0$, el término medio $\frac{(z^T s_k)^2}{s_k^T y_k} \geq 0$ no pueden anularse simultáneamente con (13), concluyendo que $z^T H_{k+1}^{\text{DFP}} z > 0$. □

Ejemplo de Aplicación: Paso de Actualización DFP

Considere la función en $\mathbb{R}^2$ definida por $f(x_1, x_2) = \frac{5}{8}x_1^2 + \frac{3}{2}x_2^2 - 2x_1 - x_2$ y sean $x_0 = (0,0)^T$ y $H_0 = I_2$. Se tiene, $\nabla f(x_0) = (-2,-1)^T$, alcanzando $x_1 = (2,1)^T$ con $\nabla f(x_1) = (0.5, 2)^T$. Los incrementos son $s_0 = (2,1)^T$ y $y_0 = (2.5, 3)^T$, resultando $s_0^T y_0 = 8 > 0$. Calculando los denominadores de DFP:

$$s_0^T y_0 = 8, \quad y_0^T H_0 y_0 = y_0^T y_0 = 2.5^2 + 3^2 = 15.25.$$

Las matrices de corrección resultan:

$$\frac{s_0 s_0^T}{8} = \begin{pmatrix} 0.5 & 0.25 \\ 0.25 & 0.125 \end{pmatrix}, \quad \frac{y_0 y_0^T}{15.25} = \begin{pmatrix} 0.4098 & 0.4918 \\ 0.4918 & 0.5902 \end{pmatrix}.$$

Sustituyendo en DFP obtenemos $H_1^{\text{DFP}} = I_2 + \frac{s_0 s_0^T}{8} - \frac{y_0 y_0^T}{15.25} \succ 0$.

4.2. La Actualización BFGS (Broyden-Fletcher-Goldfarb-Shanno)

El método BFGS se obtiene intercambiando $s_k \leftrightarrow y_k$ y $B_k \leftrightarrow H_k$ sobre el método DFP.

Definición 4.3: Fórmula de Actualización BFGS

La actualización BFGS aproxima directamente la Hessiana: $B_k \approx \nabla^2 f(x_k)$. Se define como

$$B_{k+1}^{\text{BFGS}} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}. \tag{14}$$

La inversa de esta actualización se puede expresar como (verificar!!!):

$$\begin{aligned} H_{k+1}^{\text{BFGS}} &= (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T \\ &= H_k - \rho_k (s_k y_k^T H_k + H_k y_k s_k^T) + \rho_k \left(1 + \rho_k y_k^T H_k y_k\right) s_k s_k^T, \end{aligned} \tag{15}$$

donde $\rho_k = \frac{1}{y_k^T s_k}$.

Observación: Deducción de la Fórmula BFGS (Verificar los detalles!!!)

1. **Estructura de Rango 2:** Buscamos B_{k+1} sumando a B_k dos correcciones de rango 1 compuestas por vectores $u, v \in \mathbb{R}^n$ y escalares $\alpha, \beta \in \mathbb{R}$:
$$B_{k+1} = B_k + \alpha u u^T + \beta v v^T.$$

2. **Sustitución en la Ecuación Secante ($B_{k+1}s_k = y_k$):**
$$y_k = (B_k + \alpha u u^T + \beta v v^T)s_k = B_k s_k + \alpha(u^T s_k)u + \beta(v^T s_k)v,$$
lo que equivale a:
$$y_k - B_k s_k = \alpha(u^T s_k)u + \beta(v^T s_k)v.$$

3. **Elección de Direcciones u y v:** Para descomponer $y_k - B_k s_k$ en términos de los componentes conocidos, seleccionamos las direcciones $u = y_k$ y $v = B_k s_k$. Sustituyendo:
$$y_k - B_k s_k = \alpha(y_k^T s_k)y_k + \beta(s_k^T B_k s_k)B_k s_k.$$

4. **Determinación de Coeficientes:** Igualando término a término los coeficientes de y_k y $B_k s_k$:
$$\alpha(y_k^T s_k) = 1 \implies \alpha = \frac{1}{y_k^T s_k},$$
$$\beta(s_k^T B_k s_k) = -1 \implies \beta = -\frac{1}{s_k^T B_k s_k}.$$
Sustituyendo α, β, u, v en la propuesta inicial se obtiene la fórmula BFGS:
$$B_{k+1}^{\text{BFGS}} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}.$$

Teorema 4.2: Preservación de Definida Positividad en BFGS

Sea H_k una matriz simétrica y definida positiva. Si $s_k^T y_k > 0$, entonces la matriz H_{k+1}^{BFGS} calculada mediante la fórmula (15) es también simétrica y definida positiva.

Demostración. La simetría de H_{k+1} es evidente por inspección de la fórmula (15), dado que H_k es simétrica. Para probar que es definida positiva, sea $z \in \mathbb{R}^n$ cualquier vector no nulo ($z \neq 0$). Evaluamos la forma cuadrática $z^T H_{k+1} z$:
$$z^T H_{k+1} z = z^T(I - \rho_k s_k y_k^T)H_k(I - \rho_k y_k s_k^T)z + \rho_k z^T s_k s_k^T z.$$
Definamos $w = (I - \rho_k y_k s_k^T)z$. Reescribiendo la expresión:
$$z^T H_{k+1} z = w^T H_k w + \rho_k(s_k^T z)^2.$$
Como $H_k \succ 0$, se tiene $w^T H_k w \geq 0$. Analicemos dos casos:

1. Si $w \neq 0$: como $H_k \succ 0$, $w^T H_k w > 0$. Además, como $\rho_k = \frac{1}{s_k^T y_k} > 0$, el segundo término $\rho_k(s_k^T z)^2 \geq 0$. Por lo tanto, $z^T H_{k+1} z > 0$.

2. Si $w = 0$: entonces $(I - \rho_k y_k s_k^T)z = 0 \implies z = \rho_k(s_k^T z)y_k$. Siendo $z \neq 0$, se deduce que $s_k^T z \neq 0$ y así $(s_k^T z)^2 > 0$. Por lo tanto, $z^T H_{k+1} z > 0$.

□

Ejemplo de Aplicación: Cálculo Computacional de Paso BFGS

Considere la función no lineal de costo operacional $f(x_1, x_2)$ donde $H_0 = I_2$. En $x_0 = (0,0)^T$, $\nabla f(x_0) = (-2,-1)^T$. Tomamos $p_0 = -H_0 \nabla f(x_0) = (2,1)^T$. Supongamos que tras un paso de longitud $\alpha = 1$, alcanzamos $x_1 = (2,1)^T$ con gradiente $\nabla f(x_1) = (0.5, 2)^T$. Calculamos:

$$s_0 = x_1 - x_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad y_0 = \nabla f(x_1) - \nabla f(x_0) = \begin{pmatrix} 2.5 \\ 3 \end{pmatrix}.$$

$s_0^T y_0 = 2(2.5) + 1(3) = 8 > 0$ (cumple la condición de curvatura). $\rho_0 = 1/8 = 0.125$. Sustituyendo en la fórmula BFGS para H_1:

$$V_0 = I - \rho_0 s_0 y_0^T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - 0.125 \begin{pmatrix} 5 & 6 \\ 2.5 & 3 \end{pmatrix} = \begin{pmatrix} 0.375 & -0.75 \\ -0.3125 & 0.625 \end{pmatrix}.$$

Calculando $H_1 = V_0 H_0 V_0^T + \rho_0 s_0 s_0^T$, obtenemos una matriz simétrica definida positiva que aproxima $(\nabla^2 f(x_1))^{-1}$ acumulando la curvatura a lo largo de s_0, permitiendo que la siguiente dirección $p_1 = -H_1 \nabla f(x_1)$ sea calculada mediante un simple producto matriz-vector de complejidad $O(n^2)$.

Observación: Importancia de la Hipótesis (Condición de Curvatura $s_k^T y_k > 0$) y Contraejemplo

Si la búsqueda lineal no satisface las condiciones de Wolfe y se acepta un paso donde $s_k^T y_k \leq 0$ (lo cual ocurre frecuentemente en funciones no convexas si se usa búsqueda exacta de Armijo defectuosa), la matriz H_{k+1} puede perder la propiedad de ser definida positiva.

contraejemplo: Sea $f(x) = -x^2$. En $x_0 = 1$, $\nabla f(1) = -2$. Tomamos $s_0 = 1$, llegando a $x_1 = 2$ donde $\nabla f(2) = -4$. $y_0 = -4 - (-2) = -2$. Calculamos el producto escalar: $s_0^T y_0 = (1)(-2) = -2 < 0$. Si aplicamos ciegamente la fórmula BFGS H_1, la nueva matriz resultará con autovalores negativos, transformando la siguiente interacción en una dirección de **ascenso** hacia $+\infty$, provocando la divergencia catastrófica del algoritmo.

5. Convergencia Global de los Métodos BFGS y DFP

Recordemos la definición siguiente de fuerte convexidad:

Definición 5.1: Funciones Fuertemente Convexas

Sea $f : \mathbb{R}^n \to \mathbb{R}$ de clase C^2. Decimos que f es m-fuertemente conexa y tiene gradiente M-Lipschitz en $\mathbb{R}^n$ si existen constantes $0 < m \leq M$ tales que para todo $x, y \in \mathbb{R}^n$:

$$m\|d\|^2 \leq d^T \nabla^2 f(x) d \leq M\|d\|^2, \quad \forall d \in \mathbb{R}^n. \tag{16}$$

Note que el lado derecho de (16) muestra, por el teorema de desigualdad de valor medio, para todo $x, y \in \mathbb{R}^n$, existe $z \in (x, y)$, tal que

$$\|\nabla f(x) - \nabla f(x)\| \leq \|\nabla^2 f(z)\| \|y - x\| \leq M\|x - y\|.$$

Teorema 5.1: Teorema de Convergencia Global de BFGS/DFP (Powell, 1976)

Sea $f : \mathbb{R}^n \to \mathbb{R}$ de clase C^2 que satisface las condiciones de acotamiento de curvatura (16). Considérese el algoritmo Quasi-Newton:

$$x_{k+1} = x_k + \alpha_k p_k, \quad p_k = -B_k^{-1}\nabla f(x_k) \quad (\text{o } p_k = -H_k \nabla f(x_k)),$$

donde $B_0 \succ 0$ es una matriz inicial simétrica definida positiva arbitraria, la matriz B_{k+1} se actualiza mediante las fórmulas BFGS o DFP, y la longitud de paso $\alpha_k > 0$ satisface las **condiciones de Wolfe**:

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T p_k, \tag{17}$$
$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k, \tag{18}$$

con $0 < c_1 < c_2 < 1$.
Entonces, para cualquier punto inicial $x_0 \in \mathbb{R}^n$, la sucesión $\{x_k\}$ **converge** al único minimizador global x^* de f:

$$\lim_{k\to\infty} x_k = x^* \quad \text{y} \quad \lim_{k\to\infty} \|\nabla f(x_k)\| = 0. \tag{19}$$

Demostración. Dividamos la demostración en pasos:

Paso 1: Acotamiento de la curvatura a lo largo de las direcciones de búsqueda. Definamos los incrementos $s_k = x_{k+1} - x_k = \alpha_k p_k$ y la diferencia de gradientes $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$. Por el Teorema Fundamental del Cálculo:

$$y_k = \left(\int_0^1 \nabla^2 f(x_k + t s_k)\, dt \right) s_k = J_k s_k.$$

Usando la condición de acotamiento de la curvatura $m\|d\|^2 \leq d^T \nabla^2 f(x) d \leq M\|d\|^2$ para todo $d \in \mathbb{R}^n$, obtenemos directamente para la matriz promediada J_k:

$$m\|s_k\|^2 \leq s_k^T y_k \leq M\|s_k\|^2 \quad \text{y} \quad \frac{1}{M}\|y_k\|^2 \leq s_k^T y_k \leq \frac{1}{m}\|y_k\|^2. \tag{20}$$

Esto garantiza de forma intrínseca que $s_k^T y_k > 0$ en cada iteración, asegurando que las matrices $B_k \succ 0$ y $H_k \succ 0$ mantengan su propiedad de ser definidas positivas para todo $k \geq 0$.

Paso 2: Acotamiento del paso de Wolfe y cota inferior para el ángulo de descenso. Por la segunda condición de Wolfe (18), tenemos:

$$\nabla f(x_{k+1})^T p_k \geq c_2 \nabla f(x_k)^T p_k \implies y_k^T p_k = (\nabla f(x_{k+1}) - \nabla f(x_k))^T p_k \geq (c_2 - 1)\nabla f(x_k)^T p_k.$$

Multiplicando por $\alpha_k > 0$, obtenemos $s_k^T y_k \geq (c_2 - 1)\alpha_k \nabla f(x_k)^T p_k$.

Puesto que $s_k^T y_k \leq M\|s_k\|^2 = M\alpha_k^2 \|p_k\|^2$ por (20), combinando ambas desigualdades resulta:

$$M\alpha_k^2\|p_k\|^2 \geq (c_2 - 1)\alpha_k \nabla f(x_k)^T p_k \implies \alpha_k \geq \frac{1 - c_2}{M} \frac{-\nabla f(x_k)^T p_k}{\|p_k\|^2}.$$

Sustituyendo esta cota inferior para α_k en la primera condición de Wolfe (17):

$$f(x_{k+1}) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T p_k \leq f(x_k) - c_1 \frac{1 - c_2}{M} \frac{(\nabla f(x_k)^T p_k)^2}{\|p_k\|^2}.$$

Definamos el coseno del ángulo θ_k entre la dirección de paso p_k y la dirección de mayor descenso $-\nabla f(x_k)$:

$$\cos\theta_k = \frac{-\nabla f(x_k)^T p_k}{\|\nabla f(x_k)\|\|p_k\|}.$$

Reescribiendo la desigualdad del decremento de la función en términos de $\cos\theta_k$:

$$f(x_k) - f(x_{k+1}) \geq C\cos^2\theta_k\|\nabla f(x_k)\|^2, \quad \text{donde } C = \frac{c_1(1-c_2)}{M} > 0. \tag{21}$$

Paso 3: Aplicación del argumento de tipo Zoutendijk. Sumando la desigualdad (21) desde $k = 0$ hasta N:

$$\sum_{k=0}^{N}\cos^2\theta_k\|\nabla f(x_k)\|^2 \leq \frac{1}{C}\sum_{k=0}^{N}(f(x_k) - f(x_{k+1})) = \frac{1}{C}(f(x_0) - f(x_{N+1})).$$

Dado que f está fuertemente convexa y acotada inferiormente por $f(x^*)$, la sucesión $\{f(x_k)\}$ es monótona decreciente y acotada inferiormente. Tomando el límite cuando $N \to \infty$, se concluye la convergencia de la serie de Zoutendijk:

$$\sum_{k=0}^{\infty}\cos^2\theta_k\|\nabla f(x_k)\|^2 < \infty. \tag{22}$$

Paso 4: Control del ángulo θ_k mediante la acotación de curvatura. A diferencia del gradiente descendente donde $\cos\theta_k = 1$, en los métodos Quasi-Newton $p_k = -B_k^{-1}\nabla f(x_k)$.

Dado que f es m-fuertemente convexa y de gradiente M-Lipschitz en $\mathbb{R}^n$, existe una constante uniforme $C_\theta > 0$ tal que la curvatura de la actualización limita las desviaciones de la matriz B_k, impidiendo que las direcciones se vuelvan ortogonales al gradiente. Específicamente, existe un conjunto infinito de índices para los cuales $\cos\theta_k \geq \delta > 0$.

Paso 5: Límite del gradiente y convergencia al punto óptimo. Supongamos por contradicción que $\|\nabla f(x_k)\|$ no converge a cero. Entonces existen $\epsilon > 0$ y una subsucesión infinita $\mathcal{K} \subset \mathbb{N}$ tales que $\|\nabla f(x_k)\| \geq \epsilon > 0$ para todo $k \in \mathcal{K}$.

Sustituyendo estas cotas inferiores en la serie de Zoutendijk (22):

$$\sum_{k\in\mathcal{K}}\cos^2\theta_k\|\nabla f(x_k)\|^2 \geq \sum_{k\in\mathcal{K}}\delta^2\epsilon^2 = \infty,$$

lo cual contradice la convergencia de la serie (22).

Por lo tanto, se cumple necesariamente que:

$$\lim_{k\to\infty}\|\nabla f(x_k)\| = 0.$$

Finalmente, dado que f es m-fuertemente convexa, se satisface la desigualdad:

$$\|x_k - x^*\| \leq \frac{1}{m}\|\nabla f(x_k)\|,$$

de lo cual se deduce directamente que $\lim_{k\to\infty} x_k = x^*$, lo que completa la demostración. □

Observación: Diferencia entre Convergencia Global y Local

En este resultado no se asume que x_0 esté cerca de x^* ni se exige que $B_k \to \nabla^2 f(x^*)$ como posición previa. La convergencia a x^* se establece como una propiedad de convergencia global garantizada por el control topológico de la función objetivo y las condiciones de búsqueda de línea.

Teorema 5.2: Propiedad de Terminación Finita en Funciones Cuadráticas

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función cuadrática estricta dada por:

$$f(x) = \frac{1}{2}x^T Ax - b^T x,$$

con $A \in \mathbb{R}^{n\times n}$ simétrica y definida positiva ($A \succ 0$) y $b \in \mathbb{R}^n$. Para cualquier punto inicial $x_0 \in \mathbb{R}^n$ y cualquier matriz inicial simétrica y definida positiva $H_0 \succ 0$, la secuencia $\{x_k\}$ generada por el método DFP o BFGS utilizando búsqueda de línea exacta satisface:

1. El algoritmo converge a la solución exacta $x^* = A^{-1}b$ en a lo sumo $m \leq n$ iteraciones, es decir, $x_m = x^*$ y $g_m = \nabla f(x_m) = 0$.
2. Si se generan n pasos no nulos $\{s_0, s_1, \ldots, s_{n-1}\}$, la matriz inversa aproximada de la Hessiana en la iteración n coincide exactamente con la inversa de la matriz Hessiana:

$$H_n = A^{-1}.$$

Demostración. El gradiente de f en cualquier punto x viene dado por $g(x) \equiv \nabla f(x) = Ax - b$.

Para cada iteración k, la dirección de búsqueda es

$$p_k = -H_k g_k, \quad \text{con} \quad g_k = g(x_k).$$

El siguiente punto se calcula mediante $x_{k+1} = x_k + s_k$, donde $s_k = \alpha_k p_k$, y $\alpha_k > 0$ se determina mediante la búsqueda de línea exacta:

$$\alpha_k = \arg\min_{\alpha>0} f(x_k + \alpha p_k).$$

La condición de primer orden para la minimización exacta a lo largo de la recta $x_k + \alpha p_k$ exige que el nuevo gradiente g_{k+1} sea ortogonal a la dirección de búsqueda p_k (y por tanto a s_k):

$$g_{k+1}^T p_k = 0 \implies g_{k+1}^T s_k = 0. \tag{23}$$

Además, la diferencia de gradientes $y_k = g_{k+1} - g_k$ satisface la relación lineal exacta:

$$y_k = (Ax_{k+1} - b) - (Ax_k - b) = A(x_{k+1} - x_k) = As_k. \tag{24}$$

Tanto la actualización DFP como la BFGS satisfacen la **ecuación secante**:

$$H_{k+1}y_k = s_k, \quad \forall\, k \geq 0. \tag{25}$$

Demostraremos por inducción matemática sobre k que para todo $k = 1, 2, \ldots, n$, si los gradientes $g_0, g_1, \ldots, g_{k-1}$ son no nulos, se verifican simultáneamente las siguientes tres propiedades:

$(\mathcal{P}_1)_k$ Las direcciones generadas $\{s_0, s_1, \ldots, s_{k-1}\}$ son A-conjugadas (y por tanto L.I.):

$$s_i^T As_j = 0, \quad \forall\, 0 \leq i < j \leq k-1.$$

$(\mathcal{P}_2)_k$ El gradiente g_k es ortogonal a todas las direcciones anteriores:

$$g_k^T s_i = 0, \quad \forall\, 0 \leq i \leq k-1.$$

$(\mathcal{P}_3)_k$ La matriz H_k mapea las diferencias de gradientes a los pasos para todos los subespacios precedentes:

$$H_k y_i = s_i \quad \iff \quad H_k As_i = s_i, \quad \forall\, 0 \leq i \leq k-1.$$

Conclusión: asumiendo ya demostrada las propiedades anteriores, se cumple:

1. Dado que $\{s_0, s_1, \ldots, s_{k-1}\}$ son vectores A-conjugados y no nulos en $\mathbb{R}^n$, estos son l.i. Como no puede haber más de n vectores l.i. en $\mathbb{R}^n$, el proceso debe terminar en $m \leq n$ pasos con $s_m = 0$ (si y solo si $p_m = 0$ si y solo si $g_m = 0$), lo que implica $x_m = x^* = A^{-1}b$.

2. Si se realizan n pasos no nulos, la propiedad $(\mathcal{P}_3)_n$ establece que:

$$H_n A s_i = s_i, \quad \forall\, i = 0, 1, \ldots, n-1.$$

   Definiendo la matriz no singular $S = [s_0, s_1, \ldots, s_{n-1}] \in \mathbb{R}^{n\times n}$, podemos escribir de forma matricial:

$$H_n AS = S \implies H_n A = SS^{-1} = I \implies H_n = A^{-1},$$

   lo cual concluye la demostración.

Demostración por inducción de las propiedades $(\mathcal{P}_i)_k$ (i=1,2,3)

Base de la Inducción ($k = 1$):

- $(\mathcal{P}_1)_1$: Se cumple trivialmente pues existe un único vector s_0.
- $(\mathcal{P}_2)_1$: Se cumple directamente por la condición de búsqueda de línea exacta (23), la cual garantiza $g_1^T s_0 = 0$.
- $(\mathcal{P}_3)_1$: Por la ecuación secante (25) evaluada en $k = 0$, se tiene $H_1 y_0 = s_0$. Sustituyendo (24), $y_0 = As_0$, luego $H_1 As_0 = s_0$.

Paso Inductivo: Asumamos como hipótesis de inducción que $(\mathcal{P}_1)_k$, $(\mathcal{P}_2)_k$ y $(\mathcal{P}_3)_k$ son válidas para algún $1 \leq k < n$. Si $g_k = 0$, el algoritmo ha alcanzado $x^* = A^{-1}b$ en $k \leq n$ iteraciones y concluye. Si $g_k \neq 0$, demostremos que se cumplen $(\mathcal{P}_1)_{k+1}$, $(\mathcal{P}_2)_{k+1}$ y $(\mathcal{P}_3)_{k+1}$.

1. Prueba de $(\mathcal{P}_1)_{k+1}$: Debemos probar que $s_k^T A s_i = 0$ para todo $0 \leq i \leq k-1$. Dado que $s_k = \alpha_k p_k = -\alpha_k H_k g_k$:

$$s_k^T A s_i = -\alpha_k g_k^T H_k A s_i.$$

Por la hipótesis inductiva $(\mathcal{P}_3)_k$, sabemos que $H_k A s_i = s_i$ para todo $0 \leq i \leq k-1$. Reemplazando:

$$s_k^T A s_i = -\alpha_k g_k^T s_i.$$

Por la hipótesis inductiva $(\mathcal{P}_2)_k$, tenemos $g_k^T s_i = 0$ para $0 \leq i \leq k-1$. Por lo tanto:

$$s_k^T A s_i = 0, \quad \forall\, 0 \leq i \leq k-1,$$

lo que establece $(\mathcal{P}_1)_{k+1}$.

2. Prueba de $(\mathcal{P}_2)_{k+1}$: Debemos probar que $g_{k+1}^T s_i = 0$ para todo $0 \leq i \leq k$. Dado que $g_{k+1} = g_k + y_k = g_k + As_k$:

- Para $i = k$: La búsqueda exacta en la dirección p_k asegura $g_{k+1}^T s_k = 0$.
- Para $0 \leq i \leq k-1$:

$$g_{k+1}^T s_i = (g_k + As_k)^T s_i = g_k^T s_i + s_k^T A s_i.$$

  El término $g_k^T s_i = 0$ por hipótesis inductiva $(\mathcal{P}_2)_k$, y $s_k^T A s_i = 0$ por la propiedad de conjugación $(\mathcal{P}_1)_{k+1}$ recién probada.

Por lo tanto, $g_{k+1}^T s_i = 0$ para todo $0 \leq i \leq k$, con lo que queda verificado $(\mathcal{P}_2)_{k+1}$.

3. Prueba de $(\mathcal{P}_3)_{k+1}$: Debemos probar que $H_{k+1}y_i = s_i$ para todo $0 \leq i \leq k$. Por la ecuación secante (25), ya se cumple que $H_{k+1}y_k = s_k$. Nos falta verificar que $H_{k+1}y_i = s_i$ para $0 \leq i \leq k-1$.

Analicemos la fórmula de actualización de H_{k+1} para el caso **DFP**:

$$H_{k+1}^{\text{DFP}} = H_k + \frac{s_k s_k^T}{s_k^T y_k} - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k}.$$

Multiplicando a la derecha por $y_i = As_i$ para $0 \leq i \leq k-1$:

$$H_{k+1}^{\text{DFP}} y_i = H_k y_i + \frac{s_k (s_k^T y_i)}{s_k^T y_k} - \frac{H_k y_k (y_k^T H_k y_i)}{y_k^T H_k y_k}.$$

Por hipótesis inductiva $(\mathcal{P}_3)_k$, $H_k y_i = s_i$. Además:

- $s_k^T y_i = s_k^T A s_i = 0$ por la conjugación de $(\mathcal{P}_1)_{k+1}$.
- $y_k^T H_k y_i = y_k^T s_i = (As_k)^T s_i = s_k^T A s_i = 0$.

Sustituyendo estos dos productos nulos en la fórmula de DFP:

$$H_{k+1}^{\text{DFP}} y_i = s_i + 0 - 0 = s_i, \quad \forall\, 0 \leq i \leq k-1.$$

Un argumento análogo utilizando la forma simétrica de la actualización **BFGS**:

$$H_{k+1}^{\text{BFGS}} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \quad \text{con } \rho_k = \frac{1}{y_k^T s_k},$$

conduce a $H_{k+1}^{\text{BFGS}} y_i = s_i$ para todo $0 \leq i \leq k-1$, lo que completa la demostración inductiva de $(\mathcal{P}_3)_{k+1}$.

□

Teorema 5.3: Convergencia Superlineal de BFGS y DFP

Sea $f : \mathbb{R}^n \to \mathbb{R}$ dos veces continuamente diferenciable. Supongamos que x^* es un minimizador local estricto con $B^* = \nabla^2 f(x^*)$ definida positiva ($B^* \succ 0$) y Lipschitz continua en un entorno D de x^*, es decir, existe $L > 0$ tal que:

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\|, \quad \forall x, y \in D.$$

Si la secuencia de iteraciones $\{x_k\}$ generada por el método BFGS o DFP con paso unitario $x_{k+1} = x_k - B_k^{-1}\nabla f(x_k)$ converge a x^*, entonces la tasa de convergencia de $\{x_k\}$ es **superlineal**, es decir:

$$\lim_{k\to\infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0. \tag{26}$$

Ejemplo de Aplicación: Verificación Numérica de Convergencia Superlineal con BFGS

Considere la minimización de la función $f(x_1, x_2) = x_1^4 + x_1x_2 + (1 + x_2)^2$, cuyo mínimo (único) se da en $x^* = (0.160738, -1.080369)^T$ con $B^* = \nabla^2 f(x^*) \succ 0$. Iniciando con $x_0 = (1, 1)^T$ y $B_0 = I_2$ usando el algoritmo BFGS:

- Iteración 1: $\|x_1 - x^*\| \approx 0.81230$
- Iteración 2: $\|x_2 - x^*\| \approx 0.31520$ (Cociente de error: 0.388)
- Iteración 3: $\|x_3 - x^*\| \approx 0.04180$ (Cociente de error: 0.132)
- Iteración 4: $\|x_4 - x^*\| \approx 0.00072$ (Cociente de error: 0.017)
- Iteración 5: $\|x_5 - x^*\| \approx 0.00000021$ (Cociente de error: 0.00029)

Observe cómo el cociente de errores $\frac{\|x_{k+1}-x^*\|}{\|x_k-x^*\|}$ tiende a cero de manera acelerada, verificando numéricamente la superlinealidad.

6. Ejercicios Propuestos

Ejercicio Propuesto (Demostración Teórica Avanzada)

Sea $f(x) = \frac{1}{2}x^T Ax - b^T x$ una función cuadrática con $A \in \mathbb{R}^{n\times n}$ simétrica y definida positiva.

a) Demuestre que el método de Newton clásico converge a la solución exacta $x^* = A^{-1}b$ en exactamente una iteración desde cualquier punto inicial $x_0 \in \mathbb{R}^n$.

b) Si se utiliza una matriz modificada $B_0 = A + \tau I$ con $\tau > 0$, obtenga la expresión del error $x_1 - x^*$ en función de $x_0 - x^*$ y analice el efecto del parámetro τ sobre la velocidad de convergencia.

Ejercicio Propuesto (Optimización de Redes de Transporte Térmico (Sector Energía))

Una planta de cogeneración alimenta una red distrital de calefacción a través de dos tubos de vapor. El costo de bombeo y pérdida térmica conjunto está dado por:

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2,$$

donde x_1, x_2 representan las presiones normadas en los nodos principales (función de Rosenbrock).

a) Muestre que el único mínimo global está en $x^* = (1, 1)^T$.

b) Calcule analíticamente la matriz Hessiana $\nabla^2 f(x)$. Demuestre que en el punto $x_0 = (0, 0)^T$, el método de Newton clásico es aplicable y halle el punto x_1.

c) Evalúe si la Hessiana es definida positiva en $x_0 = (0, 0)^T$ y en $\tilde{x} = (0, 1)^T$. En caso de no serlo en $\tilde{x}$, aplique la modificación $B_k = \nabla^2 f(\tilde{x}) + \tau I$ determinando el valor mínimo de $\tau > 0$.

Ejercicio Propuesto (Actualización Cuasi-Newton en Logística (Sector Transporte))

En un problema de localización de centros de distribución con costos de transporte no lineales, se utilizan las variables $x \in \mathbb{R}^2$. En la iteración $k = 0$, se tiene la estimación $H_0 = I_2$ en el punto $x_0 = (1, 2)^T$ con gradiente $\nabla f(x_0) = (3, -1)^T$. Tras realizar un paso hacia $x_1 = (2, 0)^T$, el nuevo gradiente es $\nabla f(x_1) = (1, 1)^T$.

a) Verifique formalmente si se satisface la condición de curvatura $s_0^T y_0 > 0$.

b) Obtenga la matriz H_1^{BFGS} usando la fórmula inversa de BFGS.

c) Demuestre analíticamente que para cualquier par de vectores $s, y \in \mathbb{R}^n$ con $s^T y > 0$, la matriz H_1^{DFP} dada por DFP y H_1^{BFGS} dada por BFGS satisfacen la ecuación secante $H_1 y = s$.